

## 「不確実性に挑むロボティクス」特集号

解 説

移動ロボットの環境認識  
—地図構築と自己位置推定

友納 正裕\*

## 1. はじめに

移動ロボットは、サービスロボットや探査ロボット、搭乗型ロボットなど多くのロボットの土台となり、ロボティクスの重要な研究分野となっている。ロボットが自律移動するには周囲環境の認識が不可欠であり、最も基本的な認識機能として地図構築と自己位置推定がある。地図構築は障害物やランドマークなどを記した地図を生成する技術であり、自己位置推定は地図上の自分（ロボット）の位置を推定する技術である。

本稿では、自律移動ロボットの地図構築技術を概説する。Thrunらによる『確率ロボティクス』[1]は、移動ロボットの地図構築に関して、非常に見通しのよい理論を提示した。本稿では、その後の主要な研究の流れを紹介する。自己位置推定は地図構築に包含されるが、特有の課題もあり、4. で言及する。


## 2. ロボットによる地図構築とは

本章では、地図構築の原理と難しさについて述べる。ロボットによる地図構築では、ロボットに載せたセンサを用いて地図を作る。本稿では、簡単のため、センサとロボットの座標系を同一視し、ロボットの「位置」は「向き」も含むとする。また、GPSは考えない。

センサの観測範囲は限られるため、ロボットは移動しながらセンサデータを取得し、それらをつなぎ合わせて地図を作ることになる。センサはロボットに載っているため、センサデータはロボット座標系で得られる。そのため、センサデータをつなぎ合わせるには、ロボット座標系から地図座標系への変換が必要になる。この変換を行うには、地図座標系におけるロボット座標系の位置（ロボット位置）がわかればよい。しかし、ロボット位置を知るにはそもそも地図が必要である。このように、地図構築と自己位置推定は相互に依存するため、これらを同時推定するSLAM(Simultaneous Localization and Mapping)が研究されてきた。

## 2.1 SLAM

第1図を例に、SLAMの考え方を2次元空間で説明する。回転の扱いに注意すれば、3次元でも同じ議論が成り



第1図 ロボット位置と地図の関係

立つ。ロボティクスにおける地図には、点群地図、格子地図、幾何地図、位相地図など多くの種類があるが、ここでは、最も基本的な点群地図を考える。点群地図では、地図は点の集合からなる。地図上の各点をランドマークとよぶこともある。

## (1) 観測点の位置の推定

上記のように、観測点の地図上の位置はロボット位置がわかれば計算できる。たとえば、点 $p_2$ の位置（地図座標系での2次元座標）は、観測データ $q_2$ （ロボット座標系での2次元座標）とロボット位置 $r_1 = (x_1, y_1, \theta_1)^T$ から(1)式で計算できる。 $R_1$ はロボットの向き $\theta_1$ による回転行列、 $r'_1$ は並進成分 $(x_1, y_1)^T$ である。

$$p_2 = R_1 q_2 + r'_1 \quad (1)$$

## (2) ロボット位置の推定

ロボット位置を推定する有力な方法の一つにオドメトリがある。車輪型ロボットでは、車輪の回転数から移動量を求める車輪オドメトリがよく用いられる。第1図で、ロボット位置 $r_2$ は、オドメトリで得た移動量（ロボット座標系での直進と回転）を $a_1 = (\Delta d_1, 0, \Delta \theta_1)^T$ とすると、(2)式のようになる。

$$r_2 = \begin{pmatrix} R_1 & 0 \\ 0 & 1 \end{pmatrix} a_1 + r_1 \quad (2)$$

初期位置 $r_1$ を与えれば、オドメトリによってロボット位置を次々に求めることができる。しかし、オドメトリは積分計算なので、誤差が累積されるという問題があり、走行するにつれてロボット位置はずれていく。

## (3) ロボット位置と点の位置の同時推定

オドメトリの累積誤差に対処するには、地図にすでに登録した点を再度観測して、それを目印にしてロボット

\* 千葉工業大学 未来ロボット技術研究センター

Key Words: SLAM, robotic mapping, localization, navigation, mobile robots.

位置を修正すればよい。たとえば、点  $p_2$  の位置は (1) 式ですでに得られているので、新しい観測データ  $q_3$  からロボット位置  $r_2$  に関する制約が得られる。

$$p_2 = R_2 q_3 + r_2' \quad (3)$$

(1) 式～(3) 式を合わせると冗長な連立方程式ができる。これを最小二乗法で解けば、ロボット位置と地図（各点の位置）が推定でき、累積誤差も削減される。

このように SLAM の本質は連立方程式である。この連立方程式は非線形であり、多くの場合、冗長である。そこで、これを非線形最小二乗問題として解くのが一般的である。また通常は、ロボットが走行してセンサデータを取得しながら、オンラインで地図を作ることが要求される。連立方程式の規模はロボット構成や走行時間に依存するが、ロボット位置は  $10^3 \sim 10^6$  個程度のオーダーになることが多い。

SLAM において重要なことは、同じ点を複数回観測することである。これにより方程式に冗長性をもたせ、オドメトリによる累積誤差を減らすことができる。しかしそれでも、地図が大きくなると誤差は累積する。そこで、周回経路（ループ）を一周して同じ点を観測し、そのデータを連立方程式に加えることで累積誤差を大幅に削減する。これをループ閉じ込み (Loop Closure) といひ、SLAM における重要な技術である。

## 2.2 SLAM の難しさ

SLAM には多くの困難がある。以下に、その要因を記す。これらはセンサデータ処理一般に当てはまることであるが、ロボットでは自律性と実時間性が要求されるので、難しさは増大する（実際には、人間の介入を許す応用も多数あるが、ロボットとしての理想は自律・実時間である）。

### 2.2.1 計算の複雑さ

上記のように、SLAM は非線形連立方程式であり、最小二乗問題として解かれる。連立方程式を作るためには、地図に登録された点（ランドマーク）と観測点を対応づける必要がある。このため、SLAM は最小二乗という連続最適化とデータ対応づけという離散最適化の混合問題となる。連続最適化だけでも、非線形で次元が大きいのので極値に陥りやすく、解くのが難しい。そこに組合せ最適化が加わるので、探索空間は膨大になり、一般には非常に難しい問題となる。

センサが同時に複数の点を観測できる場合、この問題を大幅に軽減できる。その鍵は、ロボット位置とデータ対応づけの依存関係にある。環境が変化しなければ、同時に観測した点群は剛体と仮定でき、ロボット位置が決まれば各点の位置が決まる。このため、ロボット位置によって二つの点群のデータ対応づけの候補を少数に限定でき、効率的に問題を解くことが可能になる。

### 2.2.2 不確実性

実環境から得たセンサデータには、下記のようなさまざまな不確実性が存在する。

- 計測雑音  
センサの偶発的な誤差であり、通常、正規分布で表される。
- アウトライア  
データ対応づけにおける誤りは、正規分布から大きく逸脱した誤差をもたらすため、最小二乗解に破壊的な影響を及ぼす。このようなアウトライアを除去する仕組みは非常に重要である。
- バイアス  
さまざまな要因により、センサデータに偏りが生じる。たとえば、ロボット台車の車輪径の違い、ジャイロのドリフト、センサ間の位置ずれや同期ずれなどがあると、SLAM で得た地図は歪む。
- 情報欠落と退化  
センサデータが十分な制約情報をもたない場合、数学的退化が起き、解が不定になることがある。たとえば、単調な壁しかない長い廊下を 2D レーザスキャナで観測すると、2 本の平行線しか得られず、どこにでも位置合わせができてしまう。


計測雑音は、『確率ロボティクス』に書かれているように、ベイズフィルタや最尤推定でうまく扱うことができる。アウトライアは、別途、注意深い対処が必要である。バイアスについては、本質的には校正が重要であるが、バイアス量推定を組み込むことで、ある程度対処できる。退化は異種のセンサデータを融合することで対処できるが、退化を検出する仕組みをもつことが望ましい。

これらの問題は静的環境でも生じるが、移動物体、照明変化、天候変化、季節変化などの動的要因があると、不確実性はさらに増大する。

## 3. SLAM の手法

『確率ロボティクス』では、EKF-SLAM や FastSLAM などのベイズフィルタに基づく手法と GraphSLAM という最適化に基づく手法が紹介されている [1]。EKF-SLAM は、SLAM の概念が最初に提案された際の手法であるが [2]、スケーラビリティがなく、特別な用途でのみ使われる。FastSLAM は、格子地図を用いて改良され [3]、Gmapping として公開されている。GraphSLAM は大規模な地図構築に適しており、現在では、グラフベース SLAM に一般化され、SLAM の主流となっている。

本章では、グラフベース SLAM を中心とする、現時点で標準的と考えられる SLAM システムの構成と手法を紹介する。その特徴は、SLAM のフロントエンドとバックエンドの役割を分担したシステム構成、および、レーザスキャナや画像などの大量のセンサデータを用いたロバストなデータ対応づけにある。



第2図 SLAMシステムの構成

### 3.1 SLAMシステムの構成

現在のSLAMシステムは、フロントエンドとバックエンドに分けて構成するのが主流である。第2図におおまかな構成を示す。フロントエンドは、逐次SLAMによってセンサ入力をオンラインで処理して、地図を逐次的に生成していく。その際、後述のポーズグラフを生成する。2.で述べたように、逐次SLAMでは誤差が累積するので、バックエンドでループ閉じ込みにより累積誤差を解消する。バックエンドは別スレッドで実行されるので、逐次SLAMの実時間性には影響しない。以下、この枠組みに沿って各手法を説明する。

### 3.2 逐次SLAM

逐次SLAMは連続的に取得したセンサデータを用いて、ロボット位置と地図を推定する技術である。

#### 3.2.1 レーザスキャナによる方法

レーザスキャナで得たスキャンの位置合わせをすることでロボット位置と地図を同時に推定できる。これはスキャンマッチングとよばれる。具体的な手法として、ICP(Iterative Closest Points)[4]やNDT(Normal Distribution Transform)[5]などがある。これらの手法は古くからあるが、『確率ロボティクス』では記述が少ないので、ここで説明する。

ICPは、現在スキャンと参照スキャンの間で、スキャン点の対応づけとロボット位置推定を交互に行う。ロボット位置 $r_t$ が決まれば、スキャン点の位置が決まるので、その位置で最も近いスキャン点同士を対応づける。その対応づけのもとで(4)式を最小化するロボット位置を求める。これを収束するまで繰り返す。

$$G_1(r_t) = \sum_i^N \|R_t^{-1}(p_{i,t-1} - r'_t) - q_{i,t}\|^2 \quad (4)$$

$p_{i,t-1}$ は時刻 $t-1$ までに生成した地図の点、 $q_{i,t}$ は時刻 $t$ のスキャンの点である。これはスキャンと地図でマッチングする場合であり、二つのスキャン間でマッチングする方法もある。一般に、前者の方が精度が高い。

NDTは、参照スキャンを粗い格子地図に投影し、格子セルごとにスキャン点の分布を正規分布で近似して、その格子セルの評価関数とする。ロボット位置に応じて現在スキャンを格子地図に投影し、各スキャン点の投影先の格子セルの評価関数値を求める。そして、その合計が最大となるロボット位置を求める。NDTにはスキャン点の対応づけが不要という利点がある。

### 3.2.2 カメラによる方法

カメラ画像による逐次SLAMでは、3D-2D対応に基づく手法がよく用いられる。それまでに生成した3D点を画像に投影して、その投影点と画像上の特徴点が一致するロボット位置を求める。ステレオカメラや距離画像カメラであれば、1回の観測で3D点が得られるので、3D-2D対応に基づく方法でSLAMができる。単眼カメラの場合は、初期状態で3D点が得られないので、2枚以上の観測画像から後述の方法で3D点を求め、それ以降は3D-2D対応の方法を使う。

3D-2D対応に基づく方法では、観測点が2D特徴点、参照点が3D点であり、(5)式に基づいて、透視変換 $h$ を介した最小二乗法で位置合せができる。

$$G_2(r_t) = \sum_i^N \|h(R_t^{-1}(p_{i,t-1} - r'_t)) - q_{i,t}\|^2 \quad (5)$$

$p_{i,t-1}$ は時刻 $t-1$ までの地図の3D点、 $q_{i,t}$ は時刻 $t$ の画像上の特徴点である。

点の対応がついている場合は、線形解法としてDLT(Direct Linear Transformation)[6,7]、非線形解法としてマーカー法や共役勾配法などがよく用いられる。点の対応がついていない場合は、透視変換を介して画像空間でICPを行う[8]。近年では、MPUの性能向上により、特徴点を用いない直接法が実用レベルになり、注目を浴びている[9]。

単眼カメラでは、1回の観測では3D点が得られない。そこで、SFM(Structure from Motion)により、複数画像の特徴点から3D点を得る。SFMの手法としては、8点法[7]、5点法[10]などがある。前者はカメラ内部パラメータも求められる。後者は、内部校正済みが前提で、外部パラメータのみを求める。用いる特徴点数が少ない方がアウトライアに強くなるので、SLAMでは5点法がよく用いられる。

### 3.3 データ対応づけとループ検出

データ対応づけ(Data Association)は、別々に観測したセンサデータから同じものを見つけることである。多くの場合、地図に登録したランドマークと観測したセンサデータとの対応づけを意味する。

『確率ロボティクス』では、位置による対応づけが主であった。現在では、それに加えて、局所記述子を用いたり、アウトライア除去の仕組みを用いたりする。

#### 3.3.1 逐次SLAMでのデータ対応づけ

逐次SLAMでは、隣接データ間の対応づけなので、ランドマークの探索範囲を限定でき、位置を手がかりにデータ対応づけができる。 $q_t^i$ を時刻 $t$ での $i$ 番目の観測点、 $\hat{q}_t^k$ を $k$ 番目のランドマークを時刻 $t$ のロボット位置で観測したときの値とし、 $\Psi_k$ をその共分散行列とすると、最尤推定として対応 $c(i)$ を求める[1]。

$$c(i) = \operatorname{argmin}_k ((q_t^i - \hat{q}_t^k)^T \Psi_k^{-1} (q_t^i - \hat{q}_t^k)) \quad (6)$$

これは、与えられたロボット位置において、観測点  $q_t^i$  に最も近く見えるランドマーク  $\hat{q}_t^k$  を  $q_t^i$  に対応づけることを意味する。前述の ICP も同じ原理に基づく。

前提が何もないければ、ランドマークと観測点の対応は指数オーダーとなる。しかし、環境形状が変形しないと仮定すれば、ロボット位置が決まると最近傍点は一意に決まる。このように、データ対応づけはロボット位置と強い相関をもつので、ロボット位置を手がかりに対応候補を大幅に絞り込むことができる。

### 3.3.2 ループ検出

ループを一周して同じ場所に戻ったと知ることをループ検出とよぶ。ループを一周するうちに誤差が累積するため、現在位置を中心に累積誤差の大きさに応じた範囲で自己位置推定をする。このため、データ対応づけの探索範囲は逐次 SLAM の場合より広がる。前述の位置に基づくデータ対応づけを用いる場合は、粗密探索や分枝限定法などで探索を高速化する。

局所記述子 (Local Descriptor) を用いて対応候補を求める方法もよく使われる。局所記述子は注目点の近傍情報から作られる特徴ベクトルである。画像は情報量が多いため、SIFT[11] や BRIEF[12] など、多くの局所記述子が提案されている。レーザスキャナでも、3D スキャンでは、スピンイメージ[13] や FPFH[14] などが提案されている。2D スキャンは点が疎なため難しいが、いくつか提案されている[15]。広範囲の地図からランドマークを見つけるには、高速なデータ検索が必要になる。画像の場合には、Bag of features を用いた高速な検索法が提案されている[16]。


対応候補が得られたら、3.2 と同様の方法で、ループの始点・終点 (再訪点) 間のロボットの相対位置を求める。そして、その相対位置を後述のポーズグラフに制約として加え、ループ閉じ込みの処理を行う。

### 3.3.3 アウトライアの対処


逐次 SLAM でもループ検出でも、データ対応づけには曖昧性があり、アウトライアが生じる。これに対処するために、RANSAC[17] や M 推定[6,7] などのロバスト推定法が用いられる。RANSAC は、少数の観測点とランドマークの対応からロボット位置の仮説を計算し、その位置においてほかの観測点は何個のランドマークと一致するか調べる。これを繰り返して、最も一致数の多い仮説をロボット位置として採用する。M 推定は、(4) 式や (5) 式の二乗ノルムを別の評価関数に置き換える。アウトライアがあると二乗ノルムは過剰に大きな値となり、推定に悪影響を与える。そこで、大きな誤差に過剰反応しない評価関数を用いる。

## 3.4 グラフベース SLAM

『確率ロボティクス』には、ロボット位置とランドマーク位置を表す完全 SLAM のグラフからランドマーク位置を捨象してロボット位置だけのグラフを生成する過程が



第 3 図 SLAM のグラフ表現



第 4 図 ポーズ調整によるループ閉じ込み

書かれている[1]。近年は、スキャンや画像などのフレーム単位でマッチングする逐次 SLAM を用いて、ロボット位置だけのグラフを直接生成することが多い。このようなグラフをポーズグラフといい、これを用いてループ閉じ込みが行われる[18–21]。グラフの例を第 3 図に示す。

### 3.4.1 ポーズ調整

ポーズグラフの頂点 (ノード) はロボット位置であり、辺 (アーク) は逐次 SLAM やループ検出で得たロボットの相対位置である。アークは観測値であり制約として使われる。ポーズグラフから、ロボット位置の列 (軌跡)  $r_{0:n}$  の確率密度が (7) 式のように得られる。 $C$  はアーク集合、 $u_{i,j}$  はアーク  $(i,j) \in C$  の観測値、関数  $g(r_i, r_j)$  はロボット位置  $r_i, r_j$  から計算した相対位置である。 $W_{i,j}$  は  $u_{i,j}$  の誤差共分散である。

$$p(r_{0:n}|C) \propto \prod_{(i,j) \in C} \exp(-\|g(r_i, r_j) - u_{i,j}\|_{W_{i,j}}^2) \quad (7)$$

(7) 式を最大化することをポーズ調整 (Pose Adjustment) という。ポーズ調整では、(7) 式のとって非線形最小二乗問題とし、ガウス・ニュートン法を用いて疎な連立一次方程式に変形する。これをコレスキー分解や QR 分解で高速に解く[18–21]。

ポーズ調整でロボット位置が求めれば、それに沿って点群を配置・統合して地図が生成される。

第 4 図に、ポーズ調整によるループ閉じ込みの例を示す。これは、公開データセット MIT-Killian<sup>1</sup> から、筆者のプログラムで構築した地図である。ICP によるスキャンマッチングで逐次 SLAM を行い、2D スキャンの局所記述子[15]でループ検出し、SPA[21]によるポーズ調整でループを閉じている。

<sup>1</sup>[http://www.ijrr.org/contents/23\\_12/abstract/bosse/raw-killian.zip](http://www.ijrr.org/contents/23_12/abstract/bosse/raw-killian.zip)

### 3.4.2 ポーズ調整のロバスト化

ポーズ調整はループ閉じ込みで重要な枠割を果たすが、ループ検出でのデータ対応づけに誤りがあれば、偽のループ制約が発生する。これは、環境によく似た場所が複数あるときによく起こる。ポーズ調整はアウトライアに弱く、少数の偽制約でも失敗することがあり、その場合、地図は大きく歪む。

この対処法として、ループ制約が正しいかどうかのラベル変数  $w_{i,j}$  を付加し、ラベル変数とロボット位置を同時に最適化する方法が提案されている。(7)式の数値をとり、さらに変形して(8)式を得る。第一項は逐次SLAMによる制約  $C_1$ 、第二項はループ検出による制約  $C_2$  について計算する。

$$F(X) = \sum_{(i,i+1) \in C_1} \|g(r_i, r_{i+1}) - u_{i,i+1}\|_{W_{i,i+1}}^2 + \sum_{(i,j) \in C_2} w_{i,j} \|g(r_i, r_j) - u_{i,j}\|_{W_{i,j}}^2 \quad (8)$$

この解法には、両者を直接最適化する手法[22]やEM法を用いて最適化する手法[23]などがある。後者はM推定と等価であることが示されている。

## 4. 自己位置推定

自己位置推定は基本的にはSLAMに含まれるが、通常のSLAMの枠組みに入らないものもある。本章では、いくつかの例を紹介する。

### 4.1 大域自己位置推定

自己位置推定には2種類ある。一つは位置追跡(Pose Tracking)であり、初期位置が与えられて、そこから自己位置推定を開始する。逐次SLAMで行われる自己位置推定は位置追跡である。もう一つは、大域自己位置推定(Global Localization)であり、初期位置を与えずに自己位置推定を行う。ループ検出は大域自己位置推定に近いが、探索範囲が限定されるので、大域自己位置推定ほど難しい。大域自己位置推定は、何らかの理由でロボットが位置を見失った場合の復帰や、複数の地図を結合して一つの地図を作るための結合箇所の検出などに必要となる。

大域自己位置推定は探索範囲をまったく限定しないので、一般には非常に難しい問題である。『確率ロボティクス』でもパーティクルフィルタを用いた大域自己位置推定の例があるが、大規模な環境だと膨大なパーティクルを必要とし、現実的でない。

このため、前述の局所記述子やBag of featuresを用いて、場所の候補を求める方法がよく用いられる。候補を求めた後は、軌跡マッチングなどで候補を絞り込み、3.2と同様の方法で詳細な位置推定を行う。

### 4.2 動的環境への対処

環境変化にロバストなSLAMや自己位置推定は、ロボットの長期自律性のために重要である。これまでの多

くのシステムは静的環境を対象としており、移動物体や準静止物体(可動物体)などの動的要因がある場合はマルコフ性が破れるため、推定に失敗することがある。ここで、マルコフ性とは、現在の状態が一つ前の状態にだけ依存することであり、ベイズフィルタの重要な前提になっている。ベイズフィルタは簡潔な再帰方程式で状態を表現し、効率よく位置推定を行うが、マルコフ性が破れるとこれができなくなる。

環境変化を考慮した研究例はいくつかあるが、本章では、マルコフ性を仮定せずに自己位置推定を行う研究を紹介する[24]。ここでは、観測点を、恒久的に静止している長期特徴(LTF)、一時的に静止している短期特徴(STF)、および、動特徴(DF)に分ける。地図はLTFから構成されているとする。現在位置から見える観測点を地図に投影し、地図上の特徴との距離が閾値より小さい観測点はLTFと判定する。つぎに、非LTF観測点のうち、同じ位置に何度も観測される特徴は、一時的に静止していると見なして、STFと判定する。それ以外の観測点はDFと判定する。そして、LTFと地図の距離、および、対応するSTF同士の距離が最小になるロボット位置の軌跡を非線形最小二乗で求める。これにより、準静止物体や移動物体が大量にある環境でも安定した自己位置推定が可能になる。

### 4.3 悪条件下での自己位置推定

『確率ロボティクス』以後に大きく発展した技術に画像認識がある。画像の局所記述子を用いて場所認識をする研究が数多くなされたが、局所記述子アプローチの問題点は、(とくに屋外での)照明変化、悪天候、季節変化などの悪条件に弱いことであった。これらは従来のロボティクスの観点からは極端な条件に思えるが、人間の活動から見れば日常的な条件である。

このような条件下でもロバストに自己位置推定を行う研究が盛んになっている。SeqSLAMは、昼と夜、晴天と雨天など、画像の見えが大きく異なる環境でも自己位置推定を行う[25]。おもに自動車を対象に道路上での一次元位置を推定し、正規化した画像のマッチングを時系列全体で行うことでロバスト性を高める。

文献[26]の手法では、画像からランドマークとして一意性の高い局所領域をSVM(Support Vector Machine)で抽出して画像地図を作る。走行時の画像から得た局所領域と画像地図のランドマークを照合し、マッチしたランドマーク集合からロボット位置を計算する。さらに、照明、天候、季節が異なるさまざまな条件下でランドマークを蓄積することで、多様な条件下での自己位置推定が可能になる。

## 5. おわりに

本稿では、移動ロボットの環境認識技術として、地図構築と自己位置推定を概説した。これらは実環境で得た

センサデータからの推定問題であり、不確実性の対処が本質的な課題である。『確率ロボティクス』でその基本的な対処法が提案されたが、その後もさまざまな発展を遂げている。本稿で述べた話題のほかにも、密な地図生成 (Dense Mapping)、物体や場所を認識して登録する意味地図生成 (Semantic Mapping)、地図結合 (Map Merging)、人間用の地図での自己位置推定、センサの自動校正など、関連する重要技術は多数ある。

近年、センサやMPUの進歩とあいまって、SLAMは実用段階に入ったといえるだろう。基礎的な課題も依然としてあるが、今後は、実用システムを組み上げる設計指針・ノウハウも重要になると考えられる。

(2016年8月1日受付)

### 参考文献

- [1] S. Thrun, W. Burgard and D. Fox: *Probabilistic Robotics*, MIT Press (2005), (邦訳) 上田訳: 確率ロボティクス, 毎日コミュニケーションズ (2007)
- [2] R. Smith and P. Cheeseman: On the representation and estimation of spatial uncertainty; *Int. J. Robotics Research*, Vol. 5, No. 4, pp. 56–68 (1986)
- [3] G. Grisetti, C. Stachniss and W. Burgard: Improved techniques for grid mapping with rao-blackwellized particle filters; *Trans. on Robotics*, Vol. 23, No. 1, pp. 34–46 (2007)
- [4] P. J. Besl and N. D. McKay: A method of registration of 3-D shapes; *IEEE Trans. on PAMI*, Vol. 14, No. 2, pp. 239–256 (1992)
- [5] P. Biber and W. Strasser: The normal distributions transform: a new approach to laser scan matching; *Proc. of IROS*, pp. 2743–2748 (2003)
- [6] 徐, 辻: 3次元ビジョン, 共立出版 (1998)
- [7] R. Hartley and A. Zisserman: *Multiple View Geometry in Computer Vision*, Cambridge University Press (2004)
- [8] 友納: エッジ点追跡に基づくステレオカメラを用いた三次元SLAM; 日本ロボット学会誌, Vol. 27, No.7, pp. 57–65 (2009)
- [9] J. Engel, T. Schops and D. Cremers: LSD-SLAM: Large-scale direct monocular SLAM; *Proc. of ECCV*, pp. 834–849 (2014)
- [10] D. Nister: An efficient solution to the five-point relative pose problem; *Trans. on PAMI*, Vol. 26, No. 6, pp. 756–770 (2004)
- [11] D. G. Lowe: Distinctive image features from scale-invariant keypoints; *Int. J. Computer Vision*, Vol. 60, No. 2, pp. 91–110 (2004)
- [12] M. Calonder and V. Lepetit, et al.: Brief: binary robust independent elementary features; *Proc. of ECCV*, pp. 778–792 (2010)
- [13] A. E. Johnson and M. Hebert: Using spin images for efficient object recognition in cluttered 3D scenes; *IEEE Trans. on PAMI*, Vol. 21, pp. 433–449 (1999)
- [14] R. B. Rusu, N. Blodow, et al.: Fast point feature histograms (FPFH) for 3D registration; *Proc. of ICRA*, pp. 3212–3217 (2009)
- [15] 友納: ユークリッド変換に不変な特徴量を用いた二次元大域スキャンマッチング方式; 日本ロボット学会誌, Vol. 25, No. 3, pp.66–77 (2007)
- [16] J. Sivic and A. Zisserman: Video Google: A text retrieval approach to object matching in videos; *Proc. of ICCV*, pp. 1470–1477 (2003)
- [17] M. Fischler and R. Bolles: Random sample consensus: A paradigm for model fitting with application to image analysis and automated cartography; *Communications ACM*, Vol. 24, pp. 381–395 (1981)
- [18] E. Olson, J. Leonard, et al.: Fast iterative alignment of pose graphs with poor initial estimates; *Proc. of ICRA*, pp. 2262–2269 (2006)
- [19] G. Grisetti, S. Grzonka, et al.: Efficient estimation of accurate maximum likelihood maps in 3D; *Proc. of IROS*, pp. 3472–3478 (2007)
- [20] E. Takeuchi and T. Tsubouchi: Multi sensor map building based on sparse linear equations solver; *Proc. of IROS*, pp. 2511–2518 (2008)
- [21] K. Konolige and G. Grisetti, et al.: Efficient sparse pose adjustment for 2D Mapping; *Proc. of IROS*, pp. 22–29 (2010)
- [22] N. Sunderhauf and P. Protzel: Towards a robust back-end for pose graph SLAM; *Proc. of ICRA*, pp. 1254–1261 (2012)
- [23] G. H. Lee and F. Fraundorfer, et al.: Robust pose-graph loop-closures with expectation-maximization; *Proc. of IROS*, pp. 556–563 (2013)
- [24] J. Biswas and M. Veloso: Episodic non-Markov localization: Reasoning about short-term and long-term features; *Proc. of ICRA*, pp. 3969–3974 (2014)
- [25] M. Milford and G. Wyeth: SeqSLAM: Visual route-based navigation for sunny summer days and stormy winter nights; *Proc. of ICRA*, pp. 1643–1649 (2012)
- [26] C. Linegar, W. Churchill and P. Newman: Made to measure: Bespoke landmarks for 24-hour, all-weather localisation with a camera; *Proc. of ICRA*, pp. 787–794 (2016)

### 著者略歴

とも のう まさ ひろ  
友 納 正 裕



1985年東京大学大学院修士課程修了。1985～1999年 NEC。2002年筑波大学大学院博士課程修了。2002～2006年科学技術振興機構さきがけ研究者。2006～2008年東洋大学。2008年より千葉工業大学未来ロボット技術研究センター、現在に至る。移動ロボットのナビゲーションの研究に従事。日本ロボット学会、日本機械学会、IEEEなどの会員。