

実機 UAV を用いた強化学習によるホバリングの実現

Realization of hovering using reinforcement learning with an actual UAV

○杉本 卓哉 郷古 学（東北学院大学）

Takuya SUGIMOTO, Tohoku Gakuin University
Manabu GOUKO, Tohoku Gakuin University

In this study, reinforcement learning was applied to actual quadrotor unmanned air vehicles (UAVs) to achieve stable hovering. UAVs have various applications, including rescue operations, sports, and entertainment. However, realizing autonomous control of UAVs remains a challenge. Q-learning is a common reinforcement learning method that is used in this study. To date, most of the studies on learning controllers of UAVs have conducted only computer simulations to verify the effectiveness of learning. In contrast, an actual quadrotor UAV has been utilized in this study. The experimental results demonstrate that the UAV could realize stable hovering over a marker placed on the ground.

Key Words: Unmanned aerial vehicle, AR.Drone2.0, reinforcement learning, Q-learning

1. 諸言

近年、無人航空機（Unmanned aerial vehicle, 以下 UAV と記す）は、スポーツシーンや災害現場の撮影に活用されている。UAV は搭載されたジャイロセンサや加速度センサの情報により安定した飛行が可能である。

しかし、機体の故障などが発生すると、現有の制御器では制御が困難になる。また、このような非常事態を想定した制御器の開発には限界がある。そのため、UAV の墜落に関する事故が起きている。機体のトラブルに対応する方法の一つとして、オンラインでの学習が可能な学習型制御器の導入が考えられる。

近年、強化学習をはじめとするロボットの行動学習に関する研究が盛んに行われている。強化学習を用いることで、ロボット自身が試行錯誤により、目標を達成するための適切な行動（制御方策）を獲得することができ、そのため、機体にトラブルが発生しても、自律的に制御系を獲得することにより、対応することが期待できる。また、制御系設計の負担を減らすことも期待できる。UAV に強化学習を適用した研究事例として、高度の推定、自動操縦、安定した着陸などが行われている[1][2][3]。

しかし、強化学習は行動の獲得に比較的多くの学習時間が必要になるため、UAV に応用した従来研究の多くは実機ではなくシミュレーションによる学習性能の検証のみが行われている。一方で、これまでに、実機の UAV を用いた学習に関する研究も行われている[4]。しかし、同研究では強化学習ではなく、人間による操作を前提とした模倣学習を扱っている。

本研究では、実機の AR.Drone2.0（パロット社製）を用い、強化学習による行動学習実験を行う。実験では、機体に搭載された小型カメラから取得した画像を元に、床に置かれたマーカー上で、安定したホバリングを実現するようにオンライン学習を行った。

2. 実験概要

2-1. AR.Drone2.0

本研究では、比較的安価であり、開発環境が整備されていることを考慮し、小型クアッドローターである AR.Drone2.0（パロット社製）を実験に使用した。



Fig. 1 AR.Drone2.0

AR.Drone2.0 は、コンピュータやスマートフォンでの操作が可能である。機体の前方と中央付近に、それぞれ 1 つずつ小型カメラを搭載している。実験では中央付近の底面カメラを使用する。

2-2. 強化学習

強化学習とは、目標のための望ましい入出力関係を、システムに自動的に獲得させる手法である。本実験では強化学習手法のなかでも比較的単純な Q-learning を使用した。

2-3. Q-learning

Q-learning は、システムが試行錯誤しながら、Q 値と呼ばれる状態 s における行動 a を行う価値を、得られる報酬 r によって更新していく強化学習手法である。学習の結果、システムは得られる報酬を最大化する行動をとるようになる。Q 値の更新は以下の式で行う。

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)] \quad (1)$$

上式において、時刻 t における状態を s_t 、行動を a_t とする、また $Q(s_t, a_t)$ は、状態を s_t において行動 a_t を行う価値 (Q 値) である。時刻 $t+1$ において最も価値の高い行動を a' とする。 α は学習率、 γ は割引率である。

2-4. 実験設定

本実験で用いた学習システムは、AR.Drone2.0 と PC により構成される。AR.Drone2.0 と PC は Wi-Fi により接続



Fig. 2 State of flight




Fig. 3 The bottom camera image

している。学習プログラムの開発には Visual C++を使用した。AR.Drone2.0 のカメラが取得した画像は、PC のモニターにリアルタイムで表示される。ここでは、地面に配置したマーカーの上空で、AR.Drone2.0 が静止（ホバリング）しているときを「安定した制御」と位置付け、「モニター中央にマーカーが静止するための制御則の獲得」を学習の目標とした。

AR.Drone2.0 が、地面から高さ約 1m を飛行中（Fig.2）に撮影した画像を、Fig.3 に示す。青の格子は取得した画像に対して OpenCV により描画したものである。マーカーの直径は 100mm であることから、格子のスケールは縦 100mm、横 214mm となる。実験では、マーカーが存在する格子から状態を定義する。

PC は、画像の情報を元に画像処理と Q-learning を行い、決定したコマンドを AR.Drone2.0 に送信する。この相互のやり取りを繰り返し行い、モニター中央にマーカーが静止するための Q 値の学習を行う。

2-5. 学習手順

学習の流れを Fig.4 に示す。始めに、AR.Drone2.0 が飛行中に撮影した画像を PC に送信する。PC では、受信した画像から「赤の要素が 100 以上、および緑と青より 1.5 倍以上あるピクセル」を目的対象として識別する。本実験では直径 100mm の赤いマーカーを目的対象とした。また、目的対象の中心座標を MG とする。

次に、MG が位置する状態 s_t （マス目）を決定する。状態は Fig.5 のように、 $s_0 \sim s_8$ 、 s_Q がある。 s_Q は青枠の外側全域を指す。決定した状態をもとに行動 a_t を選択し、AR.Drone2.0 に行動（出力コマンド・速度指令）を送信する。選択できる行動の種類は「右」「左」「前方」「後方」「その場に留まる」の 5 つを使用した。行動により、MG




Fig. 4 Flowchart of learning

s_0	s_1	s_2
-0.5	-0.5	-0.5
s_3	s_4	s_5
-0.5	+10	-0.5
s_6	s_7	s_8
-0.5	-0.5	-0.5

$-60 \quad s_Q$

Fig. 5 The arrangement of rewards

が位置する状態が他の状態に遷移した場合、遷移後の新たな状態を s_{t+1} とする。

一方、行動パターン「右」「左」「前方」「後方」から、いずれかを選択し行動を実行しても、MG が位置する状態が遷移しない場合は、新たな状態へと遷移するまで、同じ出力コマンドを AR.Drone2.0 に送信し続ける。

新たな状態 s_{t+1} へ MG が遷移したとき、および、行動パターンから「その場に留まる」を選択したときに、報酬 r_{t+1} を得て Q 値を更新する。報酬は Fig.5 のように、各状態につき +10, -0.5, -60 とした。学習では、「モニター中央にマーカーを維持する」行動の獲得を目指しているため、モニター中央にあたる状態 s_4 に最も大きい報酬を置いた。なお、報酬値の大きさは予備実験により決定した。Q 値の更新 1 回につき、学習回数を 1 回と数える。

学習中に MG が状態 s_Q に遷移した場合は、AR.Drone2.0 に報酬 -60 を与え、Q 値を更新すると共に、状態 s_4 （マーカーの上空）に機体を強制的に戻した。

2-6. 学習実験の条件

AR.Drone2.0 に搭載するバッテリー残量がなくなるまでの飛行を 1 セットとし、計 5 セットの学習実験を行った。学習初期の段階で Q 値はランダムに設定した。行動の選択確率は、学習初期はランダムとし、学習回数 400 までに、徐々に Q 値の大きさをもとに確率的に行動を選択する。また、学習回数 401 以降は、Q 値が最も高い行動を選択するように設定した。学習率 $\alpha=0.9$ 、割引率 $\gamma=0.8$ とし、実験場所は外乱の影響がほとんどない屋内で行った。

3. 実験結果

3-1. 獲得報酬の変化

Fig.6 に学習曲線を示す。このグラフでは、学習回数 100




Fig. 6 Learning curve

Table 1 Comparison of the learning performance

	状態が s_4 だった時間 (%)
学習初期 (学習回数1から1分間)	3.09sec (5.17%)
学習後期 (学習回数401から1分間)	18.69sec (31.15%)

回毎の獲得報酬の総和を示している (5 セット分の平均). エラーバーは標準偏差を示している.

学習回数 400 までの獲得報酬は低い値を示しているが, 学習回数 401 以降は獲得報酬が上昇し, 高い値を保持している. このことから, より大きい報酬を得るための行動を学習できていると考えられる. また, バッテリーがなくなり, 飛行不能になるまでの 1 セット飛行時間は平均 11 分 34 秒となり, 学習回数 400 回までの飛行時間は平均 7 分 11 秒であった.

3-2. 学習の性能評価

学習による性能の評価を行うために, モニター中央にあたる s_4 に, マーカーの重心 MG が滞在した割合を比較した. 比較対象として, 学習初期にあたる学習回数 1 からと, 学習終盤の学習回数 401 から, それぞれ 1 分間計測した. Table 1 は, 学習実験の 5 セット中, 最も成績が良かった 1 セットのデータである. 状態 s_4 に滞在した割合を見ると, 滞在時間が約 15 秒増加していることが分かった. このことから, 制御則の学習による性能の向上を確認できた.

4. まとめと課題

本研究では, AR.Drone2.0に搭載された小型カメラから取得した画像を元に, 制御則を自律的に取得する学習システムの開発を試みた. また, 地面に配置したマーカーの上空で, AR.Drone2.0が静止しているときを「安定した制御」と位置付け, 「モニター中央にマーカーが静止するための制御則の学習」を目標として学習実験を行った.

結果として, 「安定した制御」を可能にする制御則の学習と, それによる性能の向上を確認できた. 今後の課題として, 外乱を想定した学習や, 学習の高速化が挙げられる.

5. 謝辞

本研究の一部は, 科研費基盤研究(C)(15K00363)の助成により行われました. ここに謝意を表します.

6. 参考文献

- [1] Anoop Cherian, Jonathan Andersh, Vassilios Morellas, Berenice Mettler, "Autonomous Altitude Estimation of a UAV using a Single Onboard Camera," *Proceedings of IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 3900-3905, 2009.
- [2] Haitham Bou-Ammar, Holger Voos, Wolfgang Ertel, "Controller Design for quadrotor UAVs using Reinforcement Learning," *Proceedings of 2010 IEEE International Conference on Control Applications part of 2010 IEEE Multi-Conference on Systems and Control*, pp. 2130-2135, 2010.
- [3] Narek Melik-Barkhudarov, Andreas Wendel, Debadeepta Dey, "Vision-Based Landing of a Simulated Unmanned Aerial Vehicle with Fast Reinforcement Learning," *Proceedings of International Conference on Emerging Security Technologies (EST)*, pp. 183-188, 2010.
- [4] Mark N R Smith, Shigang Yue, Tom Duckett, "Learning Monocular Reactive UAV Control in Cluttered Natural Environments," *Proceedings of IEEE International Conference on Robotics and Automation (ICRA)*, pp. 1765-1772, 2013.