

強化学習とモデル予測制御を用いた UAVの自律的バッテリー管理による飛行経路最適化

Autonomous Flight Path Optimization for UAV under Management of Battery System
via Reinforcement learning with Model Predictive Control

堀江直人 *1

Naoto Horie

荒井幸代 *1

Sachiyo Arai

千葉大学院 融合理工学府 都市環境システム

Department of Urban Environment Systems, Graduate School of Science and Engineering, Chiba University

Unmanned aerial vehicles (UAVs) have the potential to significantly reduce labor and risk by providing a means of gathering information during disasters, providing an aerial base station during emergencies, and providing a means of last-mile delivery. However, UAVs with autonomous control consume a lot of battery power, and their applications may be limited due to energy constraints. This paper focuses on the energy constraint problem of UAVs, and aims to obtain autonomous battery management for UAVs. battery depletion of UAVs is difficult to model accurately because it is greatly affected by external factors, making model-based control difficult. In this paper, we propose a control model for UAVs that combines reinforcement learning and model predictive control without requiring a nominal model for optimization.

1. はじめに

無人航空機 (UAV) は、災害時の情報収集や緊急時の空中基地局、ラストマイルの配送手段として期待され、労力やリスクを大幅に削減する可能性を秘めている。しかし、自律制御を行う UAV はバッテリーの消費が激しく、エネルギーの制約からその用途が制限される可能性がある。この問題に対し、強化学習を用いて充電を考慮した経路の生成を行う方法があるが、この方法ではオフラインで生成した経路をそのまま追従するため、再度経路の生成を行うまで飛行経路を変更することができない。また、経路の生成には数千エピソードの学習が必要になるため、オンラインで経路の生成を行う場合、電力を浪費する可能性がある。そこで、本研究では予め充電の必要に応じた目的地の指示を学習させることで、飛行中に逐次目的地の指示を行う、UAV の自律的なバッテリーマネジメントの獲得を目的とする。具体的には、最適化にノミナルモデルを必要としない強化学習を UAV のガイダンスとして用い、制御システムにモデル予測制御を用いた UAV の制御モデルを提案する。

2. 準備

本章では、本稿の理解に必要な強化学習、Actor-Critic の基礎理論について述べた後、提案法を構成する Soft Actor-Critic(SAC) とモデル予測制御の概要を説明する。

2.1 強化学習

強化学習 [Sutton 00] は、未知の環境において最適な制御則を試行錯誤的に獲得する手法である。意思決定主体であるエージェントには、状態入力に対する正しい出力を示す教師信号が存在せず、報酬と呼ばれるスカラーの情報だけが与えられる。エージェントはこの報酬の期待総和を最大化することを目的として、蓄積した経験に基づく学習を行う。

環境モデルを $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R})$ 、エージェントが持つ行動指針を方策 π と定義する。 $\mathcal{S}$ は状態空間、 $\mathcal{A}$ は行動空間、 $\mathcal{P}$ は状態遷移確率、 $\mathcal{R}$ は報酬関数を表し、方策 π は状態 s において行動 a を選択する確率である。エージェントは時刻 t において

状態 $s \in \mathcal{S}$ を観測し、自身の方策 π_t に応じた行動 $a \in \mathcal{A}$ を選択する。その後、時刻 $t+1$ では s, a によって確率的に次状態 s' に遷移し、報酬 $\mathcal{R}(s, a)$ を得る。エージェントは上記のプロセスを繰り返し、報酬に基づいた学習を進めていく。エージェントは獲得した報酬から状態価値 $V(s)$ を推定し、その値を用いて方策 π の評価と改善を行う。方策 π を用いて、状態価値 $V(s)$ 式 (1) で表される。ただし、割引率 $\gamma (0 \leq \gamma \leq 1)$ は、将来期待される報酬の重要度を表すパラメータである。本稿では状態価値を出力する関数を価値関数と呼ぶ。

$$V^\pi(s) = \mathcal{R}(s) + \gamma \sum_{s'} \mathcal{P}_{s\pi(s)}(s') V(s') \quad (1)$$

2.1.1 Actor-Critic

Actor-Critic は、行動選択部 (Actor) と、選択した行動の評価部 (Critic) が独立して存在する強化学習フレームワークの一つである。各行動選択の後、Critic 部で新たな状態 s' を評価、状態価値を推定・更新する。また、推定した状態価値を用いた、状態 s の実際の価値 $\mathcal{R}(s) + \gamma V(s')$ と状態遷移前の状態価値 $V(s)$ の差を用いて行動選択を担う Actor 部の更新を行う。

2.1.2 SAC

Soft Actor-Critic (SAC) [Haarnoja 18] は、Actor-Critic の Critic 部、Actor 部にニューラルネットワークを用いた、深層強化学習手法の一つであり、最大エントロピー強化学習に基づいた手法である。最大エントロピー強化学習とは、報酬の期待総和の最大化を目的とする強化学習と違い、報酬の期待総和に、より無作為な探索を目的とするエントロピー $\mathcal{H}$ の最大化を加えた強化学習手法である。報酬の期待総和の最大化にエントロピー $\mathcal{H}$ の最大化を加える事で、局所的な方策の学習を回避することができる。強化学習の目的関数を式 (2) に、SAC の目的関数を式 (3) に示す。

$$J(\pi) = \sum_t E_{s_t, a_t \sim \pi} [r(s_t, a_t)] \quad (2)$$

$$J(\pi) = \sum_t E_{s_t, a_t \sim \pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot|s_t))] \quad (3)$$

連絡先: 堀江直人, 千葉大学大学院融合理工学府, 千葉市稲毛区弥生町 1-33, 043-290-3316

ここで α は、報酬に対するエントロピー項の相対的な重要性を決める働きがあり、温度パラメータと呼ばれる。

2.2 モデル予測制御

モデル予測制御は、制御対象の数値モデルを用いて制御を行うモデルベース制御の一つであり、制御対象の振る舞いを表す数値モデルを用いる予測モデルと、制御目的を最適化問題で表す最適化器から構成される。モデル予測制御には、制御の目標となる値が目標指令 X_{target} として与えられ、予測区間 N 内での対象の振る舞い X と、目標指令 X_{target} との差が小さくなるような操作量 u を最適化問題を解くことによって出力する。最適化問題に用いる目的関数 J は、一般的に予測区間内での時刻 t における操作量 u_t 、予測した対象の振る舞い X_t 、予測区間長 N を用いて式 (4) のように表される。

$$J = \omega_1 \Phi_N + \omega_2 \sum_{n=0}^{N-1} L(X_t, u_t) \quad (4)$$

目的関数 J における Φ_N 、 $L(X, u)$ は、制御の目標値と出力（制御結果）を評価するコスト関数であり、 $L(X, u)$ はステージコスト（stage cost）、 Φ_N は終端コスト（terminal cost）と呼ばれる。ステージコストは、制御の目的を満たすまでの制御対象の振る舞いを評価し、終端コストは制御対象が制御の目的を満たした後の振る舞いを安定させる働きを持つ。 ω_1 、 ω_2 は、コスト関数においてステージコスト、終端コストの相対的な重要性を決めるパラメータである。

3. 問題設定

3.1 対象問題

無人航空機（UAV）は、配送業務の労力や危険を伴う作業のリスクを大幅に削減する可能性を秘めており、様々な分野で期待されている。しかし、現状広く普及しているリチウムポリマー電池（LiPo）を用いたドローンの飛行時間は 30 分程度であり、安全な自律飛行実現には必要に応じて、バッテリーの中間充電のためにルートを変更するなど、知的な判断が必要である。本研究では、オンボード制御を行う UAV の自律的な飛行意思決定の獲得を目的とし、バッテリーマネジメントの学習・獲得を目標とする。具体的には、UAV のフェイルセーフ機能に焦点を当て、複数の充電場所が存在する飛行環境で、充電が必要であるか否かを自律的に判断し、適切に目的地まで飛行するタスクを対象とする。

3.2 関連研究

強化学習を用いて、バッテリー残量を考慮して自律飛行を目指した既存研究では、道中での充電が必須であることを前提として、飛行経路の計画を行なっている。具体的には、強化学習の学習過程の環境に、充電が必須なことを前提で作成したマップを用いて学習させている [Imanberdiyev 16][Hooshmand 20]。そのため、実際の状態遷移確率が一定ではない環境においては適用が難しく、その場での判断が必要となった場合に安全性を保証できない可能性がある。本研究では、強化学習を用いてバッテリーの減少関数を暗に推定することで、その場の状況に応じた目的地の変更を可能にする、UAV の制御モデルを提案する。

3.3 対象問題のモデル化

本研究では、図 1 に示す $100[\text{m}] \times 100[\text{m}]$ のマップを UAV の飛行する環境として使用する。充電場所をタスクが成り立つ範囲内でランダムに二ヶ所設置することで、状況に応じて適切




図 1: 実験環境

に目的地の変更が可能であるかを評価する。図 1 における青い範囲は充電場所を設置する範囲であり、これは UAV の最大充電時の飛行距離から定めたものである。また、図 1 の飛行環境において、UAV は常に高度を維持しているものとし、UAV の進行方向 ϕ と水平方向の加速度 a_{UAV} を操作して、水平方向にのみ移動するものとする。

UAV の状態遷移モデル

UAV の状態遷移モデルは、式 (5) に示す自身の加速度 a_{UAV} による空気抵抗 a_{wind} を加味し、式 (6)、式 (7)、式 (8) に示す運動方程式に従うものとする。

$$a_{wind} = \frac{1}{2m} \rho A v_{UAV}^2 \quad (5)$$

$$v_{t+\Delta t} = v_t (a_{UAV} - a_{wind}) \Delta t \quad (6)$$

$$x_{t+\Delta t} = x_t + v_t \Delta t \cos \phi + \frac{1}{2} (a_{UAV} - a_{wind}) (\Delta t)^2 \quad (7)$$

$$y_{t+\Delta t} = y_t + v_t \Delta t \sin \phi + \frac{1}{2} (a_{UAV} - a_{wind}) (\Delta t)^2 \quad (8)$$

ここで、式 (5) 中の m 、 A はそれぞれ UAV のバッテリーを含んだ重量 [kg]、空気抵抗を受ける面積 [m^2] を表し、 ρ は空気密度 ($\rho = 1.204$) [kg/m^3] を表す。

UAV は高度を維持し、水平方向にのみ移動する。バッテリーの減少は、UAV の重量 m 、空気抵抗を受ける面積 A 、重力加速度 g 、回転翼の数 n 、単位時間あたりの移動距離 Δl から算出され、式 (9) に従うものとする。

$$P = m^{\frac{3}{2}} \sqrt{\frac{g^3}{2\rho A n}} + m a_{UAV} \Delta l \quad (9)$$

4. 提案法

本研究では、UAV の自律的なバッテリーマネジメントの獲得を目的とし、深層強化学習とモデル予測制御を組み合わせた UAV の制御モデルを提案する。具体的には、強化学習を用いて目的地の指示を行い、環境への行動出力をモデル予測制御を用いて行う。提案する制御モデルの概要を図 2 に示す。強化学習は環境から UAV の位置、バッテリー残量を観測し、モデル予測制御に目的地の指示を行う。モデル予測制御は指示された目的地までの距離を最小化するように、UAV の加速度、向きを決定する。強化学習のエージェントが、充電が必要と判断した場合、直近の充電場所が目的地として指示され、充電が不要

であると判断した場合、目的地として目標地点が指示される。この制御モデルにおいて、強化学習はニューラルネットワークを用いてバッテリーの減少関数を暗に推定することで、適切な目的地の指示を学習する。

5. 計算機実験

5.1 実験設定

実験は、図1に示す100[m] × 100[m]のマップで行い、UAVは開始地点から目標地点を目指す。実験で想定するUAVと実験環境の詳細を表1に示す。学習段階では、開始地点を(0, 0)とし、目標地点を(100, 100)とする。また、充電場所はタスクの成り立つ範囲内でランダムに2ヶ所設置し、バッテリーマネジメントの学習を行う。学習終了後、以下に示す4つの飛行環境にて、UAVの軌跡、各stepにおける目的地の指示を用いてバッテリーマネジメントの評価を行う。

- 環境1: 充電場所が開始位置(0, 0)から最も遠い場合
- 環境2: 充電場所が目標地点(100, 100)から最も遠い場合
- 環境3: 充電場所が双方から最も遠い場合
- 環境4: 目標地点を(70, 70)とし、充電不要である場合

5.1.1 強化学習エージェントの設定

状態入力

エージェントへの状態入力は、現在位置を中心とした目標地点の極座標、直近の充電場所の極座標、UAVのバッテリー残量の5次元とする。状態入力の詳細を表2に示す。

行動出力

行動出力は、目的地変更の1次元とする。具体的には、[0, 1]の値域を出力し、閾値(0.6とする)以上であれば直近の充電場所(B_x, B_y)を指示、閾値未満であれば目標地点(G_x, G_y)を指示するものとする。

報酬

学習過程において、UAVが墜落($s_B = 0$)した場合、エージェントは-1000の報酬を受け取り、目標地点に到達した場合、1000の報酬を獲得するものとする。また、過度な充電を回避するため、充電毎に-3の報酬を与える。エピソードを通してエージェントの選択した目的地に対する評価を与えるため、各step毎に式(10)に示す報酬関数に基づく報酬を与える。式(10)中の第一項は、目標地点までの距離に応じて正の報酬を与える意図を持ち、目標地点の座標(G_x, G_y)と現在位置(s_x, s_y)から算出される。式(10)中の第二項は、不要な電力消費を回避させる意図を持ち、各step毎に消費される電力 ΔB の総和から算出される。式(10)の各stepにおける目標地点までの距離と報酬の関係性を図3を用いて視覚的に示す。

$$r_{step_t} = \frac{1}{10} \left\{ \frac{100}{\sqrt{(G_x - s_x)^2 + (G_y - s_y)^2}} - \left(\frac{1}{200} \cdot \sum_{i=1}^t \Delta B_i \right)^2 \right\} \quad (10)$$

5.1.2 モデル予測制御の設定

モデル予測制御は、現在位置(s_x, s_y)、強化学習により指定された目的地(X_{target}, Y_{target})とこれから算出される目的地の方角 ϕ_{ref} を入力とし、式(11)に示す最適化問題を用いて、進行方向 ϕ とUAVの加速度 a_{UAV} を算出する。また、モデル予測制御の予測モデルには式(6)、式(7)、式(8)に示す運動方程式を用いるものとする。




図2: 提案法の概要

表1: 想定するUAVと実験環境の詳細

項目	変数	値
重量	m	1[kg]
回転翼の数	n	4
空気抵抗を受ける面積	A	$4.4 \times 10^{-2} [\text{m}^2]$
重力加速度	g	$9.8 [\text{m}/\text{sec}^2]$
バッテリー容量	B_{max}	700[J]
最高加速度	$a_{UAV_{max}}$	$3.5 [\text{m}/\text{sec}^2]$
最高速度	$v_{UAV_{max}}$	$7.0 [\text{m}/\text{sec}]$
制御間隔	Δt	0.1[s]

表2: 強化学習エージェントへの状態入力

入力	値域	単位	詳細
L_G	[0, 200]	m	現在位置(s_x, s_y)を中心とする目標地点(G_x, G_y)の極座標
θ_G	$[-\pi, \pi]$	rad	現在位置(s_x, s_y)を中心とする直近の充電場所(B_x, B_y)の極座標
L_B	[0, 200]	m	現在位置(s_x, s_y)を中心とする直近の充電場所(B_x, B_y)の極座標
θ_B	$[-\pi, \pi]$	rad	バッテリー残量の百分率
s_B	[0, 100]	%	




図3: 各時刻における目標地点までの距離と報酬の関係性

$$\begin{aligned}
\min \quad & J = w_1 \Phi_T + w_2 \sum_{t=0}^{T-1} L(x, y, u) \\
\text{s.t.} \quad & L(x, y, u) = |x_{\text{target}} - x_t|^2 + |y_{\text{target}} - y_t|^2 + |\phi_{\text{ref}} - u_{2t}|^2 \\
& \Phi_T = |x_{\text{target}} - x_T|^2 + |y_{\text{target}} - y_T|^2 + |v_T|^2 \\
& \begin{bmatrix} x_{t+1} \\ y_{t+1} \\ v_{t+1} \\ \phi_{t+1} \end{bmatrix} = \begin{bmatrix} 1 & 0 & \Delta t \cos \phi & 0 \\ 0 & 1 & \Delta t \sin \phi & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_t \\ y_t \\ v_t \\ \phi_t \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ 0 & 0 \\ \Delta t & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \\
& u_1 = a_{UAV} \quad (0 \leq a_{UAV} \leq 3.5) \\
& u_2 = \phi \quad (-\pi \leq \phi \leq \pi) \\
& 0 \leq v_t \leq 7.0
\end{aligned} \tag{11}$$

5.2 実験結果・考察

飛行環境 1~4 の実験結果を、図 4~7 に示す。各図において、左図は UAV の軌跡を示し、右図上部は各 step における目的地の指示、右図下部は step 毎のバッテリー残量 [J] を示す。また、実験結果はそれぞれランダムに充電場所を設置した環境で学習済みの方策から得られたものであり、各環境条件に応じた追加学習は行っていない。飛行環境 1 において、図 4 よりエピソード開始から充電場所へ向かう様子が確認できる。エージェントによる指示はエピソード開始から充電まで、充電の判断をしており、充電後は目標地点の指示が確認できる。図 4 右上図より、170step 付近で再度充電の指示が確認できる。これは 5.1.1 項に示す報酬設計より、各 step で負の報酬が与えられるのは 200step 以降のため、正の報酬が獲得できることを学習したためだと考えられる。飛行環境 2 では、図 5 よりエピソード開始直後に目標地点を目指し、約 70step 後に充電場所を指示している様子が確認できる。飛行環境 2 の充電場所は飛行環境 1 と比べて開始位置から近く、最短距離で充電が可能であるにもかかわらず、図 5 右上図と 4 右上図を比較すると、充電時のバッテリー残量がほとんど同じであることが確認できる。これは、各 step で負の報酬が与えられるのは 200step 以降、かつ目標地点に近づくほど大きな報酬を獲得できるため、より報酬の累積値を大きくするように学習したことが原因だと考えられる。飛行環境 3 では、飛行環境 1 と同様の結果が得られた。これは、図 6 右下図より充電時のバッテリー残量が少ないことから、充電場所が開始位置から最も遠く、目標地点と開始位置の直線状にない場合、エピソード開始直後に目標地点を目指すことで得られる余分な報酬を獲得するための十分なバッテリーを確保できないことが理由だと考えられる。飛行環境 4 では、エピソードを通して充電の指示は行われず、直接目標地点へ向かう結果が得られた。飛行環境 4 の条件は学習環境に含んでいないが、エージェントが観測する状態は目標地点、充電場所の極座標、バッテリー残量であるため、学習中に開始条件と同等の状態もしくはそれに近い状態を観測・経験できたのだと考えられる。本実験では、各飛行環境にて、ゴールへ到達できず充電場所に留まる、または墜落する実験結果は得られず、全ての試行で目標地点へ到達することができた。

6. 結論

本研究では、深層強化学習とモデル予測制御を組み合わせた制御モデルを提案することで、逐次充電の判断を行うバッテリーマネジメンの獲得を試みた。実験により、強化学習でバッテリーの減少関数を暗に推定し、それを用いることで充電場所の変化に影響されずバッテリーのマネジメントが可能であることを確認した。今後の課題として、飛行環境の変化に対して適応的なバッテリーマネジメンの獲得を挙げる。本研究で取り上げた深層強化学習に用いられるニューラルネットワークは、人為的な設計が困難な関数を近似することができ、強化学習はモデルフリーで最適化を行うことができるため、モデルベース制御では困難な制御対象に適用することができる。しかし、ニューラルネットワークは学習に多大な計算を必要とし、強化学習は学習初期の不安定さから実機を損傷させる恐れがある。そのため、実際の環境で一から学習させることは困難であり、予め計算機等で方策を学習する必要がある。本実験で用いたバッテリー減少関数は、UAV の重量に比例し、実験結果から確認できるように、バッテリー残量は線形に減少しているが、実際の飛行環境では温度や劣化などにより徐々に減少関数に変化する可能性がある。今後は、このように強化学習の適用対象が徐々に変化するタスクに対して、学習済みの方策を変化に合わせて更新するアルゴリズムの検討を行う。




図 4: 飛行環境 1 における UAV の軌跡 (左)
各 step におけるバッテリー残量と充電の判断 (右)




図 5: 飛行環境 2 における UAV の軌跡 (左)
各 step におけるバッテリー残量と充電の判断 (右)




図 6: 飛行環境 3 における UAV の軌跡 (左)
各 step におけるバッテリー残量と充電の判断 (右)




図 7: 飛行環境 4 における UAV の軌跡 (左)
各 step におけるバッテリー残量と充電の判断 (右)

参考文献

- [Sutton 00] Richard S. Sutton, Andrew G. Barto: Reinforcement Learning: An Introduction, 三上貞芳, 皆川雅章訳: "強化学習", 森北出版, pp.142-170, (2000)
- [Haarnoja 18] aarnoja, Tuomas, et al. "Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor." International conference on machine learning. PMLR, 2018.
- [Imanberdiyev 16] manberdiyev, Nursultan, et al. "Autonomous navigation of UAV by using real-time model-based reinforcement learning." 2016 14th international conference on control, automation, robotics and vision (ICARCV). IEEE, 2016.
- [Hooshmand 20] ooshmand, Arash. "Reinforcement Learning-based Joint Path and Energy Optimization of Cellular-Connected Unmanned Aerial Vehicles." arXiv preprint arXiv:2011.13744 (2020).