

ドローン配送計画最適化問題のための最短経路情報を利用したマルチエージェント強化学習

Multi-agent Reinforcement Learning using Shortest Path Information for Drone Routing Problem

青山 秀紀^{*1}
Hideki AOYAMA

丁 世堯^{*2}
Shiyao DING

林 冬恵^{*2}
Donghui LIN

^{*1}パナソニック
Panasonic Coporation

^{*2}京都大学
Kyoto University

Safe and efficient drone delivery services require navigational controls and flight space restrictions to avoid collisions and reduce damage from unexpected falls. This paper formulates this optimization problem and proposes it as Drone Routing Problem (DRP). And we propose a multi-agent reinforcement learning method using analytically calculated shortest path information, and show its effectiveness through experiments.

1. はじめに

近年、ドローンの物流分野への応用が盛んに検討されており、EC の増加に伴って増え続ける配送需要に応えるソリューションとして期待されている。特に、配送拠点から最終顧客への配送となるラストワンマイルと呼ばれる部分は、大量輸送による効率化を図りにくく、また、受取人不在による再配達等の問題も重なりコスト効率が悪いため、ドローンや Unmanned Ground Vehicle (UGV) による省コスト化、省人化の効果が大きいと目されている。このように多数のドローンが街中を飛行する状況を想定した場合、衝突事故を回避するためには、各々が自由に飛行するのではなく、有人航空機と同様に飛行計画や航空管制を考える必要がある。また、墜落のリスクを考えると安全に飛行できる領域は限定される。河川、用水路、植栽、アーケード、防護ネット上等、特に都市部では飛行可能領域は限定され、この限られた空路を衝突することなく、できるだけ効率的に移動することを考える必要がある。本稿では、この問題を Drone Routing Problem (DRP) と定義する。

効率的な物流を扱う問題として、Vehicle Routing Problem (VRP) がある。これは、制約として与えられた各移動体の積載量制約を満たした上ですべての配送先を最も低いコストで巡回することを目的としており、Bin Packing Problem に代表される割り当て決定問題と Traveling Salesman Problem に代表される順路決定問題を内包する組み合わせ最適化問題である。ただし、VRP では、拠点（配送拠点と配送先）間の移動は単純に移動時間や金額のコストとして表現され、衝突回避のための拠点間移動の細かな経路選択は通常は扱われない。一方で、DRP では衝突回避が主たる目的の一つであり、また、積載量が少ないことから多くの用途では積載貨物は 1 と限定しても差し支えない。VRP の考え方は衝突回避問題を解決した上で高次の問題として応用できる可能性はあるものの、本稿では衝突回避を主とした Multi-agent Path Finding (MAPF) 問題として DRP を検討する。

MAPF は複数のエージェントをコントロールして全体のコストを最小化、あるいは、報酬を最大化する問題である。これも VRP と同様に NP 困難な問題として知られており [Yu 13]、様々な手法が提案されている。多数のエージェントや広いマップ、様々な制約条件に対応した種々の手法が提案されているが、

多くの手法では 4 連結のグリッドマップと離散時間が仮定されている [Sharon 15][Sartoretti 19]。すなわち、エージェントの行動は上下左右への移動に停止を加えた 5 種類で、時間は離散化されており、各エージェントは 1 タイムステップで次のグリッドへ移動し、同時に次の行動を行う。しかし、DRP で扱いたい実際の市街地を基礎としたマップでは、経路はあらゆる角度で連結し、経路長、すなわち、移動時間は連続量であり、各エージェントが一つの行動を完了して次の行動を決定・開始する時刻も同時ではない。そこで、本稿では、まず、ロボットや UGV をエージェントとした場合とは異なっている DRP の制約条件を整理し、この問題をマルチエージェント強化学習の枠組みを利用して解く手法について解説する。

2. Drone Routing Problem

DRP では、ドローンの移動可能な領域を図 2 のような無向グラフ $G = (V, E)$ で表現する。ノード V_a, V_b を連結するエッジ E_{ab} の値はノード間の距離を表し、連続値を取る。ドローンは同じノードに他のドローンと同時に居ることはできず、同じエッジを同時に通行できないものとする。同じエッジを逆行できないだけでなく、同じ方向にも同時に移動できないとするのは、鉄道の衝突回避にも用いられている閉塞方式を採用するためである。ドローンは非常に高速で、かつ、1 つのエッジは数 10m 程度と短く数秒で移動するため、安全区間として同一エッジへの侵入を禁止する。ある区間の利用可能領域が広く複数のドローンが安全に移動できる場合には、同一ノード間に複数のエッジを引くことで表現する。

ドローンの台数を N とし、時刻 t における各ドローン i の所在地を $l_i^c[t]$ 、目的地（配送先や集荷地点）を $l_i^d[t]$ とする。ドローンは目的地に到着後、次の目的地が与えられる。予約配送等で次の目的地が予めわかっている状況も考えられるが、ここではオンデマンドで次々に入る注文に対応するためにその場で新しい指示が与えられることを想定している。発展的な問題として、「複数の注文のどれに対応するか選択する」という問題も考えられる。一般的には移動速度や積載量が異なる機種が存在することも考えられるが、本稿の実験では単純化のため 1 機種の場合で評価を行っている。

各エージェント、あるいは、管制塔は、マップ情報 G と全てのエージェントの現在地 $L_c[t]$ と目的地 $L_d[t]$ の情報を利用可能（完全情報）である。DRP の目的は、全てのドローンの移動コストの総和 (Sum of Cost (SoC)) を最小化すること（完

連絡先: 青山秀紀, パナソニック, 〒571-8508 大阪府 門真市 大字門真 1006, aoyama.hideki@jp.panasonic.com

Algorithm 1 Simple DP

```

1: ワーシャル・フロイト法を用いて任意の 2 点  $V_a, V_b$  間の
   最短距離  $D_{ab}$  を求める
2:  $V_a$  から  $V_x$  を経由して  $V_b$  移動する距離を求める
    $D_{ab}(V_x) \leftarrow E_{ax} + D_{xb} \quad (\exists x | E_{ax} \in E)$ 
3:  $D_{ab}(V_x)$  が小さい順に  $V_x$  をソートする
    $Y_{ab} \leftarrow \text{array } V_x \text{ sorted by } D_{ab}(x)$ 
4: while  $l_c[t] \neq l_d[t]$  do
5:   for  $y \in Y_{l_c[t]l_d[t]}$  do
6:     if  $E_{l_c[t]y}$  と  $y$  に他のドローンが存在しなければ then
7:        $y$  へ移動する
8:       goto 4:
9:     end if
10:  end for
11:  現在地に一定時間留まる
12: end while


```

全協力ゲーム) である。移動コストは本稿の実験では所要時間と等しいとしているが、燃料消費量やそれらを加重平均したもの等も考えられる。また、SoC ではなく、最長待ち時間の最小化等を目的関数とするとしてもよい。

3. 関連研究

2 点間の最短経路を求める手法としてはダイクストラ法や A* アルゴリズム等が知られており、エージェントが 1 台で衝突が発生しない場合であればこれらの手法を用いて簡単に最短経路を求めることができる。エージェントが複数の場合、各エージェントの取りうる行動の組み合わせを行動空間として再定義して単一のエージェントとして扱うことで、単一エージェントの場合に有効な各種手法を用いることができるが、再定義した行動空間はエージェント数のべき乗で増加するため、通常は現実的な時間では解は得られない。衝突が発生しない状況では各エージェントの行動を個別に計算することで組み合わせ爆発を避ける手法として Conflict Based Search (CBS)[Sharon 15] や M*[Wagner 11] が提案されており、CBS を連続時間・非グリッド構造に拡張した Continuous-time CBS (CCBS)[Andreychuk 19][Andreychuk 21] は DRP にもそのまま適用することができる。しかし、4.2 節の実験と同条件で実験した場合に解が得られた割合は 82.5% であり、CCBS でもエージェントがある程度以上密集してしまう状況では実時間では計算を完了することができなかった。一方で、実運用においては、最適でなくともある程度効率的な解を現実的な時間で導出することが求められる。


前段で挙げた始点から目的地までの経路を予め計算する手法に対し、Algorithm 1 のようにその時点での状況を入力として次の行動を順次選択していく手法も考えられる。Dynamic Programming (DP) に分類されるこれらの手法は最適解の保証はできないものの、実行時の計算コストは比較的小さく実時間での利用に適している。DRP では目的地に到達すれば完了というわけではなくさらに次の目的地に移動すること、また、次の目的地は動的に与えられるという点も、DP との相性が良いと考えられる。この分野において、近年では深層学習を利用した Multi-agent Reinforcement Learning (MARL) を用いた手法が数多く提案されている [Sartoretto 19][Rashid 18]。しかし、一般に深層学習を利用した MARL では学習に大きな



	ld までの距離	入力ベクトル
a_0	-	$-T_{wait}/C$
a_1	$14.2 + 23.7 = 37.9$	$-7.9/C$
a_2	$13.3 + 16.7 = 30.0$	$0/C$
a_3	$21.4 + 12.1 = 33.5$	$-3.5/C$

C: クリッピング定数

(a) 直近経路上に他のエージェントが存在しない場合



	ld までの距離	入力ベクトル
a_0	-	$-T_{wait}/C$
a_1	$14.2 + 23.7 = 37.9$	$-7.9/C$
a_2	$13.3 + 16.7 = 30.0$	$0/C$
a_3	$21.4 + 12.1 = 33.5$	-1

C: クリッピング定数

(b) 直近経路上に他のエージェントが存在する場合

図 1: 最短経路情報ベクトル

計算コストを必要とし、DRP で要求される連続時間・非グリッド問題では、必要な計算量はさらに大きくなる。そこで、我々は、グラフ構造を事前知識として入力することと、学習対象外エージェントの行動決定に Simple DP のように簡単にルール化することができる経路選択手法を利用することで、効率的に学習を行う手法について検討した。

4. Multi-agent Reinforcement Learning

4.1 設計

行動空間 「 a_0 : 現在のノードに一定時間 (T_{wait}) 留まる、 a_i : 現在のノードからエッジで連結されているノードのうち i 番目に小さい番号のノードに移動する」とする。すなわち、行動の種類は「最大の連結数を持つノードの連結数+1」となる。連結ノード数が少ないノードでそれ以上の番号の行動が選択された場合は誤った行動として学習エピソードを終了させる。

最短経路情報の事前計算 グラフ状の任意の 2 点間の最短経路を求める問題の計算量は適切なアルゴリズムを利用した場合でも $O(V^3)$ であり、強化学習では当然それ以下の効率となり、マップが大きくなるにつれて学習に非常に大きな計算量が必要になる。一方で、ワーシャル・フロイト法を用いることで、こ




図 2: 評価用マップ

の計算は短時間で行うことができる。また、この計算はマップが変わらない限り不変であるため、一度計算するだけで良い。そこで、単純にマップのグラフ構造を深層学習への入力として与えるのではなく、図 1(a) の形でこの最短経路情報を与えることで、学習の効率化を狙う。また、図 1(b) のように、他のエージェントがいるエッジに侵入する行動は-1 とすることで、明らかに誤った行動であるという情報を与える。これらの情報は Simple DP の扱う情報と本質的に同一であり、この入力の最大値を常に選択することは Simple DP と同一の行動選択となる。

報酬 典型的な報酬設定として「目的地ノードへの移動は 0、それ以外の行動は-1」とする設定があるが、これは出発地点までの Q 値の伝搬に時間がかかるという点で効率が悪くない。また、DRP では行動にかかる時間は一定ではないため、所要時間を評価に参入するために「目的地ノード以外への移動は所要時間 $\times -1$ 」とすると、「短いエッジを移動する行動のほうが長いエッジを移動する行動より良い」と評価されてしまい、うまく学習することができない。そこで、図 1(a) の入力ベクトルの選択した行動の値を報酬と設定する。これは「目的地に最も近づく行動 a_s を 0、それ以外の行動は a_s より遠回りになる距離 (時間) $\times -1$ 」となっており、累積報酬は「目的地までの最短距離と比べて遠回りした距離 (時間) の累計 $\times -1$ 」となるため、これを最大化することで最短距離 (最短時間) で目的地に到達する行動選択を学習させることができ、同時に、毎回の行動で報酬を得ることで学習速度を向上させることができる。

ルールベースポリシーの利用 強化学習ではエージェントは様々な行動を試すことで、おかれた状況における各行動の良さを学習していく。しかし、MARL では、エージェント A が良い行動をした場合でも、エージェント B が悪い行動 (エージェント A に衝突していく行動等) を行った場合には結果として低い報酬が与えられてしまい、行動を正しく評価することができないという状況が発生する。これは、良くない行動を選択しがちな学習初期に顕著で、学習の非効率化の原因となる。そこで、学習対象とする 1 台のエージェント以外は Simple DP によって行動選択を行わせることで、「他のエージェントが『それなりに良い』行動を行う場合に取るべき行動」を効率的に学習させることを狙う。最終的には、「他のエージェントも同一のポリシーで行動選択をした場合に取るべき行動」を学習する必要があるため、ある程度学習が進んだ時点で他のエージェントも学習中のポリシーで行動選択するように設定を変更する。




図 3: 目的地到達率




図 4: 総所要時間

4.2 評価

前節で提案したアルゴリズムの有効性の確認のため、下記の実験を行った。

使用したマップを図 2 に示す。これは実在する街路を象ったものである。エッジの値は、エージェントが移動にかかる時間を示す。

学習時のドローンの台数は 2 から 4 のランダム (均等分布) とし、所要時間、目的地到着率はその平均値を示している。学習ステップ毎の目的地到達率とそのときの総所要時間をそれぞれ図 3、図 4 に示す。目的地到達率は、1000 単位時間以内に全てのエージェントが衝突することなく最初の目的地に移動することができた割合である。総所要時間は、全てのドローンが最初の目的地に移動するためにかった時間の総和の平均値である。なお、衝突や時間切れが発生した場合は平均値の計算に参入しない。評価時には、他のエージェントは学習したポリシーで行動選択させた。

図 3 より、最短経路情報を利用することで、目的地に到達可能な行動選択を効率的に学習できたことがわかる。また、図 4 より、他のエージェントを Simple DR で動作させることにより、短い経路選択を効率的に学習できたことがわかる。これは、他のエージェントが学習中のポリシーで行動選択をしている場合には衝突されないように遠回りの経路を選択するように学習しがちであったことが理由としてあげられる。なお、(b)(c) の総所要時間は変わらないように見えるが、(b) では目的地に到達できなかった条件、すなわち、衝突や時間切れが生じやすい難しい条件での所要時間が平均に参入されていないため、両方の手法を取り入れた (c) がより効率的な経路選択ができていたと言える。また、最短経路情報、他エージェントの

ルールベースポリシーの両方を使わない場合はこの条件ではうまく学習できず、エージェント数を徐々に増やしていくといった工夫が必要であったが、これらの提案手法を利用することで、最初から複数のエージェントで学習させることができた。

5. まとめ

本稿では、ドローン配送を安全かつ効率的に行うために必要となる運行計画最適化問題の諸条件を整理し、Drone Routing Problem (DRP) として定式化した。また、解析的に計算した最短経路情報を利用することで、マルチエージェント強化学習を効率的に行うことができることを示した。

今後は、ドローンの加速度を考慮した問題への応用や、どの配送注文をどのドローンが行うべきかの選択問題の解法を検討し、実応用へ繋げていく予定である。

参考文献

- [Andreychuk 19] Andreychuk, A., Yakovlev, K., Atzmon, D., and Stern, R.: Multi-Agent Pathfinding with Continuous Time, in *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence, IJCAI-19*, pp. 39–45, International Joint Conferences on Artificial Intelligence Organization (2019)
- [Andreychuk 21] Andreychuk, A., Yakovlev, K., Boyarski, E., and Stern, R.: Improving Continuous-time Conflict Based Search, *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 35, No. 13, pp. 11220–11227 (2021)
- [Rashid 18] Rashid, T., Samvelyan, M., Schroeder, C., Farquhar, G., Foerster, J., and Whiteson, S.: QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning, in Dy, J. and Krause, A. eds., *Proceedings of the 35th International Conference on Machine Learning*, Vol. 80 of *Proceedings of Machine Learning Research*, pp. 4295–4304, PMLR (2018)
- [Sartoretti 19] Sartoretti, G., Kerr, J., Shi, Y., Wagner, G., Kumar, T. K. S., Koenig, S., and Choset, H.: PRIMAL: Pathfinding via Reinforcement and Imitation Multi-Agent Learning, *IEEE Robotics and Automation Letters*, Vol. 4, No. 3, pp. 2378–2385 (2019)
- [Sharon 15] Sharon, G., Stern, R., Felner, A., and Sturtevant, N. R.: Conflict-based search for optimal multi-agent pathfinding, *Artificial Intelligence*, Vol. 219, pp. 40–66 (2015)
- [Wagner 11] Wagner, G. and Choset, H.: M*: A complete multirobot path planning algorithm with performance bounds, in *2011 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pp. 3260–3267, San Francisco, USA (2011)
- [Yu 13] Yu, J. and LaValle, S. M.: Structure and Intractability of Optimal Multi-Robot Path Planning on Graphs, in *Proceedings of the Twenty-Seventh AAAI Conference on Artificial Intelligence, AAAI’13*, p. 1443–1449, AAAI Press (2013)