

ポテンシャル法と深層強化学習を用いた
クアドロータの自律的障害物回避

白石 大介*・市原 裕之*

Obstacle Avoidance of a Quadrotor Based on Potential Field Method
with Deep Reinforcement Learning

Daisuke SHIRAISHI* and Hiroyuki ICHIHARA*

In motion planning of robots such as quadrotors, potential field methods are useful so that robots avoid obstacles. The artificial potential field method, which is one of the potential field ones, enables us to plan actions. However, the quadrotors sometimes fail to avoid the obstacles because the artificial potential field method does not take into consideration the inertia effect arising from the velocity of the quadrotors. To overcome the inertia effect, we give an idea of applying deep reinforcement learning to the artificial potential field method to determine an additional reference signal to the quadrotor. Thanks to this reference signal, the quadrotor improves the performance in trial and error to avoid the obstacles. Then the robot achieves an optimal action from the velocity of the robot and the position of the obstacles.

Key Words: quadrotor, potential field method, reinforcement learning, motion planning

1. はじめに

移動ロボットが障害物を回避する方法にポテンシャル法がある。ポテンシャル法は障害物に高いポテンシャル場、目的地に低いポテンシャル場を与え、その勾配から移動ロボットを導く手法である。移動ロボットはポテンシャル場の低い方向に移動することで障害物を避けつつ目的地に向かうことができる。ポテンシャル法の最も古典的な手法である人工ポテンシャル法¹⁾は、移動ロボットと目的地および障害物の位置からポテンシャル場を構成する。

クアドロータに対しては、経路計画やフォーメーション制御などにポテンシャル法を応用する研究がある^{2)~4)}。クアドロータのような高速で移動するロボットの場合、ポテンシャル場を構成するだけでは十分ではない。クアドロータの慣性により静止している障害物に近づきすぎることや、動いている障害物を回避できないことがある。このような背景から、障害物および目的地との相対速度を考慮する手法も研究されている⁵⁾。しかし、各障害物を認識し、それぞれの速度を算出する必要がある。

強化学習は、入出力特性が未知または複雑であるような非

線形確率システムに対する制御器を推定近似するための有用な手法の1つである。強化学習では、学習主体が環境に対する試行錯誤とその評価値である報酬からよりよい行動を選択する⁶⁾。とくに、Deep Q-Network (DQN)⁷⁾では行動価値関数、Actor-Critic型の学習法⁸⁾では方策関数と状態価値関数をそれぞれニューラルネットワークで近似する。これらは深層強化学習と呼ばれる。

ニューラルネットワークを用いることで、強化学習では対応が難しかった連続値の状態、行動を取り扱うことができる。近年、深層強化学習に関する多様な手法が提案されている。その多くは得られた制御系の安定性や最適性に関する議論が乏しい。しかしながら、多数の未知パラメータを有する制御系設計問題を近似的に解く能力の高さに対して、制御分野からの期待も高まっている⁹⁾。これまでにビークルやクアドロータに応用した研究もあり、深層強化学習を用いた自律移動の高知能化も期待されている^{10), 11)}。

方策関数の最適化を重視する深層強化学習の手法の1つとしてProximal Policy Optimization (PPO)¹²⁾が知られている。PPOでは、学習環境における状態をニューラルネットワークの入力層のノードとし、方策と状態価値関数を出力層のノードとするActor-Critic型のニューラルネットワークを用いる。行動を決定する方策がActorであり、それを評価する状態価値関数がCriticとなる。ニューラルネットワークの接続重みとバイアスを合わせてパラメータと呼び、パラメータを調整することにより多層のニューラルネットワークは任

* 明治大学理工学部 川崎市多摩区東三田 1-1-1

* School of Science and Technology, Meiji University, 1-1-1 Higashi-mita, Tama-ku, Kawasaki

(Received June 8, 2019)

(Revised December 5, 2019)

意の可微分で連続な関数を近似することができる¹³⁾。方策を学習する際に行動による正味の価値を評価するためにアドバンテージ関数を導入し、これに更新前後の方策比を乗じた関数をクリッピングした値の期待値を目的関数とする。これを最大にする方向に方策勾配法¹⁴⁾を用いて Actor に関するパラメータを更新する。アドバンテージ関数を評価する Actor-Critic 型ニューラルネットワークによる強化学習手法は、一般に Advantage Actor-Critic (A2C) と呼ばれる。一方で、Trust Region Policy Optimization (TRPO)¹⁵⁾では、更新によるパラメータが急激に変化するのを防ぐために、更新前後の方策に関するカルバックライブラー距離に対する制約条件のもとで、アドバンテージ関数と更新前後の方策比を乗じた関数の期待値を最大化するように Actor に関するパラメータを更新する。しかし、制約条件付き最大化問題を解く必要があるため実装が難しいことで知られている。これに対して PPO は、パラメータの過剰変化を抑制するために制約条件を課すのではなくクリッピングを含む目的関数に基づいて学習しているため、同程度の学習効果を与える手法の中では高速に実行できる。

本論文ではクアッドロータの障害物回避において、人工ポテンシャル法を用いた参照信号による軌道計算を繰り返し行ない、軌道データから慣性による影響を減らすための追加の参照信号を生成するニューラルネットワークを設計する。設計したニューラルネットワークのパラメータを PPO によって推定することで追加の参照信号を生成する。この信号をポテンシャル法を用いた参照信号に加えて適用することで所望の経路への追従精度を高める。

以下、2 章ではクアッドロータについて述べ、3 章では人工ポテンシャル法の概要と問題点を指摘するとともに本論文の問題設定を述べる。4 章で深層強化学習について説明し、5 章では人工ポテンシャル法の問題点を解決するための深層強化学習におけるニューラルネットワークの設計について述べる。6 章で数値実験について述べる。最後に 7 章で本論文をまとめる。

2. クアッドロータ

全体座標系 $\Sigma_{World}(X, Y, Z)$ 上のクアッドロータのモデルを **Fig. 1** に示す。 $\Sigma_{Quad}(x, y, z)$ はクアッドロータの局所座標系を表わす。 Σ_{World} 上のクアッドロータの位置は $(x, y, z) \in \Sigma_{Quad}$ である。 $(\theta, \phi, \psi) \in \mathbb{R} \times \mathbb{R} \times \mathbb{R}$ は姿勢角で、それぞれヨー、ピッチ、ロール角を表わす。 ω_i ($i = 1, \dots, 4$), T_i ($i = 1, \dots, 4$) はそれぞれ各ロータの回転角速度、推力を表わす。合計推力 T および各軸まわりのトルク τ_x, τ_y, τ_z は次式で与えられる。

$$\begin{bmatrix} T \\ \tau_x \\ \tau_y \\ \tau_z \end{bmatrix} = \begin{bmatrix} b & b & b & b \\ 0 & -db & 0 & db \\ -db & 0 & db & 0 \\ -k_q & k_q & -k_q & k_q \end{bmatrix} \begin{bmatrix} \omega_1^2 \\ \omega_2^2 \\ \omega_3^2 \\ \omega_4^2 \end{bmatrix}$$




Fig. 1 Quadrotor model

ただし、 b はロータ定数であり、空気密度、ロータ翼半径、ロータ翼数などに依存する値である。 k_q は空力抵抗係数であり、 b と同じ要因に依存する定数である。 d はクアッドロータの中心からロータの中心までの距離である。制御入力を

$$\mathbf{u}(t) = \begin{bmatrix} U_1 \\ U_2 \\ U_3 \\ U_4 \end{bmatrix} = \begin{bmatrix} T \\ \tau_x \\ \tau_y \\ \tau_z \end{bmatrix}$$

とすると、クアッドロータの非線形モデルは次式で表わされる。

$$\begin{cases} \ddot{x} = \frac{1}{M}(\cos \psi \sin \theta \cos \phi + \sin \psi \sin \phi)U_1 \\ \ddot{y} = \frac{1}{M}(\sin \psi \sin \theta \cos \phi - \cos \psi \sin \phi)U_1 \\ \ddot{z} = \frac{1}{M}(\cos \theta \cos \phi)U_1 - g \\ \ddot{\phi} = \frac{J_y - J_z}{J_x}\dot{\theta}\dot{\psi} + \frac{U_2}{J_x} - \frac{J_r}{J_x}\Omega\dot{\theta} \\ \ddot{\theta} = \frac{J_z - J_x}{J_y}\dot{\psi}\dot{\phi} + \frac{U_3}{J_y} + \frac{J_r}{J_y}\Omega\dot{\phi} \\ \ddot{\psi} = \frac{J_x - J_y}{J_z}\dot{\phi}\dot{\theta} + \frac{U_4}{J_z} \end{cases} \quad (1)$$

ただし、 M はクアッドロータの総質量、 g は重力加速度、 (J_x, J_y, J_z) は各軸まわりの慣性モーメント、 J_r はロータの慣性モーメントであり、 $\Omega = -\omega_1 + \omega_2 - \omega_3 + \omega_4$ である。ここで、 $\boldsymbol{\xi} = [x \ y \ z]^T$, $\mathbf{v} = \dot{\boldsymbol{\xi}}$, $\boldsymbol{\eta} = [\phi \ \theta \ \psi]^T$, $\boldsymbol{\omega} = \dot{\boldsymbol{\eta}}$ に対して $\mathbf{q} = [\boldsymbol{\xi}^T \ \mathbf{v}^T \ \boldsymbol{\eta}^T \ \boldsymbol{\omega}^T]^T$ は状態変数である。このとき、(1) 式を適当な時間間隔で離散化したモデルを

$$\mathbf{q}(k+1) = f(\mathbf{q}(k), \mathbf{u}(k)) \quad (2)$$

とする。ただし、 $f: \mathbb{R}^{12} \times \mathbb{R}^4 \rightarrow \mathbb{R}^{12}$ は適当な関数とする。また、離散化された状態変数 $\mathbf{q}$ に対する参照信号を $\mathbf{q}_{ref}^*$ 、状態フィードバックゲインを $F \in \mathbb{R}^{4 \times 12}$ とするとき、制御則を次式で与える。

$$\mathbf{u}(k) = F(\mathbf{q}_{ref}^*(k) - \mathbf{q}(k)) \quad (3)$$

3. 人工ポテンシャル法と問題設定

3.1 ポテンシャル関数とその勾配

ポテンシャル法を適用する空間に対して、全体座標系を $\Sigma_{\text{World}} \subset \mathbb{R}^n$ とする. Σ_{World} における時刻 $k \in \{0, 1, \dots\}$ の移動主体位置を $\xi(k) \in \Sigma_{\text{World}}$, 目標位置を $\xi_{\text{tar}}(k) \in \Sigma_{\text{World}}$, i 番目の障害物位置を $\xi_{\text{obs}}^i(k) \in \Sigma_{\text{World}}$ ($i = 1, \dots, N$), それらの集合を $\xi_{\text{obs}} = \{\xi_{\text{obs}}^1, \dots, \xi_{\text{obs}}^N\}$ とするとき, ポテンシャル関数 $P: \mathbb{R}^n \times \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ を次式で定義する.

$$P(\xi, \xi_{\text{tar}}, \xi_{\text{obs}}) = P_{\text{att}}(\xi, \xi_{\text{tar}}) + \sum_{i=1}^N P_{\text{rep}}(\xi, \xi_{\text{obs}}^i) \quad (4)$$

ここで, $P_{\text{att}}: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ は引力ポテンシャル関数であり, 目標位置への引力を発生するように ξ が ξ_{tar} に近づくほど小さくなるように選ぶ. また, $P_{\text{rep}}: \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$ は斥力ポテンシャル関数であり, 障害物からの斥力を発生するように ξ が ξ_{obs}^i に近づくほど大きくなるように選ぶ. N は移動主体が備えるセンサが検出する障害物の数である. ポテンシャル関数の勾配は次式で与えられる.

$$\begin{aligned} \nabla P(\xi, \xi_{\text{tar}}, \xi_{\text{obs}}) \\ = \nabla P_{\text{att}}(\xi, \xi_{\text{tar}}) + \sum_{i=1}^N \nabla P_{\text{rep}}(\xi, \xi_{\text{obs}}^i) \end{aligned} \quad (5)$$

ここで, $\nabla P_{\text{att}}(\xi, \xi_{\text{tar}})$, $\nabla P_{\text{rep}}(\xi, \xi_{\text{tar}})$ は, それぞれ $P_{\text{att}}(\xi, \xi_{\text{tar}})$, $P_{\text{rep}}(\xi, \xi_{\text{tar}})$ の ξ に関する勾配である.

本論文では, $\nabla P(\xi, \xi_{\text{tar}})$, $\nabla P_{\text{att}}(\xi, \xi_{\text{tar}})$ を次式のように定義する⁵⁾.

$$\nabla P_{\text{att}}(\xi, \xi_{\text{tar}}) = K_{\text{att}} \mathbf{n}_{\text{att}} \quad (6)$$

$$\begin{aligned} \nabla P_{\text{rep}}(\xi, \xi_{\text{obs}}^i) \\ = \begin{cases} -K_{\text{rep}} \log \left(\frac{d(\xi, \xi_{\text{obs}}^i)}{d_o} \right) \mathbf{n}_{\text{rep}} & \text{if } d(\xi, \xi_{\text{obs}}^i) < d_o \\ 0 & \text{otherwise} \end{cases} \end{aligned} \quad (7)$$

ここで, $d(\mathbf{p}, \mathbf{q}) = \|\mathbf{q} - \mathbf{p}\|$ は2点 $\mathbf{p}, \mathbf{q} \in \mathbb{R}^n$ 間のユークリッド距離, $\mathbf{n}_{\text{att}} = (\xi_{\text{tar}} - \xi)/d(\xi, \xi_{\text{tar}}) \in \mathbb{R}^n$ は移動主体位置から目標位置への単位ベクトル, $d_o (> 0)$ は移動主体が備えるセンサの計測可能距離である. また, $K_{\text{att}}, K_{\text{rep}} (> 0)$ はそれぞれ引力重み, 斥力重みである. これらの重みの大きさによってポテンシャル場を調整する. (6)式は目標位置に対して移動主体がどの距離にあっても受ける一定の引力を表わし, (7)式は障害物に対して移動主体が受ける斥力を表わす. 障害物がセンサの範囲内にあるとき障害物との距離が短くなるにつれて移動主体が受ける斥力は急激に大きくなる一方で, センサの範囲外にあるとき斥力は受けない.

障害物が配置されている2次元空間上におけるポテンシャル関数の勾配(5)~(7)式の例を **Fig. 2** に示す. 白丸は障害物であり, 矢印はポテンシャル関数の勾配を表わしている. 人




Fig. 2 Example for gradient vectors of potential field

工ポテンシャル法では, 移動主体が勾配に沿って移動することで, 障害物を回避しながら目標位置に到達することを期待する.

3.2 人工ポテンシャル法を用いた参照信号の生成

移動主体に人工ポテンシャル法を用いる場合, ポテンシャル関数の勾配計算に必要な全情報が既知かつ静的な環境であれば, あらかじめ所望とする経路を求めそれに沿うように制御を行えばよい. 一方, 未知情報を含む環境や動的な環境であれば, ポテンシャル関数の勾配をリアルタイムに計算し速度制御を行なうことが考えられる. ポテンシャル関数の勾配は移動ロボットが進むべき方向を示しているため, 勾配 $\nabla P \in \mathbb{R}^n$ の負方向を速度 $\mathbf{v} \in \mathbb{R}^n$ に対する参照信号 $\mathbf{v}_{\text{ref}} \in \mathbb{R}^n$ として用いることで移動主体をポテンシャル関数の勾配方向に導くことができる.

この考え方を3次元空間上の移動主体であるクアドロータのフィードバック制御における参照信号の生成に適用する. 2章で述べるように, クアドロータの状態方程式は12個の状態変数を有する. それぞれの状態変数に対する参照信号を次式で表わす.

$$\mathbf{q}_{\text{ref}} = [\xi_{\text{ref}}^{\top} \mathbf{v}_{\text{ref}}^{\top} \boldsymbol{\eta}_{\text{ref}}^{\top} \boldsymbol{\omega}_{\text{ref}}^{\top}]^{\top} \quad (8)$$

ここで, $\xi_{\text{ref}}, \mathbf{v}_{\text{ref}}, \boldsymbol{\eta}_{\text{ref}}, \boldsymbol{\omega}_{\text{ref}} \in \mathbb{R}^3$ はそれぞれ, クアドロータの位置, 速度, 姿勢角, 姿勢角速度に対する参照信号である.

以下, それぞれの参照信号について述べる. まず, 位置に対する参照信号として現時刻の位置をそのまま用いることでクアドロータに加わる位置に関する制御入力を零にする. また, 障害物回避のためにポテンシャル関数の勾配の負方向を速度に対する参照信号とする. これらは次式のように表わすことができる.

$$\xi_{\text{ref}}(k) = \xi(k) \quad (9)$$

$$\mathbf{v}_{\text{ref}}(k) = -\nabla P(\xi(k), \xi_{\text{tar}}(k), \xi_{\text{obs}}(k)) \quad (10)$$

姿勢角と姿勢角速度は零に近いほうが好ましいため, 対応する参照信号を零にする. すなわち, $\boldsymbol{\eta}_{\text{ref}}(k) = [0 \ 0 \ 0]^{\top}$, $\boldsymbol{\omega}_{\text{ref}}(k) = [0 \ 0 \ 0]^{\top}$ とする.




Fig. 3 Environment with obstacles

参照信号(8)式に基づいてフィードバック制御を行なうことで、障害物を回避し目的位置に向かうことを期待する。しかしながら、(5)式のポテンシャル関数では速度を考慮していないため、クアドロータが高速で飛行するときにその慣性によって所望の経路を追従できないおそれがある。その結果、障害物に衝突する危険性が高くなる。

3.3 障害物の検知

人工ポテンシャル法を用いる際には、移動主体は周辺環境をオンラインでセンシングする必要がある。3次元空間上の移動主体のセンシングの例として、障害物を含む環境とセンシングのようすをそれぞれ Fig. 3, Fig. 4 にそれぞれ示す。両図において $\mathbf{x}$ は移動主体の位置を表す。Fig. 3 における物体が障害物を表す。Fig. 4 には障害物上のセンシング点を示す。たとえば、移動主体からレーザを発射しセンシング点までの距離を計測することを想定する。その場合、ポテンシャル関数(4)式における N をセンシング点の数と考える。

3.4 問題設定

クアドロータが初期位置から障害物を回避しながら目標位置に到達することを目的とする。クアドロータは適切な方法で安定化飛行できるとする。このとき、クアドロータは全体座標系での位置に加え、3.3節で述べた方法で障害物上の点までの距離と方向をセンサを使って検知する。また、クアドロータは目標位置の相対的な方向をつねに知ることができる。簡単のため、障害物に対する回避方向は2次元に限定する。

4. 深層強化学習

4.1 強化学習

学習主体が置かれた環境の要素を状態 $s \in \mathcal{S}$ 、環境に対する働きかけを行動 $a \in \mathcal{A}$ と呼ぶ。ただし、 $\mathcal{S}$ は状態空間であり取りうる状態の集合を表す。 $\mathcal{A}$ は行動空間であり状態 s において取りうる行動の集合を表す。また、環境は行動によって変化する状態を含む学習主体が作用する場のことである。本論文では、学習主体は移動主体と考える。状態 s において行動 a を取る確率 $\pi(a|s) \in [0, 1]$ を考えると、 $\pi(a|s)$ は $a \in \mathcal{A}$ の確率分布であり $\sum_{a \in \mathcal{A}} \pi(a|s) = 1$ が成立する。




Fig. 4 Sensing points on obstacles

これを方策と呼ぶ。とくに、行動が方策の分布にしたがうことを $a \sim \pi(a|s)$ と表現する。時刻 $k \in \{0, 1, 2, \dots\}$ において、現在の状態 S_k が行動 A_k によってつぎの状態 S_{k+1} に遷移したとき、報酬関数 $r: \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow \mathbb{R}$ によって報酬は $R_{k+1} = r(S_k, A_k, S_{k+1})$ となる。長期的視野で得られる報酬を評価する指標を収益と呼ぶ。収益の計算にはつぎの割引報酬和を用いる。

$$\sum_{k=0}^{\infty} \gamma^k R_{k+1} \quad (11)$$

ここで、 $\gamma \in (0, 1)$ は割引率である。割引報酬和は時刻 $k = 0$ から無限ステップ未来への報酬和であり、未来に行くほど割引率により報酬が減衰する。

収益は方策に依存して確率的に変動するので、状態 s を条件とした収益の期待値を状態価値とし、方策の良し悪しを決める指標とする。状態価値関数は現在の状態 s と方策 π に依存する関数であり、次式で表わされる。

$$V^{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k R_{k+1} \middle| S_0 = s \right]$$

ここで、 $\mathbb{E}_{\pi}$ は方策 π のもとでの期待値を表す。つまり、状態価値関数は状態 s における収益の期待値を表わしている。行動の評価を行なう場合には、次式で表わされる行動価値関数を用いる。

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k R_{k+1} \middle| S_0 = s, A_0 = a \right]$$

方策および価値関数をパラメータ $\Theta \in \mathbb{R}^{d_{\Theta}}$ によって定めるとき、それらを $\pi_{\Theta}(a|s)$ および $V_{\Theta}^{\pi}(s)$ と表わすことにする。このとき、 $V_{\Theta}^{\pi}(s)$ を評価し割引報酬和(11)式をなんらかの意味で最大にする $\pi_{\Theta}(a|s)$ を決めることは、強化学習の手法の1つとなる。状態 S_k で行動 A_k を取り S_{k+1} に遷移し報酬 R_{k+1} を得るとき、 Θ を更新することでより高い報酬を得られる方策を学習する。

4.2 A2C

方策評価と方策改善を繰り返す学習手法を方策反復と呼ぶ。

方策評価とは現在の方策に対応した状態価値関数を推定することであり、方策改善とは新しい方策を導くことである。方策評価と方策改善を交互に繰り返し方策を学習する手法全般を一般化方策反復と呼ぶ。交互の反復がない学習法では、行動可能なパターンが増えるにしたがい選択に大きな計算コストが必要になる。また、方策と状態価値関数がそれぞれ独立に最適値へ向かうために互いの整合性は取れない。一般化方策反復では、行動を選択する方策を Actor と呼び、Actor が選択した行動に基づいて推定した状態価値関数を Critic と呼ぶ。Actor と Critic の構造を導入することで、行動選択に最小限の計算コストしか必要とせず、サンプルを増やすことが可能になる。サンプルが増えることで Critic の状態価値関数の推定精度が上がり Actor はより大きな報酬を得るようになる。このとき、方策と状態価値関数が整合を取りながら互いに最適化されることが期待できる。

深層強化学習では、強化学習における状態価値関数、行動価値関数、方策関数を多層のニューラルネットワークで近似する。いま、 Θ をパラメータとする Actor-Critic 型のニューラルネットワークを考える。ただし、 Θ のうち $\pi_{\Theta}(a|s)$ を出力するパラメータ θ_A と $V_{\theta_C}^{\pi}(s)$ を出力するパラメータ θ_C に重複がないとする。このとき、 $\Theta = \{\theta_A, \theta_C\}$ である。その場合、パラメータ学習のために Actor と Critic の両方に目的関数を設定する必要がある。Actor は割引報酬和 (11) 式を最大にする行動を決める。行動は方策で決まるので、方策 $\pi_{\theta_A}(a|s)$ を用いて Actor の目的関数を次式で与えることができる。

$$L_{\text{act}}(\theta_A) = \mathbb{E}_{\pi}[\log \pi_{\theta_A}(a|s) A^{\pi}(s, a)] \quad (12)$$

ただし、 $A^{\pi}(s, a)$ はアドバンテージ関数であり、次式で与えられる。

$$A^{\pi}(s, a) = Q^{\pi}(s, a) - V_{\theta_C}^{\pi}(s)$$

アドバンテージ関数は状態 s において、行動 a がほかの行動に比べてどれだけよいかを表わしている。

一方、Critic は状態価値関数 $V_{\theta_C}^{\pi}(s)$ を行動価値関数 $Q^{\pi}(s, a)$ に近づける。すなわち、Critic の目的関数は次式となり、最小化する。

$$L_{\text{cri}}(\theta_C) = \mathbb{E}_{\pi}[(Q^{\pi}(s, a) - V_{\theta_C}^{\pi}(s))^2] \quad (13)$$

評価関数 (12) 式を最大にする θ_A を求めるには、方策勾配法を用いる。このとき、期待値はサンプルデータによる値の平均として処理する。(12) 式を最大にするには、 θ_A に関する $L_{\text{act}}(\theta_A)$ の勾配と逆方向に θ_A を更新する。同様に、(13) 式を最小にするには、 θ_C に関する $L_{\text{cri}}(\theta_C)$ の勾配方向に θ_C を更新する。

4.3 PPO

入力層を状態 s 、出力層をすべての行動 $a \in \mathcal{A}$ に対応する方策 $\pi_{\theta_A}(a|s)$ および状態価値関数 $V_{\theta_C}^{\pi}(s)$ とする Actor-Critic 型のニューラルネットワークを考える。PPO では、Actor の目的関数には (12) 式の代わりに次式を用いる。

Algorithm 1 PPO Algorithm

Require: $\mathcal{P} := \{(S_k, A_k, S_{k+1}, R_{k+1})\}_{k=0, \dots, T}$

Require: $\Theta := \{\theta_A, \theta_C\}$

$A_T \leftarrow 0$

for $k = T, \dots, 0$ **do**

$\delta_{k-1} \leftarrow R_k + \gamma V_{\theta_C}^{\pi}(S_k) - V_{\theta_C}^{\pi}(S_{k-1})$

$A_{k-1} \leftarrow \delta_{k-1} + \gamma \lambda A_k$

end for

$\mathcal{A} := \{A_0, A_1, \dots, A_T\}$

$(\theta_A^{\text{old}}, \theta_C^{\text{old}}) \leftarrow (\theta_A, \theta_C)$

$\theta_A \leftarrow \text{Adam}(\mathcal{M}, \mathcal{A}, L_{\text{act}}, \theta_A^{\text{old}})$ with clipping $c(\theta_A)$

$\theta_C \leftarrow \text{Adam}(\mathcal{M}, \mathcal{A}, L_{\text{cri}}, \theta_C^{\text{old}})$

return $\{\theta_A, \theta_C\}$

$$L_{\text{act}}^{\text{PPO}}(\theta_A) = \mathbb{E}_{\pi}[\min(c(\theta_A) A^{\pi}, c_{\text{clip}}(\theta_A) A^{\pi})] \quad (14)$$

ここで、

$$c(\theta_A) = \frac{\pi_{\theta_A}(a|s)}{\pi_{\theta_A^{\text{old}}}(a|s)}$$

$$c_{\text{clip}}(\theta_A) = \begin{cases} c(\theta_A) & \text{if } 1 - \epsilon \leq c(\theta_A) \leq 1 + \epsilon \\ 1 - \epsilon & \text{if } c(\theta_A) < 1 - \epsilon \\ 1 + \epsilon & \text{if } 1 + \epsilon < c(\theta_A) \end{cases}$$

である。 $\pi_{\theta_A^{\text{old}}}(a|s)$ と $\pi_{\theta_A}(a|s)$ は、それぞれ更新前と更新後の方策を表わす。 ϵ はハイパーパラメータであり 0.2 とする。(14) 式は本来最大化したい指標とは異なる代理の目的関数を更新前後の方策の比を用いて構成している。一方、Critic の評価関数には (13) 式を用いる。

ある程度の数のサンプルデータ $(S_k, A_k, S_{k+1}, R_{k+1})$ が与えられたとき、パラメータ Θ の更新は Algorithm 1 にしたがう。はじめにアドバンテージ関数を逆時間で求める。 $\lambda \in [0, 1]$ は収益に関する長期のステップを考慮するためのハイパーパラメータであり 0.95 とする。 Θ を推定するための方策勾配法には Adaptive Moment Estimation (Adam)¹⁶⁾を用いる。更新ステップ幅が大きすぎると学習が安定しないため、PPO に対して用いるときは $c(\theta_A)$ を区間 $[1 - \epsilon, 1 + \epsilon]$ でクリッピング、すなわち制限する。また、クリッピングしない方策比と比較し小さい方を評価値とするように Θ を定める。

Adam にはパラメータ Θ の学習を調整する 3 つのハイパーパラメータ $(\alpha, \beta_1, \beta_2)$ がある。 α はいわゆる学習率と呼ばれ、ほかの勾配法と同様に一度のパラメータ学習でどれだけパラメータを更新するかを決める。 β_1, β_2 はそれぞれ 1 次と 2 次モーメント用のハイパーパラメータである。通常は α のみ調整し、残りは $\beta_1 = 0.9, \beta_2 = 0.99$ と固定する。

5. ニューラルネットワークの設計

5.1 慣性を考慮した参照信号

速度に対する参照信号を人工ポテンシャル関数の勾配を用いて生成することを 3 章で述べた。また、この参照信号は移動主体の慣性については考慮していないことについても述べた。そこで、次式によって参照信号を生成する。




Fig. 5 State and action spaces




Fig. 6 Neural network model

$$\mathbf{v}_{\text{ref}}^*(k) = \mathbf{v}_{\text{ref}}(k) + \mathbf{v}_{\text{add}}(k) \quad (15)$$

ここで、 $\mathbf{v}_{\text{add}}(k)$ は移動主体の慣性を考慮するための追加の参照信号である。 $\mathbf{v}_{\text{ref}}(k)$ は人工ポテンシャル法から求めた速度に対する参照信号であることに注意する。このとき、クアドロータの状態変数に対する参照信号を

$$\mathbf{q}_{\text{ref}}^* = [\xi_{\text{ref}}^{\top} (\mathbf{v}_{\text{ref}}^*)^{\top} \boldsymbol{\eta}_{\text{ref}}^{\top} \boldsymbol{\omega}_{\text{ref}}^{\top}]^{\top} \quad (16)$$

とする。本論文では、 $\mathbf{v}_{\text{add}}(k)$ を深層強化学習を用いて生成する。

5.2 状態・行動空間とニューラルネットワークの構造

本論文で考える学習環境における状態および行動空間の概念図を Fig. 5 に示す。白丸は移動主体、 $\mathbf{v}(k)$ は移動主体の速度、 $\mathbf{v}_{\text{ref}}(k)$ は速度に対して人工ポテンシャル法より得られる参照信号、 $\mathbf{v}_{\text{add}}(k)$ は慣性を考慮するための追加の参照信号、 $\zeta(k)$ は $\mathbf{v}(k)$ と $\mathbf{v}_{\text{ref}}(k)$ のなす角度であり、次式で与えられる。

$$\zeta(k) = \cos^{-1} \left(\frac{\mathbf{v}_{\text{ref}}(k) \cdot \mathbf{v}(k)}{\|\mathbf{v}_{\text{ref}}(k)\| \|\mathbf{v}(k)\|} \right) \quad (17)$$

このとき、学習環境における状態と行動をつぎのようにおく。

$$S_k = \{ \|\mathbf{v}(k)\|, \|\mathbf{v}_{\text{ref}}(k)\|, |\zeta(k)| \} \in \mathcal{S}$$

$$A_k = \mathbf{v}_{\text{add}}(k) \in \mathcal{A}$$

行動 A_k をニューラルネットワークで生成するためのモデルを Fig. 6 に示す。モデルは、破線で表わす入力層、複数の隠れ層、出力層からなり、各層に実線で表わす複数のノードを配置する。入力層に状態 S_k の値、出力層にすべての行動

$a \in \mathcal{A} (\subset \mathbb{R}^n)$ に対応する方策 $\pi_{\theta_A}(a|S_k) \in [0, 1]$ と状態価値 $V_{\theta_C}^{\pi}(S_k) \in \mathbb{R}$ の値をノードとする。方策は確率分布であるため、ソフトマックス (Softmax) 関数に通して 0 から 1 までの範囲の値としている。また、方策と状態価値を生成するパラメータが独立になるように隠れ層を 2 つに分けている。入力層の各ノードはこれら二重の隠れ層の中のノードと別々に接続する。二重の隠れ層のうち、片方の隠れ層のノードは出力層の方策に、もう一方の隠れ層のノードは出力層の状態価値関数と接続する。つまり、前者の隠れ層を含むニューラルネットワークが Actor、後者の隠れ層を含むニューラルネットワークが Critic を生成する。このとき、(14) 式を最大にし (13) 式を最小にするように θ_A 、 θ_C をそれぞれ求める。

出力層における行動に関する n 個のノード値 $\pi_{\theta_A}(a|S_k) \in [0, 1]$ ($a \in \mathcal{A}$) を得たとき、本論文で用いる行動 A_k の生成方法は、つぎに述べる 2 種類である。

- ノード値 $\pi_{\theta_A}(a|S_k)$ ($a \in \mathcal{A}$) の対数を取り、それにガンベル分布 $\text{Gumbel}(0, 1)$ (注 1) にしたガウスノイズ g_a ($a \in \mathcal{A}$) を加え、最も値が大きい行動を単独で選択する。つまり、次式で行動を生成する。

$$A_k = \arg \max_{a \in \mathcal{A}} (\log \pi_{\theta_A}(a|S_k) + g_a) \quad (18)$$

このような行動選択は Gumbel-max トリック¹⁷⁾と呼ばれ、得られた行動の確率分布はもとの確率分布 $\pi_{\theta_A}(a|S_k)$ ($a \in \mathcal{A}$) に一致するという性質を有する。

- ノード値 $\pi_{\theta_A}(a|S_k)$ ($a \in \mathcal{A}$) のうち、最も値が大きい行動を単独で選択する。つまり、次式で行動を生成する。

$$A_k = \arg \max_{a \in \mathcal{A}} \pi_{\theta_A}(a|S_k) \quad (19)$$

このような行動選択はグリーディと呼ばれる。

行動空間を $\mathcal{A} \subset \mathbb{R}^n$ として学習すると、 $\mathbf{v}_{\text{add}} \in \mathbb{R}^n$ の各要素に対応する方向ごとに一定の大きさの行動しか取ることができない。そこで以降では、方向や大きさを含めて $m(> n)$ 個の行動パターンを取れるように $\mathcal{A}$ を $\bar{\mathcal{A}} \subset \mathbb{R}^m$ に拡張する。

二重になった隠れ層がそれぞれ ℓ 層あるとき、各層のノード数を $n_1, n_2, \dots, n_{\ell}$ とする。入力層から第 1 層の隠れ層への接続重みが $2 \times 3n_1$ 個、第 i 層から第 $i+1$ 層への接続重みが $2n_i n_{i+1}$ 個、第 ℓ 層から出力層への接続重みが $n_{\ell}(m+1)$ 個、接続重みと同時に二重になった各層でバイアスを 1 個加えるため、推定すべきパラメータ Θ の次元は次式で与えられる。

$$d_{\Theta} = 2(3n_1 + 1) + \{n_{\ell}(m+1) + 2\} + \sum_{i=1}^{\ell-1} 2(n_i n_{i+1} + 1) \quad (20)$$

5.3 報酬関数の設計

行動価値関数を推定するために報酬関数を設計する。設計のために Fig. 5 に示す状態から Fig. 7 に示す状態への遷移を考える。Fig. 5 において $\mathbf{v}_{\text{ref}}(k)$ と $\mathbf{v}_{\text{add}}(k)$ の和を参照信号

(注 1) 付録 A を参照のこと。




Fig. 7 State transition

として用いた結果, Fig. 7 では時刻 $k+1$ に移動主体の速度が $\mathbf{v}(k+1)$ に遷移している. $\zeta'(k+1)$ は, $\mathbf{v}_{\text{ref}}(k)$ と $\mathbf{v}(k+1)$ のなす角度である. いい換えると, 現時刻の所望の経路方向と 1 ステップ先の軌道方向との誤差角度である. 以上の準備のもと, 本論文では状態 S_k で行動 A_k を取り S_{k+1} に遷移したときの報酬を

$$R_{k+1} = r(\mathbf{v}(k), \mathbf{v}_{\text{ref}}(k), \mathbf{v}(k+1)) \in \mathbb{R}^n$$

とする. 報酬関数は次式で定める.

$$r(\mathbf{v}(k), \mathbf{v}_{\text{ref}}(k), \mathbf{v}(k+1)) = r_1(\mathbf{v}_{\text{ref}}(k), \mathbf{v}(k+1)) + r_2(\mathbf{v}(k), \mathbf{v}_{\text{ref}}(k)) + r_3(\mathbf{v}(k+1)) \quad (21)$$

ただし,

$$r_1(\mathbf{v}_{\text{ref}}, \mathbf{v}) = \begin{cases} 6.0 & \text{if } 0^\circ \leq \zeta' < 5^\circ \\ 3.0 & \text{if } 5^\circ \leq \zeta' < 10^\circ \\ -3.0 & \text{otherwise} \end{cases}$$

$$r_2(\mathbf{v}, \mathbf{v}_{\text{ref}}) = -\|\mathbf{v}_{\text{add}}\|$$

$$r_3(\mathbf{v}) = 0.5\|\mathbf{v}\|$$

とする. $\zeta' = \cos^{-1}(\mathbf{v}_{\text{ref}} \cdot \mathbf{v} / \|\mathbf{v}_{\text{ref}}\| \|\mathbf{v}\|)$ に注意する. (21) 式において, 第 1 項は誤差角度を小さくし, 第 2 項は報酬を高くし, 第 3 項は速度を維持するのに貢献する.

5.4 パラメータの学習と評価

障害物の配置が異なる複数の学習用環境を準備する. また, これとは別に評価用環境を準備する. 両環境において, Fig. 6 に示すニューラルネットワークを用いる. 学習においては, 学習用環境を使ってニューラルネットワークに含まれる接続重みやバイアスからなるパラメータ Θ を求める. その際, 一定数のサンプルを蓄積し, それらすべてを用いてパラメータを更新することをバッチ学習と呼ぶ. バッチ学習はオンライン学習に比べて計算負荷が低減できる. このとき, パラメータを更新するために必要となるステップ数を更新間隔と呼ぶ. また, 蓄積したサンプルからある数のサンプルをランダムに抜き出してパラメータを更新することをミニバッチ学習, そのときに用いるサンプル数をミニバッチサイズと呼ぶ. ミニバッチ学習は環境に偏った学習を防ぐ利点がある. 本論文では, ミニバッチ学習を採用する. 学習後, 求まった Θ に対して学習用と評価用の各環境で障害物回避性能を評価する.

学習においては, 初めにパラメータを初期化する. その後, 指定した回数の試行を実行しパラメータを学習していく. 1 回の

Algorithm 2 Train per trial

```

 $n_L \leftarrow 0, n_U \leftarrow 0, \mathcal{D} \leftarrow \phi$ 
while  $n_L < N_L$  do
  for  $i = 1, \dots, N_E$  do
    Set  $i$ -th Environment
     $k \leftarrow 0$ 
    Observe  $\mathbf{q}(0)$ ,  $\xi_{\text{tar}}(0)$  and  $\xi_{\text{obs}}(0)$ 
    Get  $\mathbf{v}_{\text{ref}}(0)$  and  $\zeta(0)$  from Eqs. (10) and (17), respectively
     $S_0 \leftarrow \{\|\mathbf{v}(0)\|, \|\mathbf{v}_{\text{ref}}(0)\|, |\zeta(0)|\}$ 
    while not reaching Goal do
      Put  $S_k$  to NN
      Get  $\pi_{\Theta}(a|S_k)$  for  $a \in \bar{\mathcal{A}}$  and  $V^{\pi}(S_k)$  from NN
      Determine  $\mathbf{v}_{\text{add}}(k) = A_k$  by Eq. (18)
       $A_k \leftarrow \mathbf{v}_{\text{add}}(k)$ 
      Get  $\mathbf{v}_{\text{ref}}^*(k)$  from Eq. (15)
      Get  $\mathbf{q}_{\text{ref}}^*(k)$  from Eq. (16)
      Get  $\mathbf{u}(k)$  from (3)
      Get  $\mathbf{q}(k+1)$  by applying  $\mathbf{u}(k)$  to Model (2)
      Observe  $\xi_{\text{tar}}(k+1)$  and  $\xi_{\text{obs}}(k+1)$ 
      Get  $\mathbf{v}_{\text{ref}}(k+1)$  and  $\zeta(k+1)$  from Eqs. (10) and (17), respectively
       $S_k \leftarrow \{\|\mathbf{v}(k+1)\|, \|\mathbf{v}_{\text{ref}}(k+1)\|, |\zeta(k+1)|\}$ 
      Get  $r(\mathbf{v}(k), \mathbf{v}_{\text{ref}}(k), \mathbf{v}(k+1))$  from Eq. (21)
       $R_{k+1} \leftarrow r(\mathbf{v}(k), \mathbf{v}_{\text{ref}}(k), \mathbf{v}(k+1))$ 
       $\mathcal{D} \leftarrow \{\mathcal{D}, (S_k, A_k, S_{k+1}, R_{k+1})\}$ 
       $n_U \leftarrow n_U + 1, n_L \leftarrow n_L + 1$ 
      if  $n_U = N_U$  then
         $\mathcal{M} \leftarrow \text{Minibatch}\{\mathcal{D}\}$  with  $N_M$ 
        Run PPO Algorithm for  $\mathcal{M}$  and Update  $\Theta$ 
         $\mathcal{D} \leftarrow \phi, n_U \leftarrow 0$ 
      end if
       $k \leftarrow k + 1$ 
    end while
  end for
end while

```

試行は Algorithm 2 にしたがう. 汎用性をもたせるために N_E 種類の学習用環境を順に繰り返し用いる. モデル (2) 式を使い軌道を計算し, 確率分布 $\pi_{\Theta_A}(a|s)$ にしたがう確率的な行動になるように (18) 式で生成した行動 A_k を追加の参照信号 $\mathbf{v}_{\text{add}}(k)$ とする. 試行開始から指定したステップ数 N_L に達したらその試行を終了する. その間, サンプル $(S_k, A_k, S_{k+1}, R_{k+1})$ が指定した更新間隔 N_U だけ集合 $\mathcal{D}$ として蓄積されると, そこからミニバッチサイズ N_M のサンプルを抜き取り集合 $\mathcal{M}$ に対して PPO を用いてパラメータ Θ を更新する. 1 回の試行が終了したら, 得られたパラメータをつぎの試行の初期値とする.

評価においては, 学習で得られたパラメータ Θ を用い, 単一の環境に対して, グリディな行動を取るように (19) 式で生成した A_k を $\mathbf{v}_{\text{add}}(k)$ とする.

6. 数値実験

追加の参照信号 $\mathbf{v}_{\text{add}}$ の構成に提案手法を用いた場合のクアドロータの障害物回避に関する数値実験を行なう. 実験において障害物の検知, 人工ポテンシャル法の勾配計算, ニューラルネットワークの計算, 制御入力の計算, 行動の評価による

Table 1 Physical parameters of quadrotor

M	1.3 kg
d	0.248 m
b	$4.340 \times 10^{-5} \text{ N} \cdot (\text{s/rad})^2$
k	$2.188 \times 10^{-6} \text{ N} \cdot \text{m} \cdot (\text{s/rad})^2$
J_x	$1.467 \times 10^{-2} \text{ kg} \cdot \text{m}^2$
J_y	$1.467 \times 10^{-2} \text{ kg} \cdot \text{m}^2$
J_z	$2.331 \times 10^{-2} \text{ kg} \cdot \text{m}^2$
J_r	$1.757 \times 10^{-4} \text{ kg} \cdot \text{m}^2$
g	9.806 m/s^2

Table 2 Hyper parameters of neural network

Input Layer	3 nodes
Hidden Layer	2 layers $\times$ 256 nodes $\times$ 2
Output Layer	(21 + 1) nodes
Learning Rate	7×10^{-4}
Update Interval	128×5
Minibatch Size	128
Activating Function	ReLU



パラメータ更新はすべて同一の時刻で行なう．そのステップ間隔は 0.01 s とする．また，(11)式における割引率 γ を 0.99 とする．引力および斥力ポテンシャル関数の勾配 (6)，(7)式では， $(K_{\text{att}}, K_{\text{rep}}) = (4.0, 0.4)$ とする．

軌道計算には非線形モデル (1) 式を 2 次項まで考慮したオイラー近似による離散時間モデル (2) 式を用いる．また，安定化制御のために状態フィードバック制御を用いる．ゲイン F の設計には (1) 式を線形化したモデルに LQR を適用して設計する．以上で必要となった物理パラメータを **Table 1** に示す⁴⁾．学習と評価の計算には CPU: Core i5-7400 (3.0 GHz), Memory: 64 GB, GPU: GeForce GTX 1050Ti 4 GB を備える PC において，ChainerRL¹⁸⁾を用いる．

学習用と評価用の環境における水平面は，ともに $12 \text{ m} \times 12 \text{ m}$ の正方形である．また，クアドロータの初期位置を $(0.0, 0.0)$ ，目標位置を $(11.5, 11.5)$ とする．クアドロータが備えるセンサは水平方向の 360° を 16 等分した方向で，重心位置から 5 m 以内の障害物を検知する．

6.1 ハイパーパラメータの設定

障害物の配置を変えた学習用環境を $(N_E = 3)$ 種類，評価用環境 1 種類を準備する．学習用環境を A, B, C とするとき， $A \rightarrow B \rightarrow C \rightarrow A \rightarrow \dots$ のように順に適用する．学習におけるパラメータ Θ の初期化には，平均を 0，分散を入力ノード数の逆数としたガウス分布を用いた¹⁹⁾．また，1 回の試行は 5×10^4 ステップとする．この試行を 1×10^7 回繰り返す．深層学習に関するハイパーパラメータの値を **Table 2** に示す．これらは学習用環境に対して予備実験を行ない調整した．Fig. 6 に示すニューラルネットワークの入力層は 3 ノードあり，移動主体の速度の大きさ，ポテンシャル関数の勾配の大きさ，誤差角度である．これらは状態 S_k の要素に対応している．隠れ層は 2 層であり各 256 ノードある．これが二重になっている．出力層は 22 ノードあり，(20)式よりパラメータ Θ の次元は 138246 となる．出力層において 21 ノードは追加

**Fig. 8** Discretization of action**Fig. 9** Reward evolution

の参照信号 $\mathbf{v}_{\text{ref}}$ を離散化している．残り 1 ノードは状態価値関数に対応している．追加の参照信号 $\mathbf{v}_{\text{ref}}$ の次元は 3 であるが，3.4 節で述べたように回避方向は 2 次元に限定している．そのため， $\mathbf{v}_{\text{add}} = v[\cos \kappa \sin \kappa 0]^T$ と考える．方向に関して離散化した信号 $\mathbf{v}_{\text{ref}}$ のようすを **Fig. 8** に示す．8 方向に離散化されるように見えるが，角度 $\zeta(k)$ の正負によって $\mathbf{v}_{\text{add}}$ の向きを変えて行動するので，実際には 5 方向の信号を生成する．つまり， $\kappa \in \{0, \frac{\pi}{4}, \frac{\pi}{2}, \frac{3\pi}{4}, \pi\}$ とする．また，大きさは 5 段階にする．具体的には， $v \in \{0, 0.5, 1.0, 1.5, 2.0\}$ とする．大きさ 5 種類に対して方向 5 種類を考えるが，大きさ 0 に対しては方向は 0 のみ考えるため，5.2 節における行動パターン m は 21 となる．移動主体から見た座標系 $\Sigma_{\text{Quad}}(x, y, z)$ を導入すると，速度を x 軸方向としたとき， y 成分が正であれば正方向の 5 種類から，負であれば負方向の 5 種類から追加の参照信号を選択する．Adam の学習率 α は 7×10^{-4} とする．パラメータの更新間隔を 128×5 ，ミニバッチサイズを 128 とする．ニューラルネットワークにおける活性化関数は ReLU 関数とする．

6.2 実験結果

学習用環境を順に変えた学習の試行回数に対するミニバッチ学習ごとの報酬の平均値の推移を **Fig. 9** に示す．図には 1×10^6 回の試行ごとの平均値を示している．試行回数が増えると得られる報酬が上がる傾向が見られる．また，急激な報酬の減少がないため特定の環境に対する過学習は起きていないと考えられる．ただし， 5×10^6 ， 7×10^6 回で報酬が下がっている．要因としては，特定の学習環境に対して偏りのある方策に陥っているか，局所的な最適解を与える方策を一度経由しなければより優れた方策が得られない学習問題になって




Fig. 10 Trajectory and error angle (train B)




Fig. 12 Trajectory and error angle (test)




Fig. 11 Velocity and additional reference (train B)




Fig. 13 Velocity and additional reference (test)

いるか、のどちらかであると考えられる。

学習用環境 A, B, C のうち B とそれに対する結果を Fig. 10, Fig. 11 に、評価用環境とそれに対する結果を

Fig. 12, Fig. 13 に示す。Fig. 10, Fig. 12 は、人工ポテンシャル法のみを用いた場合と提案手法を用いた場合の軌道を上段に、そのときの時刻に対する誤差角度を下段に表わして




Fig. 14 Learning environment A (upper) and C (lower)

いる。上段の図において、破線が人工ポテンシャル法を用いた場合の慣性の影響がない理想的な軌跡である。この軌道はオフライン計算ではなく、オンラインで時刻ごとに障害物の検知、人工ポテンシャル法による参照信号の生成、参照信号にしたがった理想的な移動を繰り返すことにより生成した軌跡である。実線が提案手法を用いた場合のクアドロータの軌道、点線が人工ポテンシャルのみを用いた場合のクアドロータの軌道である。下段の図において、実線が提案手法、破線が人工ポテンシャル法のみによる誤差角度である。Fig. 11, Fig. 13 は、時刻に対する速度の大きさと速度に対する参照信号の大きさを表わしている。上段の図において、破線が人工ポテンシャル関数の勾配の大きさであり、実線が速度の大きさである。中段と下段の図はクアドロータの速度方向を x 軸方向としたときの、 x および y 方向の追加入力を表わす。追加入力は参照信号と同様に 1 ステップごとに更新される。Fig. 11 では、180 ステップ付近で左下の障害物に近づくのを防ぐために y 軸正方向、330 から 500 ステップ付近まで右下の障害物を避けるために x 軸負方向に継続的に追加入力を加えていることがわかる。また、Fig. 13 では、400 ステップ付近

で右中央の障害物を避ける際に y 軸正方向に継続的に追加入力を加えていることがわかる。学習用環境 A, C と対応する人工ポテンシャル法による理想的な軌道については Fig. 14 に示す。これらを学習用環境 B とともに用いた。

学習用環境 B では、提案手法は所望の経路から大きく外れない軌道を取っており、とくに障害物を避ける際に人工ポテンシャル法よりも所望の経路に近い軌道を取る傾向が見られる。

また、学習時には使用していない初見の評価用環境においては、提案手法は人工ポテンシャル法よりも全体的に所望の経路に近い軌道を取る傾向が見られる。以上から、汎用的な学習ができていると考えられる。移動速度に関してはどちらの環境においても参照信号によく追従しており、行動空間を増やした効果が現われている。

7. おわりに

本論文では人工ポテンシャル法を用いたクアドロータのような動的なロボットの障害物回避において生じる、慣性による影響を深層強化学習を用いて低減する手法を提案した。行動計画において参照信号を生成する際に、ポテンシャルの勾配に加えて、速度を考慮する追加の参照信号をニューラルネットワークを用いて推定した。数値実験では所望の経路との角度誤差を小さくする行動に報酬を与えて学習することで、追従精度を高めることができた。また、学習に用いた環境以外に対しても誤差を小さくすることができた。以上から、学習したニューラルネットワークに汎用性が確認できた。

今後は行動空間を 2 次元に制限しない動的障害物の回避問題への適用を考えている。また、連続行動を取り扱うことも考える。

謝辞 本論文をまとめるにあたり、明治大学理工学部機械情報工学科制御工学研究室芦田樹君、長岡椋介君にお手伝いいただいた。また、本研究は JSPS 科研費 JP19K04444, JP19H02158 の助成を受けたものである。謝意を表する。

参考文献

- 1) O. Khatib: Real-time obstacle avoidance for manipulators and mobile robots, *Int. Journal of Robotics Research*, **5**-1, 90/98 (1986).
- 2) T.T. Mac, C. Copot, A. Hernandez and R.D. Keyser: Improved potential field method for unknown obstacle avoidance using UAV in indoor environment, *Proc. 2016 IEEE 14th International Symposium on Applied Machine Intelligence and Informatics (SAMI)*, Herlany, 345/350 (2016)
- 3) T. Paul, T.R. Krogstad and J.T. Gravdahl: Modeling of UAV formation flight using 3D potential field, *Simulation Modeling Practice and Theory*, **16**-9, 1453/1462 (2008)
- 4) K. Motonaka, K. Watanabe and S. Maeyama: Motion planning of a UAV using a kinodynamic motion planning method, *Proc. 39th Annual Conference of the IEEE Industrial Electronics Society (IECON 2013)*, 6383/6387 (2013)
- 5) S.S. Ge and Y.J. Cui: Dynamic motion planning for mobile robots using potential field method, *Autonomous Robots*, **13**-3, 207/222 (2002)
- 6) R.S. Sutton and A.G. Barto: *Reinforcement Learning: An Introduction*, 2nd edition, MIT Press (2018)

- 7) V. Mnih, K. Kavukcuoglu, D. Silver, A.A. Rusu, J. Veness, M.G. Bellemare, A. Graves, M. Riedmiller, A.K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg and D. Hassabis: Human-level control through deep reinforcement learning, *Nature*, **518**-7540, 529/533 (2015)
- 8) D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra and M. Riedmiller: Deterministic policy gradient algorithms, *Proc. 31st International Conference of Machine Learning (ICML 2014)*, **32**, 387/395 (2014)
- 9) L. Buşoniu, T. Bruin, D. Tolić, J. Kober and I. Palunko: Reinforcement learning for control: Performance, stability, and deep approximators, *Annual Reviews in Control*, **46**, 8/28 (2018)
- 10) Preferred Networks : ロボットカーの強化学習による自動走行, <https://research.preferred.jp/2016/01/ces2016/> (2016)
- 11) Preferred Networks : 深層強化学習に基づくドローンの自律飛行, <https://research.preferred.jp/2016/10/ceatec2016-drone/> (2016)
- 12) J. Schulman, F. Wolski, P. Dhariwal, A. Radford and O. Klimov: Proximal policy optimization algorithms, *arXiv preprint*, arXiv:1707.06347 (2017)
- 13) G. Cybenko: Approximation by superpositions of a sigmoidal function, *Mathematics of Control, Signals and Systems*, **2**-4, 303/314 (1918)
- 14) R. Sutton, D. McAllester, S. Singh and Y. Mansour: Policy gradient methods for reinforcement learning with function approximation, *Proc. 12th International Conference on Neural Information Processing Systems (NIPS'99)*, 1057/1063 (1999)
- 15) J. Schulman, S. Levine, P. Abbeel, M. Jordan and P. Moritz: Trust region policy optimization, *Proc. 32nd International Conference on Machine Learning (ICML15)*, 1889/1897 (2015)
- 16) D.P. Kingma and J. Ba: Adam: A method for stochastic optimization, *arXiv*:1412.6980 (2014)
- 17) C.J. Maddison, D. Tarlow and T. Minka: A* Sampling, *Advances in Neural Information Processing Systems*, 3086/3094 (2014)
- 18) Preferred Networks : 深層強化学習ライブラリ ChainerRL, <https://research.preferred.jp/2017/02/chainerrl/>
- 19) Y. LeCun, L. Bottou, G.B. Orr and K.R. Müller: *Efficient BackProp*, *Neural Networks: Tricks of the Trade*, 2nd edition, 9/48, Springer Berlin Heidelberg (2012)

《付 録》

A. ガンベル分布

実定数 μ と正定数 η に対して, 確率変数 x の分布関数が

$$G(x) = \exp \left[-\exp \left\{ -\left(\frac{x - \mu}{\eta} \right) \right\} \right]$$

で与えられるとき, x はガンベル分布 $\text{Gumbel}(\mu, \eta)$ にしたがるという.

ガンベル分布 $\text{Gumbel}(0, 1)$ にしたがる確率変数 g は, 上式を使って逆算することで, 一様分布 $\text{Uniform}(0, 1)$ にしたがる確率変数 u を用いて, $g = -\log(-\log(u))$ として生成することができる.

[著 者 紹 介]

白 石 大 介



2017 年明治大学理工学部機械情報工学科卒業.
2019 年明治大学大学院理工学研究科機械工学専攻
博士前期課程修了. 在学中, 強化学習の研究に興味をもつ.

市 原 裕 之 (正会員)



2000 年明治大学大学院理工学研究科機械工学
専攻博士後期課程修了. 博士 (工学). 同年明治大
学理工学部助手. 2001 年茨城大学大学院理工学
研究科 SVBL 非常勤研究員. 2002 年九州工業大
学情報工学部助手. 2010 年明治大学理工学部専任講
師. 2013 年同准教授. 2019 年同教授となり現在
に至る. 2016 年から 1 年間 LAAS-CNRS (フラ
ンス) 客員研究員. 制御工学の研究に従事. シス
テム制御情報学会, IEEE CSS の会員.