

# マルチエージェント強化学習による障害物回避を伴う UAV 編隊の経路計画

Autonomous Path Planning for UAV Formation Flight Control within Unknown Environment  
via Multi-agent Reinforcement Learning

森友輝 荒井幸代  
Yuki Mori Sachiyo Arai

千葉大学大学院 融合理工学府 電気電子工学コース

Department of electrical and electronic engineering, Graduate School of Science and Engineering, Chiba University

In recent years, there has been a great demand for cooperative work by multiple autonomous mobile robots. This research deals with the task of maintaining the formation of multiple robots in an environment with obstacles. Existing research using deep reinforcement learning (DRL) deals only with the movement of the robot in charge of following in the formation (follower). However, if obstacles restrict the movement of the follower, it becomes temporarily difficult to maintain the formation. In this study, we propose a path planning method using multi-agent DRL for all robots in the formation, including the leading robot, which is responsible for determining the direction of the formation (leader). The performance of the proposed method is verified in an experimental environment, and it is confirmed that the autonomous action selection of each robot enabled formation maintenance and obstacle avoidance.

## 1. はじめに

近年、解決すべき問題の複雑化に伴い、複数の自律移動ロボットによる協調作業への要請が高まっている。中でも、障害物が存在する環境で複数ロボットが適切な編隊を維持しながら移動するタスクは、それぞれのロボットの経路計画を問題として様々なアプローチで研究されている [Zhang 18, Lee 18]。このとき、深層強化学習 (DRL) によるアプローチに着目した既存研究 [Sui 19] では、分散制御を前提として、編隊の中で追従を担当する機体 (フォロワー) の動きだけを扱っている。しかし、障害物などの外乱によってフォロワーの動きが制限されれば、一時的に編隊維持は困難となる。そこで本研究では、マルチエージェント強化学習を用いて、編隊の進行方向を決定する役割を担う先頭の機体 (リーダー) を含めた、編隊を形成するすべての機体を対象とする経路計画法を提案する。

## 2. 準備

本稿の理解に必要な強化学習、行動価値関数, Actor-Critic およびアプローチの基礎理論となる DDPG を紹介する。

### 2.1 強化学習

強化学習 [Sutton 00] は、未知の環境における最適な制御則を試行錯誤的に獲得する手法である。意思決定主体であるエージェントには、状態入力に対する正しい出力を示す教師信号が存在せず、報酬と呼ばれるスカラーの情報だけが与えられる。エージェントはこの報酬の期待総和を最大化することを目的として、蓄積した経験に基づく学習を行う。

環境モデルを  $\langle S, \mathcal{A}, \mathcal{P}, \mathcal{R} \rangle$ 、エージェントが持つ行動指針を方策  $\pi$  と定義する。  $S$  は状態集合、  $\mathcal{A}$  は行動集合、  $\mathcal{P}$  は状態遷移確率、  $\mathcal{R}$  は報酬関数を表し、方策  $\pi$  は状態  $s$  において行動  $a$  を選択する確率である。 エージェントは時刻  $t$  において状態  $s \in S$  を観測し、自身の方策  $\pi_t$  に応じた行動  $a \in \mathcal{A}$  を選択する。 その後、時刻  $(t+1)$  では  $s, a$  によって確率的に次状態  $s'$  に遷移し、報酬  $r(s, a)$  を得る。 エージェントは上記のプロセスを繰り返し、報酬に基づいた学習を進めていく。

連絡先: 森友輝, 千葉大学大学院融合理工学府, 千葉市稲毛区 弥生町 1-33, 043-290-3316

### 2.2 行動価値関数

エージェントは獲得した報酬から行動価値関数  $Q(s, a)$  を推定し、その値を用いて方策  $\pi$  の評価と改善を行う。 方策  $\pi$  が与えられるとき、行動価値関数  $Q^\pi(s, a)$  は式 (1) で定義される。 ただし、割引率  $\gamma$  ( $0 \leq \gamma \leq 1$ ) は、将来期待される報酬の重要度を示すパラメータである。

$$Q^\pi(s, a) = \sum_{s'} P_{ss'}^a \left[ r(s, a) + \gamma \max_{a'} Q^\pi(s', a') \right] \quad (1)$$

### 2.3 Actor-Critic

Actor-Critic は、Actor と呼ばれる行動選択部と、Critic と呼ばれる選択した行動の評価部が独立して存在する強化学習のフレームワークの一つである。 Actor-Critic では、Actor に確率密度関数を導入することによって、連続行動空間についても迅速な行動選択が可能になる。

### 2.4 DDPG

Deep Deterministic Policy Gradient (DDPG) は、Actor-Critic の Actor 部、Critic 部がニューラルネットワークで構成されている深層強化学習手法の一つである [Lillicrap 15]。 このとき、Actor 部は状態  $s$  において一意的な行動  $a$  が選択される決定論的方策となる。 エージェントは Critic 部で推定された行動価値関数  $Q$  を基に、行動選択を担う Actor 部の評価と改善を行う。

## 3. 問題設定

### 3.1 複数ロボットの適切な隊形維持を要するタスク

物流や環境調査に関するタスクの遂行を一つの目的として、複数の自律移動ロボットが適切な編隊を維持しながら移動するタスクの研究が進められている [Zhang 18, Lee 18]。 このとき、複数の機体が協力してタスクにあたることの利点として、合計積載量の増加や移動時のエネルギー節約 [Mirzaenia 19] が挙げられる。 本研究では、障害物が存在する環境で適切な隊形維持を目指すタスクに焦点を当て、DRL を用いたアプローチに着目する。

### 3.2 関連研究

DRL を用いた既存研究 [Sui 19] では、分散制御を前提として、編隊の中で追従を担当する機体（フォロワー）の動きだけを扱っている。具体的には、編隊の先頭に行く機体（リーダー）への追従を行ううえで、衝突の可能性がある動的障害物を必要に応じて避けている。しかし、障害物などの外乱によってフォロワーの動きが制限されれば、障害物回避を優先した行動を行うため、一時的に編隊が崩れてしまう可能性がある。本研究では、制御対象をリーダーを含む編隊を形成するすべての機体に拡張し、静的障害物回避と編隊維持を考慮した編隊全体の経路計画法を提案する。

### 3.3 対象問題のモデル化

本研究では、香川県丸亀市近海の地形を模して作成した図 1 における物資輸送タスクを想定する。具体的には、複数のスタート地点から同時に出発した 3 台の Unmanned Aerial Vehicle (UAV) が特定のゴール範囲を目指して移動する。なお、環境の簡略化のため、障害物として離島上空を設定した。各機体は即座に編隊を形成した後に、編隊を維持しながら、離島上空を避けてゴールを目指すことが要求される。

## 4. アプローチ：MADDPG

### 4.1 MADDPG の導入

自律移動ロボットの編隊を扱う対象問題は、環境内に複数のエージェントが存在するマルチエージェントシステム (MAS) である。このとき、複数のエージェントの行動によって環境が動的に変化するため、第 2 章で述べた従来の強化学習手法は対象問題に適していない。各エージェントは他エージェントの状態と行動を考慮した方策の学習が必要であり、本研究では、マルチエージェント強化学習手法の一つである Multi-Agent Deep Deterministic Policy Gradient (MADDPG) を導入する。

### 4.2 MADDPG の概要

MADDPG は、シングルエージェント用の学習手法として開発された DDPG を MAS に応用した強化学習手法である [Lowe 17]。各エージェントがもつ Actor 部と Critic 部の概要図を図 2 に示す。

MADDPG と DDPG の違いとして、環境内に存在する  $N$  体すべてのエージェントの状態値  $S = \{s_1 \dots s_N\}$  と行動値  $A = \{a_1 \dots a_N\}$  を入力とする Critic 部が挙げられる。対して、タスク実行時に用いられる Actor 部に関して、各エージェントは個別に設定された状態  $s_i$  を基にした行動選択を行っている。言い換えると、各エージェントはすべてのエージェントの状態と行動を考慮したうえで、個別報酬  $r_i$  に応じた行動価値関数  $Q(S, A)$  を推定し、分散制御を前提とする自身の方策  $\pi_i$  の評価と改善を行っている。

各エージェントの行動によって環境が動的に変化する対象問題について、編隊を形成するエージェント間における協調動作の獲得が期待される MADDPG は対象問題に有効である。

## 5. 計算機実験

### 5.1 実験設定

#### 5.1.1 機体設定

対象タスクで用いる機体として垂直に離着陸が可能な Vertical Take-Off and Landing aircraft (VTOL) を想定する。このとき、離着陸を除く移動時は所定高度を常に維持するものとして、経路計画を地面に水平に二次元に限定する。



図 1: 実験環境：香川県丸亀市近海




図 2: MADDPG の概要図




図 3: UAV 3 台で構成される V 字型編隊

#### 5.1.2 V 字型編隊設定

UAV 3 台で構成される V 字型編隊を図 3 で定義する。このとき、各フォロワーの理想位置は、リーダーの現在位置と進行方向によって決定される。なお、本研究では編隊を形成しているか否かの判断として許容誤差を用いる。具体的には、各フォロワーの理想位置からのずれ幅がそれぞれ許容誤差以内である場合に編隊を組んでいるとする。

### 5.1.3 エージェント設定

各エージェントの状態、行動および報酬を説明する。

#### (1) 状態

エージェント番号  $i$  の機体がつま情報として絶対座標  $(x_i, y_i)$  と進行方向  $\theta$  を定義する。各エージェントの状態を表 1 に示す。ただし、 $x_{12}$  はリーダーから見たフォロワー 1 の相対座標である。本研究ではフォロワー間の観測、通信は行われない。

#### (2) 行動

行動はすべてのエージェントに共通して、次の 20 秒間における速度  $v$  の決定と進行方向  $\theta$  の調整である。各値は表 2 で示す連続値の範囲から選択される。

ただし、本研究では推奨速度として「120km/h」を設定する。各エージェントは編隊形成時を除いて、できる限り推奨速度で移動することが求められる。

#### (3) 報酬

報酬は表 3 で示す 4 つの観点の合計値として各エージェントに与えられる。このとき、リーダーは各フォロワーに対する二つの編隊報酬をもつ一方で、各フォロワーはリーダーに対する一つだけである。

## 5.2 実験結果および考察

本研究で扱う計算機実験は実験 1 と実験 2 の二つである。ただし、実験 2 は実験 1 で得られた方策を用いた追加シミュレーションであり、学習自体は行っていない。

### 5.2.1 実験 1：異なるスタート地点から出発するタスク

実験 1 で得られた実験結果を図 4～図 6 で示す。

図 4 は、学習済みの方策から得られた各エージェントの行動軌跡である。離れた位置から出発した各エージェントが即座に編隊を形成し、離島上空を避けながらゴールを目指す様子が確認できる。より具体的な各エージェントの動きを図 5 と図 6 で説明する。

図 5 は各エージェントの速度推移、図 6 は各フォロワーの理想位置からのずれ幅の時間推移を示している。ただし、図中の灰色は図 5 では選択可能な速度範囲、図 6 では許容誤差範囲である。出発直後はリーダーが最高速度でゴールを目指し、各フォロワーはリーダーに合流することで、ずれ幅を素早く許容誤差以内に抑えていることが確認できる。また、編隊形成後は推奨速度で緩やかなカーブをするリーダーに、フォロワーが追従することによって、ずれ幅を常に許容誤差以内に抑えている。

上記より、各エージェントは障害物回避と編隊維持の両方の観点において合理的な経路計画ができていていると考える。

### 5.2.2 実験 2：得られた方策を用いたシミュレーション

実験 1 では、提案法がスタート地点とゴール範囲を結ぶ理想経路の作成が可能であることが確認できた。しかし、実際の移動時には外乱の影響を受け、理想経路から外れてしまうことが予想される。したがって、各エージェントが保持する方策は理想経路から外れた位置からでも新しい理想経路を作成することが求められる。本研究では、実験 1 で得られた方策を用いて、瀬戸内海を吹く風に着目した追加シミュレーションを実施する。

実験環境付近で観測された最大瞬間風速は「風向：北北東、風速：36.0m」である。このとき、20 秒間隔で行動選択を行う本研究では、編隊は目標状態に対して最大で南南西に 720m 流されることが想定される。風に流される前後で各エージェントの位置関係は変化しないものとして、編隊が南南西に 720m 流された場合のシミュレーションを行う。

表 1: 各エージェントの状態

| エージェント              | 状態                                                                       |
|---------------------|--------------------------------------------------------------------------|
| リーダー ( $i = 1$ )    | $x_1, y_1, \theta_1, x_{12}, y_{12}, \theta_2, x_{13}, y_{13}, \theta_3$ |
| フォロワー 1 ( $i = 2$ ) | $x_2, y_2, \theta_2, x_{21}, y_{21}, \theta_1$                           |
| フォロワー 2 ( $i = 3$ ) | $x_3, y_3, \theta_3, x_{31}, y_{31}, \theta_1$                           |

表 2: 全エージェントに共通する行動

| 行動                            |
|-------------------------------|
| 速度 $v$                        |
| 100km/h ~ (120km/h) ~ 140km/h |
| 進行方向 $\theta$                 |
| $-15^\circ \sim +15^\circ$    |

表 3: 報酬を構成する各観点

| 観点         | 役割                |
|------------|-------------------|
| 1. ゴール距離報酬 | ゴール到達を妨げる動きを抑制    |
| 2. 障害物報酬   | 障害物 (離島) を通る動きを抑制 |
| 3. 編隊報酬    | 理想位置を保つ動きを促進      |
| 4. 速度報酬    | 推奨速度で移動することを促進    |




図 4: 各エージェントの行動軌跡




図 5: 各エージェントの速度推移




図 6: 各フォロワーにおける理想位置からのずれ幅

表 4: 各フォロワーにおけるずれ幅の最大値

| 目標状態  | フォロワー 2 (青) | フォロワー 3 (緑) |
|-------|-------------|-------------|
| No.14 | 150.0 m     | 122.8 m     |




図 7: 14 番目の目標状態に対するシミュレーション結果

一例として、図 4 で示す理想経路上に存在する 14 番目の目標状態へ移動中 (260 ~ 280 秒後) に、前述した風に流された場合のシミュレーション結果を図 7 と表 4 に示す。図 7 は、各エージェントに関して新たに作成された理想経路である。すでに形成されている編隊を維持しながら、新たな経路でゴールを目指す様子が確認できる。表 4 はシミュレーションにおける各フォロワーのずれ幅の最大値である。

実験 2 では、図 4 で示す理想経路上に存在する 22 個の目標状態すべてに対して同様のシミュレーションを実施した。シミュレーション結果として、表 4 を一例とする、各目標状態に対する各フォロワーの最大ずれ幅を図 8 に示す。図 6 と図 8 の比較より、新たに作成されたすべての理想経路において、形成済みの編隊を崩す動きは見られなかった。したがって、現状の理想経路から外れた場合に生成される新たな理想経路についても、適切な編隊維持を実現している。

6. 結論および今後の課題

本研究では、複数の自律移動ロボットが適切な編隊を維持しながら移動するタスクに対して、DRL によるアプローチに着目し、リーダーを含めた編隊を形成するすべての機体の経路計画法を提案した。このとき、リーダー自身も編隊維持を考慮した行動選択を行うため、障害物などの外乱に応じた編隊全体の移動が可能となる。

提案法の性能は、実際の地形を模した実験環境を用いて検証し、編隊維持と障害物回避を各ロボットの自律的な行動選択によって実現できたことを確認した。また、理想経路の追従が不可能な状況として、編隊全体が強風による影響を受けた場合を想定し、獲得した方策の外乱に対する適応性を確認した。

今後の課題として、実機を用いた実証実験と編隊規模の拡大を挙げる。このとき、編隊規模の拡大に伴い、学習の複雑化と計算量の増加が予想されるため、転移学習をはじめとする取り組みの検討をしていく。




図 8: 各目標状態に対する各フォロワーの最大ずれ幅

参考文献

[Zhang 18] Zhang, Jialong, et al. "Collision avoidance in fixed-wing UAV formation flight based on a consensus control algorithm." IEEE Access 6 (2018): 43672-43682.

[Lee 18] Lee, Giroung, and Dongkyoung Chwa. "Decentralized behavior-based formation control of multiple robots considering obstacle avoidance." Intelligent Service Robotics 11.1 (2018): 127-138.

[Sui 19] Z. Sui, Z. Pu, J. Yi and T. Xiong, "Formation Control with Collision Avoidance through Deep Reinforcement Learning," 2019 International Joint Conference on Neural Networks (IJCNN), 2019, pp. 1-8, doi: 10.1109/IJCNN.2019.8851906.

[Sutton 00] Richard S. Sutton, Andrew G. Barto: Reinforcement Learning: An Introduction, 三上貞芳, 皆川雅章訳: "強化学習", 森北出版, pp.142-170, (2000)

[Lillicrap 15] Lillicrap, Timothy P., et al. "Continuous control with deep reinforcement learning." arXiv preprint arXiv:1509.02971 (2015).

[Mirzaenia 19] Mirzaenia, A., et al. "Energy conservation of V-shaped swarming fixed-wing drones through position reconfiguration." Aerospace Science and Technology 94 (2019): 105398.

[Lowe 17] Lowe, Ryan, et al. "Multi-agent actor-critic for mixed cooperative-competitive environments." Advances in neural information processing systems 30 (2017).