

「一般化塗りつぶし問題」における強化学習

Multi-Agent Reinforcement Learning in General Filling Problem

岩井大河¹ 三宅陽一郎¹

Taiga Iwai¹, Youichiro Miyake¹

¹立教大学大学院

¹Rikkyo University

Abstract: In this study, a top-down Commander AI-Agent (CAIA) model and a bottom-up Multi-Agent Communication (MAC) model are applied to the "Generalized Filling Problem". This problem is researched as a game that requires multiple agents to fill an entire grid map and can be used to explore algorithms for coordinating multiple robots, such as cleaning robots, mine clearance, and drone control. Each agent has a neural network, the inputs of which are the coordinates and map information of each agent, and the outputs of which agent's actions. The NN in the CAIA model is held by the Commander and a NN of agent in the MAC model is held by each agent. When the entire map is filled, rewards are given to all agents and the learning process is made progress. The goal of study is to compare the two models and determine which algorithm is more efficient, the CAIA model or the MAC model, depending on the shape of the map. A useful application of this research is as a way for multiple drones to efficiently explore a space.

1 はじめに

本報告では、以下で定義する「一般化塗りつぶし問題」の提案と、この問題にマルチエージェント強化学習を使用した実験から分析を行う。

マルチエージェント強化学習は、実世界においてエージェントに協調することを学習させるための有望な手法であり、災害地で実際に複数のドローンで人を発見する助けになると思われる。

本問題は、ドローンが災害地の広い範囲から人を見つけるための効率的な探索に応用できる重要な問題である。この問題をシンプルにした、決められたサイズのグリッド状マップにおいて、全てのタイルを塗りつぶす「塗りつぶしゲーム」を制作した。このゲームを「一般化塗りつぶし問題」と呼ぶ。

この問題は、マップ内にタイルを敷き詰めていることに着目し、学習環境をグリッド環境と迷路環境の二つに分ける。この二つの環境にマルチエージェント強化学習を使用した指揮官 AI-エージェントモデルとマルチエージェント・コミュニケーションモデルを用いて比較実験を行い、各モデルの塗りつぶす早さや塗りつぶす方策の違いを考察する。

2 関連研究

「一般化塗りつぶし問題」は、マップには確率的占有マップ[1]、エージェントの行動は完全網羅経路計画[2]、タイルの塗りつぶす方策は巡回セールスマン問題[3]と中国人郵便配達問題[4]に、マルチエージェントシステムのモデルは、メタ AI[5][6]や協調型マルチエージェントシステム[7][8]が関連し

ている。

確率占有マップは、シミュレーション世界における物体の位置推定を行う方法であり、本研究ではマップの塗りつぶし判定をタイルごとに数値を用いて決定し、マップ中のタイルの状態を観測値としてエージェントに与えている。

複数のエージェントがマップを塗りつぶす過程で領域ごとに分かれるような方策は、完全網羅経路計画に関連したものがある。この経路計画は、効率的な清掃作業を行うために全体の清掃タスクを複数の清掃ロボットに効果的に割り当てる、タスクエリア割り当てアルゴリズムである。マップのタイルを点として考えると全ての点を通る巡回セールスマン問題、タイルからタイルへの移動を辺として考えると全ての辺を通る中国人郵便配達問題の単純な形と言える。

指揮官 AI-エージェントモデルは、環境における全ての情報を持つことから、メタ AI のような環境を支配する AI と関連し、本研究では環境の情報から全エージェントの行動を支配的に決定している。

マルチエージェント・コミュニケーションモデルはエージェントが他のエージェントと共有しあいながら行動をとるため、コミュニケーションを学習している。「一般化塗りつぶし問題」は、全てのタイルを塗りつぶすために、複数のエージェントが塗りつぶすタスクとタスクエリア割り当てアルゴリズムの清掃タスクを同じものとみなし、よりシンプルな問題としている。このように全体を網羅していく問題は、清掃だけでなく、実空間における地雷除去や災害時の探索などにも応用できる。

3 「一般化塗りつぶし問題」における強化学習

・「塗りつぶしゲーム」では、マップ（図1）の中央をエージェントの初期位置とする。タイルの上をエージェントが移動して塗りつぶしていく。タイルがない場所を通る事ができない。マップ情報は0と1と2の3つの状態で表現される。0はタイルがなく、1にはタイルがある状態である。エージェントがタイルの上を通ると塗りつぶされたと判定され（図2）、タイルの状態は1から2に切り替わる。そして、タイルの状態をリアルタイムでマップ情報として各エージェントに共有する。全てのタイルを塗りつぶし、マップ情報の全て1が2になると1エピソードが終了し、報酬が与えられる。




図1 3×3のマップの初期状態




図2 1ステップ後のマップの状態

例として、図のマップ情報は下記のように表現される。

図1のマップ情報 : [0, 1, 0, 1, 2, 1, 0, 1, 0]

図2のマップ情報 : [0, 2, 0, 1, 2, 1, 0, 1, 0]

終了時のマップ情報 : [0, 2, 0, 2, 2, 2, 0, 2, 0]

このベクトル列が各エージェントに渡されるマップ情報である。

・指揮官AI-エージェントモデル（以下CAIAモデル）は、図3のようにチーム全体の動きを上から下に指示が出るトップダウン型のシステムである。各エージェントは座標情報を指揮官と共有し、指揮官は、エージェントの座標情報とマップ情報から、各エージェントに次ステップの行動指示を与える。このモデルでは、エージェントは指揮官だけと繋がり、他のエージェントとの繋がりはない。このモデルは、エージェント間の同期の問題がなく、全体の統一的な動きを作るために適している。指揮官だけニューラルネットワーク（以下NN）を持ち、マップ情報と各エージェントの座標情報を入力し、各エージェントの行動を出力として決定している。




図3 CAIAモデルのイメージ

・マルチエージェント・コミュニケーションモデルは、図4のようにエージェントがそれぞれ動くことによってチーム全体の動きが形成されるボトムアップ型のシステムである。各エージェントがNNを持ち、入力には各エージェントにマップ情報と各エージェントの座標情報、出力はエージェント自身の行動である。エージェント同士で座標情報を共有し、各エージェントは他エージェントの座標とマップ情報から、次ステップの行動を決定する。全体として意思決定の柔軟さを持ち、創発的なビヘイビアが期待される。




図4 MACモデルのイメージ

4 実験

CAIAモデルとMACモデルをグリッド環境と迷路環境でマルチエージェント強化学習し、学習結果と推論結果から評価をして、考察をおこなう。

4.1 実験設定

エージェント数4体、5×5のマップで初期位置(2, 2)からエピソードを開始する。指揮官AIとマルチエージェントを使用した実験を行う。1ステップ進むごとに報酬1に減衰率0.99を乗算し、エピソード終了時に現在の報酬の値を与える。図5のように、マルチエージェント強化学習にはPP0[9]を用い、入力を5ステップ分スタックし、隠れ層は2層、学習ステップ数は1000000(1M)ステップでシミュレーションを行った。




図5 強化学習モデルのイメージ

エージェントの推論時の行動を記録する上で、座標データをグラフ化する時に観察しやすくするために、図6のようにマップの中心から何度の座標にいるのかを示す評価方法をとる。この評価方法を用いることで、X軸座標とY軸座標の2つを見なくてもエージェントの行動を-180°から180°まで観察することができる。この評価方法では、各エージェントが異なる角度をしている場合、それぞれの評価値

は離れたまま進んでいく。各エージェントが共通の行動をとった場合、評価値は近い値となり、同様なグラフとなる。




図 6 評価方法のイメージ

4.2 実験環境

グリッド環境は、図 7 のようにマップをタイルで 5 × 5 の隙間なく敷き詰めた環境である。塗りつぶすタイルの数は 2 5 である。迷路環境は、図 8 のようにマップをタイルで 5 × 5 の迷路を作成する。塗りつぶすタイルの数は 2 1 である。



図 7 グリッド環境



図 8 迷路環境

4.3 実験結果

・学習状況




図 9 エピソード長 図 10 将来報酬予測 図 11 エントロピー

	グリッド環境 CAIA モデル	グリッド環境 MAC モデル	迷路環境 CAIA モデル	迷路環境 MAC モデル
学習ステップ数	0. 996M	0. 996M	0. 996M	0. 996M
エピソード長	9. 376	13. 634	5. 984	12. 752
将来報酬予測	0. 953	0. 931	0. 970	0. 936
エントロピー	1. 259	0. 496	0. 741	0. 464

表 1 モデル別

記録は、表 1 にある 0. 996M ステップ時を参照する。図 9, 10 から全てのモデルが、エピソードが短く、将来報酬予測は大きくなっている。この二つから学習が順調にできていることがわかる。図 11 から CAIA モデルは 4 つのエージェントを制御しているため、1 つエージェントを制御している MAC モデルよりもエントロピーの値が大きくなっている。グ

リッド環境よりも迷路環境の方が塗りつぶすタイルの数が少ないため、エージェントの方策が早く安定し始めた。

・グリッド環境

CAIA モデルは図 12 のように、各エージェントが異なる行動をしている。エージェント 1, 2, 3 は隅に移動するように行動しているが、エージェント 4 は円を描くような行動をしている。MAC モデルは図 13 のように、各エージェントが同様の行動をしながら塗りつぶしていることがわかる。エージェント 1, 2, 3 は 12 ステップまで同じように、エージェント 4 は 10 ステップまでは他のエージェントと逆の行動をとっている。



図 12 CAIA モデル




図 13 MAC モデル

・迷路環境

CAIA モデルは図 14 のように、マップを四分割したそれぞれの領域を各エージェントが塗りつぶしている。そのため、全エージェントが 2 ステップ以降からはほぼ変化がない。MAC モデルは図 15 のように、全エージェントが似通った行動をとりながら塗りつぶしている。特に最初から 10 ステップまで全エージェントが同じような行動をとっている。以降は、各エージェントが四隅に広がるように行動をとった。





図 14 CAIA モデル




図 15 MAC モデル

5 考察

表1から、CAIAモデルは、グリッド環境と迷路環境でも平均的にMACモデルよりもエピソード長が短くなっている。CAIAモデルは、1つのNNで4つのエージェントを制御している。そのため、全エージェントが既に塗りつぶされたタイルを再び塗りつぶすことがないように学習したと考えられる。それにより、各エージェントが四方に分かれ、タイルを塗りつぶす範囲を割り当てている。迷路環境では、塗りつぶすタイルの数が少ないため、エージェントが四方に分かれて塗りつぶしを行えている。

MACモデルは、どちらの環境でも全エージェントが円を描くようにエージェントが行動している。MACモデルは、1つのNNで1つのエージェントを制御している。そのため、エージェントがまとまって行動するのは、エージェントのNNの生成が、元が一つのものから始まるため、各エージェントが似通った方策をとるからだと考えられる。

6 結論

本研究では、実験を通してモデルによるグリッド環境と迷路環境による影響を観察した。

(1) エージェントの行動

CAIAモデルは、各エージェントが異なる行動をしながら塗りつぶしている。MACモデルは、各エージェントが共通した行動を観測できた。

(2) エージェントの行動の要因

CAIAモデルは、一つのNNが4つのエージェントの行動を制御しているため、効率良く塗り潰そうとして、できるだけ重複しないようにタイル上を行動している。MACモデルは、4つのエージェントのNNは、1エピソードごとにNNが一つに集約されるため、同じような行動をとっている

(3) 塗り残しが発生した場合

CAIAモデルは、塗り残したタイルに1つのエージェントを向かわせる。MACモデルは、塗り残したタイルに全エージェントが向かいつつ、他のエージェントが向かっているとも考えているため、塗り残しが発生すると極端にエピソード長が長くなる。

CAIAモデルは、効率的にエージェントが行動するため、各エージェントが広がるよう行動する。一方、MACモデルは、各エージェントが他のエージェントと同じよう行動しているため、CAIAモデルよりも効率的ではない。

そのため、災害地での被災者の発見など時間を重視する時には効率良くエージェントを行動させるCAIAモデル、ゲームなど集団行動をとることでリアリティを増長するにはエージェントがまとまって行動するMACモデルを推奨する。

7 今後の展望

本研究ではマップの大きさが 5×5 と小さいサイズでの学習となりました。これからは、今回よりも大きいサイズでの塗りつぶしができるようなシステムを構築していく予定である。そのためには、報酬系を1エピソードあたりに加えるタイミングを増やしていかなければいけないと考えている。長いエピソードを学習させる場合に全てのタスクを完了させるのは不可能に近いので、学習の進みが遅くなってしまう。そのため、短いタスクをクリアし、複雑なタスクを徐々に解決していく構造にする。それに加え、モデルの組織構造も改良していく必要がある。本研究では、トップダウン型とボトムアップ型と単純な型となっているため、この2つのモデルを合わせた中間的なモデルの構築をしていく予定である。

参考文献

- [1] ISLA, Damian A.; BLUMBERG, Bruce M. Object persistence for synthetic creatures. In: Proceedings of the first international joint conference on Autonomous agents and multiagent systems: part 3. 2002. p. 1356-1363, (2002)
- [2] LEE, Jeong H., et al. Complete coverage path planning for cleaning task using multiple robots. In: 2009 IEEE International Conference on Systems, Man and Cybernetics. IEEE, 2009. p. 3618-3622., (2009)
- [3] HOFFMAN, Karla L., et al. Traveling salesman problem. Encyclopedia of operations research and management science, 2013, 1: 1573-1578, (2013)
- [4] THIMBLEBY, Harold. The directed chinese postman problem. Software: Practice and Experience, 2003, 33.11: 1081-1096, (2003)
- [5] MIYAKE, Youichiro. Meta-AI, Character AI, Spatial AI Dynamic Cooperation Model in Digital Game. In: The Japanese Society for Artificial Intelligence. (2020)
- [6] MIYAKE, Youichiro; MANABE, Kazuko. Game AI techniques from algorithmic approach to machine learning. In: SIGGRAPH Asia 2018 Courses. 2018. p. 1-491, (2018)
- [7] GUPTA, Jayesh K.; EGOROV, Maxim; KOCHENDERFER, Mykel. Cooperative multi-agent control using deep reinforcement learning. In: International conference on autonomous agents and multiagent systems. Springer, Cham, 2017. p. 66-83, (2017)
- [8] SINGH, Amanpreet; JAIN, Tushar; SUKHBAATAR, Sainbayar. Learning when to communicate at scale in multiagent cooperative and competitive tasks. arXiv preprint arXiv:1812.09755, (2018)
- [9] SCHULMAN, John, et al. Proximal policy optimization algorithms. arXiv preprint arXiv:1707.06347, (2017)