

強化学習とフィードバック誤差学習を用いた腕の姿勢制御

神原 裕行^{†,††} 金 載然^{††} 佐藤 誠^{††} 小池 康晴^{††,††}

Learning Arm's Posture Control Using Reinforcement Learning and
Feedback-Error-Learning

Hiroyuki KAMBARA^{†,††}, Jaehyo KIM^{††}, Makoto SATO^{††}, and Yasuharu KOIKE^{††,††}

あらまし 近年、生体の随意運動学習に関していくつかの計算論的なモデルが提案されている。その中に、小脳における学習モデルとしてのフィードバック誤差学習や、大脳基底核におけるそれとしての強化学習の枠組みの一つである Actor-Critic 法がある。本研究では、これら二つを組み合わせた運動学習モデルを提案する。このモデルでは、フィードバック誤差学習におけるフィードバック制御器が Actor-Critic 法により自立的に獲得される。このモデルを用いて、二関節六筋の腕を制御対象とした鉛直平面内における姿勢保持運動の学習シミュレーション実験を行った。その結果、タスクに応じた報酬のみから、腕の逆スタティックスモデルが獲得できることを確かめた。また、最適レギュレータをフィードバック制御器として用いたフィードバック誤差学習との性能比較実験を行った。更に、腕の逆スタティックスモデルと Actor-Critic 法の Actor 制御部を用いて二点間到達運動を行い、生体の運動制御に関して考察した。

キーワード フィードバック誤差学習、強化学習、Actor-Critic 法、姿勢制御、逆ダイナミックスモデル、逆スタティックスモデル

1. ま え が き

近年、人間やサルの随意運動に関する研究が数多く行われ、生体の運動制御機構にはフィードバックだけでなく、フィードフォワード制御機構も存在することが確かめられてきた。Polit と Bizzi [1] は求心性神経を切断したサルを用いて、体性感覚情報のフィードバック経路を除いても腕の到達運動が可能であることを確かめた。また、生体のフィードバック制御機構のループ時間には時間遅れが存在するため、単純なフィード

バック制御だけでは速く滑らかな運動を行うことができない。このようなことから、フィードフォワード制御機構が運動制御に重要な役割を果たしていることが分かる。

最近、フィードフォワード制御が可能となるのは、脳内に制御対象である身体などの内部モデルが存在するためであるということがいわれている [2]。内部モデルとは、制御対象の入出力特性に関する知識の内部表現であり、内部モデルの中でも特に、逆ダイナミックスモデルの存在がフィードフォワード制御には重要であると考えられている。逆ダイナミックスモデルとは制御対象と逆の入出力関係をもつシステムであり、入力として軌道を受け取り、出力としてそれを実現するための運動指令を計算する。もし脳内に制御対象の完全な逆ダイナミックスモデルが存在していれば、目標となる軌道が与えられるだけで、それを実現するための運動指令が計算できるため、フィードバック信号を必要としない完全なフィードフォワード制御が可能となる。このような逆ダイナミックスモデルは、生まれつき脳内に備わっているものではなく、脳が学習によって獲得する必要があると考えられる。しかし、教

[†] 東京工業大学大学院総合理工学研究科知能システム科学専攻, 横浜市
Department of Computational Intelligence and Systems Science, Interdisciplinary Graduate School of Science and Engineering, Tokyo Institute of Technology, 4259 Nagatsuta-cho, Midori-ku, Yokohama-shi, 226-8503 Japan

^{††} 科学技術振興機構 CREST, 川口市
Core Research for Evolution Science and Technology, Japan Science and Technology Agency, Kawaguchi-shi, 332-0012 Japan

^{†††} 東京工業大学精密工学研究所, 横浜市
Precision and Intelligence Laboratory, Tokyo Institute of Technology, 4259 Nagatsuta-cho, Midori-ku, Yokohama-shi, 226-8503 Japan

師信号として、身体ダイナミクスを表現する運動方程式を解いた理想的な解を直接得ることはできない。様々な環境において、成長とともにダイナミクスが日々変化する身体を、脳が実際に制御しながら学習し獲得していく必要がある。

このような生体の随意運動学習の計算論的なモデルとして、Kawato ら [3] はフィードバック誤差学習を提案した。このモデルでは、フィードバック制御器と、フィードフォワード制御器である逆ダイナミクスモデルの出力を用いて制御が行われ、同時にフィードバック制御器の出力を教師信号として逆ダイナミクスモデルの学習が行われる。そしてこのフィードバック誤差学習が、脳内の中でも特に逆ダイナミクスモデルが存在している可能性が高いとされる小脳の学習モデルとして、解剖学的、生理学的にもよく適合することを示した [2]。また、フィードバック誤差学習を用いて、実際に産業用マニピュレータや空気圧制御のゴム人工筋をもつマニピュレータの逆ダイナミクスを学習させるといった研究が行われ、その有効性が示されている [4], [5]。

一方、脳内における随意運動学習の他の計算論的なモデルとして、強化学習の枠組みの一つである Actor-Critic 法 [6] が注目を集めている。この方式では、状態価値を計算する Critic 部と行動を決定する Actor 部が別々に用意されており、与えられる報酬から計算される TD 誤差と呼ばれる強化信号によってそれぞれの学習が行われる。この構造が大脳基底核の神経回路構造とよく適合することが、解剖学的、生理学的にも確かめられている [7]。また、Actor-Critic 法を用いて、腕のモデルを制御対象とした水平面内のある一点への二点間到達運動を学習させるといった研究も行われている [8]。

ところで、フィードバック誤差学習を適用した上記の研究 [4], [5] では、フィードバック制御器として設計者があらかじめゲインを調節した PID 制御器などが用いられていた。しかし、我々の脳に関して考えた場合、あらかじめゲインが調節されたものが必ずしもすべての随意運動に関して備わっているとは考えられない。また、我々の身体ダイナミクスは日々変化しており、その変化に合わせて脳は制御方法を変化させていると思われる。したがって、フィードバック誤差学習を脳内における運動学習モデルとして考えた場合、フィードバック制御器も逆ダイナミクスモデル同様、環境との相互作用を通じて学習される必要がある。更

に PID 制御だけでは、ゲインをかなり調節しても到達運動において計測されたほぼ直線的な手先軌道が再現できない [10] ことから、脳内にそのような単純なフィードバック制御器が存在しているとは考えにくい。

本研究では、脳の運動学習モデルの提案を目的とし、環境との相互作用により、逆ダイナミクスモデルだけでなく、フィードバック制御器もオンラインで学習するモデルを提案する。具体的には、小脳における運動学習モデルと考えられているフィードバック誤差学習と、大脳基底核における運動学習モデルとして考えられている Actor-Critic 法を組み合わせたモデルを構築し、フィードバック誤差学習のフィードバック制御器が Actor-Critic 法を用いて獲得されるようにした。この提案モデルは、脳内の学習アルゴリズムとして考えられている教師あり学習、強化学習、教師なし学習の三つのうち [9]、教師あり学習と強化学習を組み合わせたものとなっている。

提案モデルの有効性を確認するため、鉛直平面内における腕の姿勢保持タスクに適用する。制御対象には非線形性を有する筋のモデルを導入した二関節六筋の腕モデルを用いて、生体に近いものとした。そして計算機シミュレーション実験を行い、提案モデルによって、腕を様々な姿勢に保つための逆静力学問題を解く逆スタティクスモデルが獲得できることを示す。また、フィードバック制御器にあらかじめゲインを調節したものをを用いたフィードバック誤差学習との比較シミュレーション実験を行い、提案学習モデルの性能に関する考察をする。更に、姿勢保持運動のために獲得された制御器を用いて二点間到達運動を計算機上で再現する。そして、実際に人間が行った運動との比較や、終端位置制御仮説に関する考察を行い、様々な制御方法が提案されている二点間到達運動において、逆スタティクスモデルと Actor-Critic 法によって獲得されたフィードバック制御器がどのような意味をもつかを議論する。

2. 提案学習モデル

この章では、本研究で構築した、フィードバック誤差学習と Actor-Critic 法を組み合わせた運動学習モデルに関する説明をする。

フィードバック誤差学習は、もともと大脳小脳連関と赤核系の部分をモデル化したものである [2]。このモデルをブロック図で書き表したものが図 1 である。制御対象への運動指令は、フィードバック制御器（以下




図 1 フィードバック誤差学習
Fig. 1 Feedback-error-learning.

FBC と略：Feedback Controller) と逆ダイナミクスモデル (以下 IDM と略：Inverse Dynamics Model) からの出力を足し合わせたものが用いられる。FBC には目標軌道と実現された軌道との誤差が入力され、その誤差を小さくするような運動指令が出力される。一方、IDM には目標軌道が入力され、その軌道を実現するための運動指令が出力される。IDM の教師信号には、FBC の出力が用いられ、この教師信号を 0 にするように学習が行われる。学習の初期段階では、主に FBC の出力によりフィードバック制御が行われるが、学習が進むにつれフィードバック運動指令は小さくなり、最終的に IDM の出力だけで制御されるフィードフォワード制御が実現される。

本研究では、フィードバック誤差学習におけるフィードバック制御器に、Actor-Critic 法の Actor 制御部を適用した。その構造を図 2 に示す。目標軌道 θ^d が入力されると、IDM は θ^d を実現するためのフィードフォワード運動指令 u^{ff} を出力する。一方、フィードバック制御器を構成する Actor には、目標軌道 θ^d と実現軌道 θ との軌道誤差 θ^e が入力される。Actor は θ^e に応じたフィードバック運動指令 u^{fb} を出力する。そして、 u^{ff} と u^{fb} を足し合わせた全体の運動指令 u が制御対象に入力される。すると、制御対象のダイナミクスに従い軌道 θ が遷移し、報酬 r が与えられる。この報酬をもとに TD 誤差 δ が計算され、Actor-Critic の学習を行う。また、IDM は Actor の出力 u^{fb} を教師信号として学習を行う。

ここで、従来のようにフィードバック制御器にあらかじめゲインを調節したものが用いられている場合、学習の初期段階においてもフィードバック運動指令は軌道誤差を減らす方向に働くため、IDM への適当な教師信号としてそのまま用いることができる。しかし、本研究で構築した学習モデルでは、学習の初期段階において、フィードバック制御器である Actor の学習も進行していないため、Actor からのフィードバック運




図 2 フィードバック誤差学習と Actor-Critic を組み合わせた提案学習モデル
Fig. 2 Proposed learning model using Feedback-Error-Learning and the Actor-Critic method.

動指令 u^{fb} を教師信号としてそのまま用いることはできない。そこで本研究では、TD 誤差 δ によるゲートを設け、IDM の学習係数を変化させる。これは、学習が進むにつれ TD 誤差の絶対値が小さくなるという強化学習の性質を利用したもので、フィードバック制御器である Actor の学習が進んでいない状況では IDM にあまり学習をさせないようにするためである。そして、Actor の学習が進みフィードバック制御器として働くようになるにつれ、徐々に IDM の方も学習されていくようにする。

次に Actor-Critic と IDM のネットワークの実装について述べる。

2.1 Actor-Critic

Actor-Critic 法は、強化学習における TD 誤差学習の一つの方式であり、Critic と呼ばれる状態評価関数と Actor と呼ばれる行動生成関数からなる。Critic は入力された状態がどれだけ望ましいかを表す状態評価値を出力し、Actor は現在の方策に従った行動を出力する。本研究では、Actor と Critic に入力される状態は軌道誤差 θ^e であり、これが連続値をとるため、Actor と Critic のネットワークを NGnet (Normalized Gaussian network) を用いて以下のように構成する [11]。

Critic の出力である状態評価値 $V(\theta^e(t))$ は、

$$V(\theta^e(t)) = \sum_{i=1}^N v_i b_i(\theta^e(t)) \quad (1)$$

と表される。一方、 j 番目の筋への Actor の制御出力 $u_j^{fb}(t)$ は、

$$u_j^{fb}(t) = g \left(\sum_{i=1}^N w_{ji} b_i(\theta^e(t)) + \sigma n_j(t) \right) \quad (2)$$

と表される．ただし， N は基底関数の数， v_i ， w_{ji} は重み， $b_i()$ は基底関数である．また，関数 $g()$ にはシグモイド関数を用いる． $\sigma n_j(t)$ は制御出力を探索するためのノイズであり， $n_j(t)$ は標準正規乱数により生成される． σ はノイズの大きさであり，次式のように与える．

$$\sigma = \sigma_0 \exp\left(-\frac{V(\theta^e(t))}{s_n}\right) \quad (3)$$

ただし， σ_0 ， s_n は適当な定数である．

また，それぞれの重みの更新は，連続状態に拡張された TD 誤差 $\delta(t)$ を用いて [12]，

$$\dot{v}_i = \beta_c \delta(t) e_i(t) \quad (4)$$

$$\dot{w}_{ji} = \beta_a \delta(t) \sigma n_j(t) b_i(\theta^e(t)) \quad (5)$$

とする．ただし， β_c ， β_a は学習係数， $e_i(t)$ は eligibility trace である [11]．

2.2 逆ダイナミクスモデル

逆ダイナミクスモデル (IDM) への入力は，目標軌道 θ^d となり，連続値をとる．そこで，IDM のネットワークも Actor-Critic と同様，NGnet (Normalized Gaussian network) を用いる．

ある時刻 t において目標軌道 $\theta^d(t)$ が入力されると， j 番目の筋へのフィードフォワード運動指令が

$$u_j^{ff}(t) = g\left(\sum_{i=1}^N q_{ji} b_i(\theta^e(t))\right) \quad (6)$$

のように出力される．ただし， N は基底関数の数， q_{ji} は重み， $b_i()$ は基底関数である．

重み q_{ji} の更新式は

$$\dot{q}_{ji} = \alpha u_j^{fb}(t) b_i(\theta^e(t)) \quad (7)$$

となる． α は Actor-Critic の TD 誤差により定まる学習係数であり，次式で表される．

$$\alpha = \alpha_0 \exp\left(-\frac{\hat{\delta}^2}{s_{lr}^2}\right) \quad (8)$$

ただし， $\hat{\delta}$ は 1 回前の試行中の各時刻 t における TD 誤差 $\delta(t)$ の絶対値の平均であり， α_0 ， s_{lr} は適当な定数である．

3. シミュレーション

提案学習モデルの有効性を確かめるため，鉛直平面内における姿勢保持運動を計算機上で学習させた．こ

Muscle

sh flx : shoulder flexor
sh ext : shoulder extensor
el flx : elbow flexor
el ext : elbow extensor
dj flx : double joint flexor
dj ext : double joint extensor




図 3 二関節六筋の腕モデル

Fig. 3 Arm's model of 2-joints 6-muscles.

こで姿勢保持運動をタスクとして取り上げたのは，姿勢保持に関する技能が到達運動や接触運動などのすべての運動の基本となると考えたためである．更に，4. において，姿勢保持のために獲得された制御器が到達運動の制御にどのような意味をもつのかを議論するためである．

3.1 腕のモデル

制御対象となる腕のモデルについて説明する．本研究では，図 3 のような肩，肘の二つの関節とそれに作用する六つの筋からなるモデルを用いる．

個々の筋のモデルは，筋張力が筋の長さや収縮速度に依存するということを考慮して次のように定める．ある筋 j への運動指令 u_j に対する筋張力 T_j は，

$$T_j = \left(k_0^{(j)} + k_1^{(j)} u_j\right) \left(l_0^{(j)} + l_1^{(j)} u_j - \sum_k a_{jk} \theta_k\right) - \left(b_0^{(j)} + b_1^{(j)} u_j\right) \left(\sum_k a_{jk} \dot{\theta}_k\right) \quad (9)$$

となる．ただし， $k_0^{(j)}$ ， $k_1^{(j)}$ は筋 j の弾性に関する係数， $b_0^{(j)}$ ， $b_1^{(j)}$ は粘性に関する係数， $l_0^{(j)}$ ， $l_1^{(j)}$ は筋の長さに関する係数である．これらの係数は，筋骨格系のデータに基づいて構築された腕の順ダイナミクスモデル [13] を参考として，タスクが行える十分な範囲内で定めた．また a_{jk} は筋 j の関節 k に関するモーメントアームである．

関節 k のトルク τ_k は，

$$\tau_k = \sum_j a_{jk} T_j \quad (10)$$

となる．

また，システムは，腕を二リンクの剛体と考え，ラ

グランジュの運動方程式を用いて表現する (付録参照)。

3.2 問題設定

シミュレーションのタスクとして、鉛直平面内における腕の姿勢保持を取り上げる。ある目標位置に手先を保持するための各筋への運動指令を学習させる。ただし、鉛直平面内では、手先位置を決定するとそれに対応する肩、肘の関節角度は一意に定まるため、本研究では、目標位置を実現する目標関節角度を直接与えることにする。状態空間は、肩、肘のそれぞれに関する関節角度、関節角速度を考え、実現軌道 $\theta = (\theta_S, \theta_E, \dot{\theta}_S, \dot{\theta}_E)^T$ 、目標軌道 $\theta^d = (\theta_S^d, \theta_E^d, \dot{\theta}_S^d, \dot{\theta}_E^d)^T$ 、軌道誤差 $\theta^e = (\theta_S^e, \theta_E^e, \dot{\theta}_S^e, \dot{\theta}_E^e)^T$ とした。ただし、下添字 S, E はそれぞれ肩、肘に関するという意味である。

ここで、提案学習モデル (図 2) の逆ダイナミクスモデル (IDM) に入力される目標軌道 θ^d に関して考えてみる。タスクの目的は、手先の目標位置から定まる関節角度を保持することであるため、目標軌道 θ^d の関節角速度に関する要素 $\dot{\theta}_S^d, \dot{\theta}_E^d$ は常に 0 を与えることとする。したがって、実際にこの部分で解かれている問題は、腕の逆ダイナミクスの中でも、静的な釣り合い関係である「逆スタティックス (静力学)」である。そこで、関節角速度、角加速度も含めた意味での逆ダイナミクスと区別するために、以後この部分を逆スタティックスモデル (以下 ISM と略: Inverse Statics Model) と呼ぶことにする。

逆スタティックスモデル (ISM) には目標軌道 θ^d が入力され、式 (6) に従いフィードフォワード運動指令 u^{ff} が 0 から 1 の範囲で出力される。一方、Actor-Critic には軌道誤差 θ^e が入力され、式 (2) に -0.5 を加えて -0.5 から 0.5 の範囲でフィードバック運動指令 u^{fb} が出力される。 u^{fb} をこの範囲で出力させたのは、ISM が大きな運動指令を出して筋が力を出しすぎている場合、力を抜くようにできるためである。

腕への入力 u は、 $u = u^{ff} + u^{fb}$ となるが、もしこれが 0 以下のときは 0 に、1 以上のときは 1 とし、0 から 1 の範囲の値をとるように定める。

3.3 報酬

Actor-Critic に与えられる報酬に関して説明する。タスクの目的は、手先をある位置に保持することである。そこで手先の位置に関する報酬 r_p を次式のように定める。

$$r_p(t) = 2k_p \left(\exp \left(-\frac{d(t)^2}{s_r^2} \right) - 0.5 \right) \quad (11)$$

ただし、 $d(t)$ は目標の手先位置と時刻 t における手先位置との距離であり、 k_p, s_r は適当な定数である。この式により、手先の位置が目標に近いほどより大きな報酬が与えられる。

また学習の進行とともに制御がフィードバックからフィードフォワードに移行していくためには、目標位置において Actor のフィードバック運動指令 u^{fb} が 0 となる必要がある。そこで以下のような u^{fb} の 2 乗に比例した負の報酬 r_{u_actor} を追加する。

$$r_{u_actor} = k_{u_actor} \sum_{j=1}^6 u_j^{fb}(t)^2 \quad (12)$$

ただし、 k_{u_actor} は係数である。

以上をまとめると、Actor-Critic への全体的な報酬 r は次のようになる。

$$r(t) = r_p(t) - r_{u_actor}(t) \quad (13)$$

3.4 学習条件

シミュレーションにおける実現軌道 θ の範囲を、 $-105 \leq \theta_S \leq 30$ [deg], $0 \leq \theta_E \leq 135$ [deg], $-900 \leq \dot{\theta}_S, \dot{\theta}_E \leq 900$ [deg/s], とする。また目標軌道 θ^d の範囲は $-90 \leq \theta_S^d \leq -30$ [deg], $30 \leq \theta_E^d \leq 90$ [deg], $\dot{\theta}_S^d = \dot{\theta}_E^d = 0$ [deg/s], とする。ただし、関節角度の基準を、肩に関しては上腕を水平にした状態を $\theta_S = 0$ 、肘に関しては上腕と前腕を一直線にした状態を $\theta_E = 0$ とし、関節が曲がる方向を正、伸びる方向を負とした。

試行の最初に、目標軌道 θ^d を範囲内からランダムに決定し、試行中は θ^d は一定とする。初期軌道 $\theta(0)$ は、目標軌道と同様の範囲内からランダムに与える。試行開始から 2 秒経過するか、実現軌道 θ が範囲外になった時点で 1 回の試行を終了する。また、ダイナミクスの計算、運動指令の更新はともに 0.01 秒ごとに行い、学習も同様の周期で行う。

学習モデルの各パラメータは、学習係数 $\beta_c = 0.3$, $\beta_a = 0.3$, Actor の探索に関する定数 $\sigma_0 = 1.0$, $s_n = 5.0$, ISM の学習係数に関する定数 $\alpha_0 = 0.02$, $s_{lr} = 0.1$ とした。また、報酬に関する各パラメータは、 $k_p = 1.0$, $s_r = 0.1$, $k_{u_actor} = 0.1$ とした。

3.5 結果

3.5.1 学習経過

30000 回の試行を行った際の学習経過を図 4 に示す。グラフの横軸は試行数、縦軸は上から、各試行中の平均獲得報酬、各試行中の平均手先誤差 (cm)、各試行における ISM の出力、各試行終了時の Actor 制




図 4 学習経過：平均獲得報酬，平均手先誤差，ISM の出力，目標位置における Actor の出力

Fig. 4 Learning result: Avg of reward, Avg of hand position's error, ISM's output, Actor's output in desired position.

御器に $\theta^e = 0$ を入力したときの出力である。ただし、それぞれのグラフには 100 試行分の移動平均をプロットした。図より、試行数が増えるにつれて、手先を目標位置に保てるようになり、獲得できる報酬も最大値に近づいていき、タスクの目的を達成できていることが分かる。また、ISM と Actor の両制御器の学習経過が分かる。まず、Actor が重力を保障するための運動指令を学習している。Actor の学習が進行し、ある程度の報酬が得られるようになった 5000 試行目あたりから ISM の出力も変化し始め、20000 試行を過ぎたあたりからは Actor の出力は小さくなり ISM が制御の中心になっていることが分かる。

3.5.2 獲得された制御方法

試行回数の増加とともに、制御方法がどのように変化しているかを検証するため、5000, 10000, 22500 試行後に獲得された Actor と ISM を用いて姿勢保持運動を行った。その結果を図 5 に示す。図中、(a) が 5000 試行後、(b) が 10000 試行後、(c) が 22500 試行後に関する結果である。グラフの横軸はいずれも時間 (sec) であり、縦軸はそれぞれ上から、手先誤差 (cm)、ISM の出力、Actor の出力である。ただし、いずれも腕の初期軌道、目標軌道ともに $(-60, 60, 0, 0)$ とした。

図より、(a), (b), (c) のいずれの試行においても目標位置の近くに手先を保持できていることが分かる。一方、目標位置付近における制御方法がそれぞれの試行によって大きく異なることが見て取れる。まず、(a) では Actor の出力の絶対値は大きな値をとり、Actor




図 5 姿勢保持運動の結果：手先誤差，ISM の出力，Actor の出力

Fig. 5 Posture control: Hand position's error, ISM's output, Actor's output.




図 6 フィードフォワード制御による手先位置誤差

Fig. 6 Hand position's error by feedforward control.

が主体となった制御が行われていることが分かる。次に、(b) では ISM の出力のばらつきが (a) に比べて大きくなっており、また、Actor の出力は正負の反転を繰り返した大きな値をとっている。このことから、(b) では ISM のみである程度手先を目標位置付近に保てるが、より精度を上げるために Actor がゲインを大きくしたフィードバック制御を行っているものと思われる。最後に (c) では、Actor の出力は 0 に近い値をとり、ISM が主体となって手先を目標位置に保持できていることが分かる。

3.5.3 ISM のみを用いた姿勢保持

学習によって獲得された ISM のみを用いて姿勢保持運動を行い、フィードフォワード制御が可能かどうかを検証した。図 6 は、9 個所の目標位置に対して、

22500 試行後に獲得された ISM のみを用いて 5 秒間制御を行った後の手先位置を示したグラフである。“*”が 9 個所の目標位置，“o”印がそれぞれの目標位置に対する 5 秒後の手先位置である。ただし、横軸を水平方向、縦軸を鉛直方向とし、肩の位置を原点にとった。また、手先位置誤差の目安として、それぞれの目標位置“*”を中心とした半径 3 cm の円を点線で示した。図 6 より、どの目標位置に対しても、3 cm 以内に手先が保持されており、ISM のみを用いて精度良く制御できていることが分かる。したがって、提案学習モデルによって、タスクを達成するためのフィードフォワード運動指令がほぼ正確に獲得できたといえる。

4. 考 察

4.1 提案学習モデルの性能評価

本研究で提案した運動学習モデルの性能を評価するため、従来の研究 [4], [5] で用いられてきた、あらかじめゲインを調節したフィードバック制御器を用いたフィードバック誤差学習との性能比較実験を行った。

提案学習モデルは、フィードバック誤差学習の枠組みの中の一つのモデルといえる。したがって、その目的は従来の研究で用いられてきたものと同様、制御対象の逆ダイナミクスや逆スタティックスなどの逆システムを学習することである。そこで本節では、既知の制御対象に関する逆スタティックスモデルを最終的にどれだけ正確に学習できるかで、二つの学習モデルの性能を比較する。比較対象となる学習モデルには、最適レギュレータ問題を解くことによって設計されたフィードバック制御器を用いたフィードバック誤差学習を取り上げた。以後簡単のため、この学習モデルを「学習モデル 1」、提案学習モデルを「学習モデル 2」と呼ぶこととする。

4.1.1 問題設定

シミュレーションのタスクとして、3. と同様に鉛直平面内における腕の姿勢保持を取り上げる。ただし、腕を 6 個の筋への運動指令で制御すると、運動指令と関節トルクとの間に非線形性や冗長性が存在するため、最適レギュレータ問題を解くことができない。そこで、今回のシミュレーションでは、腕を直接関節トルクで制御し、手先を目標位置に保持するための関節トルクを学習させることにする。

4.1.2 二つの学習モデル

学習モデル 1, 学習モデル 2 とともにフィードバック誤差学習の枠組みの中の一つのモデルであるが、フィー

ドバック制御器の設計に違いがある。ここでは、それぞれのフィードバック制御器に関する説明をする。

(a) PD 制御器

学習モデル 1 で用いられるフィードバック制御器には、最適レギュレータ問題を解くことによって設計された PD 制御器を用いる。状態フィードバックゲインの設定は、腕の運動方程式（付録参照）を $\theta_S = -60$ [deg], $\theta_E = 60$ [deg], $\dot{\theta}_S = \dot{\theta}_E = 0$ [deg/s] の近傍で線形化し、二次形式評価関数 J を以下のように与え、リカッチ代数方程式を解くことによって求めた [14]。

$$J = \int_0^\infty \left(\theta^e T(t) Q \theta^e(t) + \tau^{fb T}(t) R \tau^{fb}(t) \right) dt \quad (14)$$

ただし、

$$Q = \begin{pmatrix} 3 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}, R = \begin{pmatrix} 3.3 & 0 \\ 0 & 3.3 \end{pmatrix} \times 10^{-5}$$

とした。PD 制御器からの関節 j への制御出力 τ_j^{fb} は、タスクを行うのに十分な関節トルク $\pm \tau_j^{max}$ の範囲内になるように以下のように設定した。

$$\tau_j^{fb}(t) = 2\tau_j^{max} \left(g \left(\frac{2\hat{\tau}_j^{fb}(t)}{\tau_j^{max}} \right) - 0.5 \right) \quad (15)$$

$$\begin{aligned} \hat{\tau}_j^{fb}(t) &= K_{jS}^P \theta_S^e(t) + K_{jE}^P \theta_E^e(t) \\ &\quad + K_{jS}^D \dot{\theta}_S^e(t) + K_{jE}^D \dot{\theta}_E^e(t) \end{aligned} \quad (16)$$

ただし、関数 $g()$ はシグモイド関数であり、 K_{jS}^P , K_{jE}^P , K_{jS}^D , K_{jE}^D は状態フィードバックゲインである。

(b) Actor

学習モデル 2 は本研究における提案学習モデルであり、図 2 のように Actor-Critic 法の Actor 制御部をフィードバック制御器として用いる。Actor からの関節 j への制御出力 τ_j^{fb} は、

$$\begin{aligned} \tau_j^{fb}(t) &= 2\tau_j^{max} \left(g \left(\sum_{i=1}^N w_{ji} b_i(\theta^e(t)) + \sigma n_j(t) \right) - 0.5 \right) \end{aligned} \quad (17)$$

のように定め、学習モデル 1 と同様、 $\pm \tau_j^{max}$ の範囲内の値をとるようにした。また、Actor-Critic の学習に用いられる報酬 $r(t)$ は以下のように与えた。

$$r(t) = -\left(\theta^{eT}(t)Q\theta^e(t) + \tau^{fbT}(t)R\tau^{fb}(t)\right) + 1 \quad (18)$$

ただし、 Q と R は学習モデル 1 の評価関数と同様の値を用いた。ここで、強化学習の目的は報酬の累積を最大化する制御方法を獲得することなので、式 (14) と式 (18) は同様の評価を意味している。また、これらの値は、前章のシミュレーションにおける報酬と同様の傾向をもつように設定した。

4.1.3 逆スタティックスモデル

腕をある目標角度 θ_S^d , θ_E^d に保つための静的な関節トルク τ は、腕の運動方程式 (付録参照) における関節角度に θ_S^d , θ_E^d , また関節角速度, 角加速度に 0 を代入することにより以下のように求まる。

$$\begin{aligned} \tau_S &= (m_1 \hat{g} l_{g1} + m_2 \hat{g} l_1) \cos \theta_S^d \\ &\quad + m_2 \hat{g} l_{g2} \cos(\theta_S^d + \theta_E^d) \\ \tau_E &= m_2 \hat{g} l_{g2} \cos(\theta_S^d + \theta_E^d) \end{aligned} \quad (19)$$

上の式の右辺は、目標角度 θ_S^d , θ_E^d に関する三角関数と、腕の各種パラメータの積からなる係数との線形和によって表される。そこで、今回のシミュレーションでは、獲得された ISM の比較を容易にするため、ISM のネットワーク構造を図 7 のように設定した。図中の関数 f_1 , f_2 は式 (19) に合わせて、 $f_1 = \cos(\theta_S^d)$, $f_2 = \cos(\theta_S^d + \theta_E^d)$ とした。ISM から関節 j への出力 τ_j^{ff} は、

$$\tau_j^{ff} = \sum_{i=1}^2 w_{ij} f_i \quad (20)$$

となる。したがって、ネットワークの重み w_{ij} の理想的な値 $\hat{w}_{ij}$ は式 (19) より、

$$\begin{aligned} \hat{w}_{1S} &= m_1 \hat{g} l_{g1} + m_2 \hat{g} l_1 \\ \hat{w}_{1E} &= 0 \\ \hat{w}_{2S} &= \hat{w}_{2E} = m_2 \hat{g} l_{g2} \end{aligned} \quad (21)$$

であり、 w_{ij} がどれだけ $\hat{w}_{ij}$ に近づいたかによって、獲得された ISM の正確性を評価できる。

また、重み w_{ij} の更新は、フィードバック制御指令 τ_j^{fb} を教師信号として以下のように行う。

$$\dot{w}_{ij} = \alpha f_i \tau_j^{fb} \quad (22)$$

ここで、 α は学習係数であり、




図 7 ISM のネットワーク構成: 関数 $f_1 = \cos(\theta_S^d)$, $f_2 = \cos(\theta_S^d + \theta_E^d)$

Fig. 7 Network of ISM: Function $f_1 = \cos(\theta_S^d)$ and $f_2 = \cos(\theta_S^d + \theta_E^d)$.




図 8 重みの学習経過: 重みの値, 理想値との誤差の絶対値

Fig. 8 Learning result: Weight values, Absolute values of weight values' error.

$$\alpha = \begin{cases} \alpha_0 & : \text{学習モデル 1} \\ \alpha_0 \exp\left(-\frac{\delta^2}{s_{lr}^2}\right) & : \text{学習モデル 2} \end{cases} \quad (23)$$

のように設定した。ただし、 α_0 は適当な係数であり、学習モデル 1, 学習モデル 2 ともに同じ値を用いた。

4.1.4 学習条件

学習条件は 3. のシミュレーションと同様である。また、Actor-Critic 法における各パラメータは、学習係数 $\beta_c = 0.3$, $\beta_a = 0.3$, Actor の探索に関する定数 $\sigma_0 = 1.0$, $s_n = 0.05$ とした。ISM の学習に関するパラメータは、 $\alpha_0 = 0.0001$, $s_{lr} = 0.1$ とし、重み w_{ij} の初期値はすべて 0 とした。式 (15), (17) で用いられる最大トルクの値は、肩関節に関して $\tau_S^{max} = 60$ [Nm], 肘関節に関して $\tau_E^{max} = 30$ [Nm] とした。

4.1.5 学習結果

学習モデル 1, 及び学習モデル 2 を用いてシミュレーションを行った際の、ISM の重み w_{ij} の経過を図 8 に示す。それぞれ 50000 回の試行を行った結果である。図中、(a) が学習モデル 1, (b) が学習モデル 2 を用いたシミュレーションに関する結果である。グラフの横

軸はいずれも試行数であり、縦軸はそれぞれ上から、重み w_{ij} の値、式 (21) で表される理想の重み $\hat{w}_{ij}$ と w_{ij} との誤差の絶対値である。ただし、それぞれのグラフには 100 試行分の移動平均をプロットした。また、上のグラフには理想の重み $\hat{w}_{ij}$ を点線で示した。図 8 より、(a) では、すべての重みが 5000 試行目までに ± 0.1 以下の誤差で理想の重みに収束していることが分かる。一方、(b) では、すべての重みが理想の重み付近に収束するまでに 50000 試行ほどかかっている。しかし、その誤差は (a) よりやや劣るものの、最終的に ± 0.1 以下となり、精度良く学習されていることが分かる。実際に、729 パターンの目標姿勢を二つの学習モデルによって最終的に獲得された ISM に入力して、それに対する出力と、式 (19) によって計算される理想値との相関係数をそれぞれ求めたところ、両者ともに τ_S^{ff} , τ_E^{ff} に関して 1.0000, 0.9999 となった。したがって、学習モデル 1 と学習モデル 2 によって最終的に獲得された ISM の精度は、同程度といえる。

4.1.6 ま と め

提案学習モデルの性能を評価するため、従来の研究で用いられてきたフィードバック誤差学習との比較シミュレーション実験を行った。その結果、学習により多くの時間がかかるものの、従来のものと同程度の精度で制御対象の逆スタティクスモデルが獲得できることを確かめた。

提案学習モデルでは、フィードバック制御器として Actor-Critic 法における Actor 制御部を用いている。そのため、逆システムを学習するために、まず教師信号を生成する Actor 制御部を試行錯誤を通じて学習する必要がある。したがって、あらかじめ評価関数を最小化するように設計された PD 制御器などを用いる場合と比べて時間がかかってしまう。しかし、最終的に獲得されたものは同等の精度をもつことから、提案学習モデルには、人間の腕のような複雑な特性をもつ制御対象の逆システムを正確に学習できる能力があると思われる。また、フィードバック制御器が Actor-Critic 法によって自立的に獲得できるため、環境や制御対象の特性が大きく変化した場合にも自立的に対応できるという特徴を有している。

4.2 二点間到達運動

ここでは、姿勢保持運動のために獲得された制御方法を用いて、鉛直平面内における二点間到達運動を計算機上でシミュレートし、その運動の結果と実際に人間が行った運動の結果を比較する。また、終端位置制

御仮説に関する議論を行う。このことを通じて、腕の運動制御モデルに関する考察を行う。

腕の二点間到達運動は古くから研究が行われている随意運動であり、手先の軌道がほぼ直線となることや、手先の速度波形は bell-shape と呼ばれる一つだけピークをもつ形状になるといった普遍的特徴が知られている [2]。また、Polit と Bizzi [1] が行った研究などから、我々はフィードフォワードに二点間到達運動を行えることが確かめられてきた。そして、最近では、この二点間到達運動のフィードフォワード制御を説明するいくつかの計算論的なモデルが提案され、多くの議論が展開されている。

4.2.1 フィードフォワード制御の実現

3. で行った二関節六筋の腕モデルを用いた姿勢保持運動の学習シミュレーションにより獲得された、逆スタティクスモデル (ISM) と Actor を用いてフィードフォワードに二点間到達運動を実現する制御モデルを構築する。ここで、Actor はフィードバック制御器であるため、目標軌道と実現軌道との誤差が入力されなければならない。しかし、実現軌道をフィードバック情報として直接観測しては、後述する Bizzi ら [16] が行った実験の結果が説明できない。この問題を解決するため、本項では、実現軌道を順ダイナミクスモデル (以下 FDM と略: Forward Dynamics Model) によって予測し、Actor に入力される軌道誤差を、目標軌道と FDM による予測軌道の差から求めることにする。FDM とは、制御対象と同じ入出力関係をもつシステムであり、現在の状態と運動指令から次の時刻の状態を計算する。本来なら、この FDM も環境との相互作用を通じて学習される必要がある。しかし、FDM の学習は ISM や Actor の学習と違い、理想的な解を観測によって得られる教師あり学習である。そのため、ISM や Actor と比べると FDM は比較的学習しやすいと思われる。そこでここでは、あらかじめ正確な FDM が学習されているとして、ISM, Actor, そして FDM を組み合わせた制御モデルを図 9 のように構築した。図中の $\hat{\theta}$ は FDM から求められる予測軌道、 $\hat{\theta}^e$ は目標軌道と予測軌道の誤差である。ここで、図 9 には観測によって得られる求心性の状態フィードバック信号が含まれていない。本来、求心性の信号は時間遅れを伴って脳へとフィードバックされる。しかし近年、Smith 予測器の枠組みに従って、外乱がなく、かつ FDM が正確なとき、求心性の信号が FDM で予測された状態によりキャンセルされるといったモデ




図 9 ISM, FDM, Actor を組み合わせたフィードフォワード制御モデル

Fig. 9 Feedforward control model with ISM, FDM, and Actor.




図 10 二点間到達運動の手先軌道

Fig. 10 Hand trajectories during reaching movements.

ルが提案されている [17]. 本節における計算機シミュレーションでは、外乱がなくまた FDM が正確であると仮定しているため、Smith 予測器の枠組みに従うと求心性の信号はすべてキャンセルされる。そこで、図 9 には求心性のフィードバック信号は記載しないこととする。

実際に、被験者が行った鉛直平面内のいくつかの二点間到達運動と、図 9 の制御モデルを用いて計算機上でこの運動を再現した結果を図 10 に示す。図中、実線が被験者、点線が計算機上のシミュレーション結果である。ただし、被験者の運動は三次元位置計測装置 (OPTOTRAK 3020, NDI) によって計測した。また、制御モデルには、被験者が行った運動の始点と終点の手先位置を実現する関節角度をそれぞれ初期角度、目標角度として与えた。図より、ほとんどの運動に対して、シミュレーションによって実際の人間の軌道をよく再現できていることが分かる。

4.2.2 終端位置制御仮説の検証

腕の筋にある一定の運動指令を入力し続けると、腕

は筋の特性により重力と釣り合う姿勢（平衡位置）に落ち着く。この平衡位置は、1980 年代以降、筋肉骨格系の制御に関する軌道計画や運動制御モデルの議論において中心的な話題となってきた。Bizzi らは二点間到達運動のフィードフォワード制御を説明するモデルとして、運動の終点を平衡位置とする運動指令を終始出し続ける制御方法を終端位置制御仮説として提案した [15]。この仮説では、始点と終点を結ぶ軌道を計画する必要がなく、非常に単純な制御方法によって到達運動が説明できる。本研究でも、学習シミュレーションにより獲得された ISM を用いることにより、終点における姿勢で重力と釣り合う運動指令が求められるので、終端位置制御仮説のような制御によって到達運動が可能となる。しかし、同じく Bizzi らがサルを用いて行った実験によって、終点だけでなく運動の途中の軌道も計画されていることが示された [16]。彼らはサルを訓練して、ターゲットが目前に提示されるとそれに向かって到達運動を行えるようにした後、そのサルの求心性神経を切断した。そして、ターゲットしか見えない暗室で到達運動を行わせた。その際、ターゲットを提示する前にあらかじめサルの手先を強制的にターゲットの位置に移動させ、ターゲット提示後もしばらくサルの手を強制的にその位置に維持した。その後、サルの手を解放して手先が描く軌道を計測した。もし、サルが終端位置制御仮説に基づいた制御を行っているのであれば、サルの手は解放後もターゲットの位置にとどまるはずであるが、手先は到達運動の始点の方向に一度向かった後、ターゲットの位置に戻った。この結果から彼らは、サルが到達運動の始点から終点を結ぶ目標軌道を計画しており、手先が解放された後はその軌道に戻るように腕が動いたと考えた。

この見解は、サルがフィードフォワード制御を、平衡位置を制御する ISM のような制御器のみを用いて行っていると考えると正しいように思われる。しかし、サルが図 9 のように ISM とともに、FDM と組み合わせたフィードバック制御器を制御に用いていると考えるとどうであろうか。例えば、サルは FDM によって自らが描く軌道を予測し、その予測軌道と目標軌道との誤差に従いフィードバック制御器の出力を計算し、ISM の出力とともに制御に用いているとする。FDM の予測の中で自らの手が終点に近づくと、サルは手を止めようとして、フィードバック制御器により自らの手が動いてきた（動いてきたと思っている）方向と逆方向に加速度を生じさせる。もし、この加速度が負に




図 11 Bizzzi が行った実験に関するシミュレーションの手先軌道: $t = 0$ においてターゲットを表示, $t = 0$ から $t = 0.16$ まで手を強制的に目標位置に固定, $t = 0.16$ において手を解放

Fig. 11 Hand trajectory during the simulation of the Bizzzi's experiment: At $t = 0$, display the target. From $t = 0$ to $t = 0.16$, hold the hand in the target position. At $t = 0.16$, release the hand.

なった瞬間に、それまで強制的にターゲットに維持していた手を解放したら、おそらく手先は始点の方向に一度戻るであろう。このように考えると、図 9 のような ISM, FDM, フィードバック制御器を用いたフィードフォワード制御によって、始点と終点の間の目標軌道を計画しなくても、終点の姿勢を目標として入力するだけで、Bizzzi らが行った実験の結果を説明できる。

このことを検証するため、図 9 の制御モデルを用いて、Bizzzi らが行った実験を計算機上でシミュレートした。ただし、Bizzzi らが行った実験と違い、到達運動は、水平面内ではなく鉛直平面内で、また単関節ではなく二関節で行った。このシミュレーションでは、時刻 $t = 0$ [s] においてターゲットを提示（目標軌道として終点における姿勢を入力）し、 $t = 0$ から $t = 0.16$ [s] までの間手先をターゲットの位置に固定（実現軌道を終点における姿勢に固定）する。そして、 $t = 0.16$ [s] で手を解放（実現軌道を腕のダイナミクスに従い更新）する。その時の手先の軌道を図 11 に示す。図より、手が解放された直後 ($t = 0.16$ [s]) から、手先は到達運動の始点の方向に一度戻っていることが分かる。この到達運動中、制御モデルへの目標軌道 θ^d には、到達運動の終点における腕の姿勢が終始入力されている。つまり、FDM と組み合わせたフィードバック制御器を制御モデルに含めることにより、始点と終点の間の目標軌道を計画していなくても、Bizzzi らが

実験で得た、手先が一度始点の方向に向かった後に終点に戻るといった結果が再現できることが分かる。もちろん、シミュレーション結果と実験結果では、運動時間や目標位置への手先の到達の仕方が異なっているなどのことから、到達運動において目標軌道は計画されていないとはいえない。しかし、少なくとも、生体のフィードフォワード制御機構を議論するのに、FDM と組み合わせさせたフィードバック制御器の存在を無視することはできないと思われる。また、そのときに用いられるフィードバック制御器は、あらかじめ適当にゲインを調節した PID 制御器などではなく、Actor-Critic 法などのように脳の中で行われている可能性の高い学習方法によって獲得されたものを用いるのが望ましいだろう。

4.2.3 ま と め

本項では、姿勢保持のために獲得された ISM と Actor に FDM を組み合わせることにより、鉛直平面内の二点間到達運動をフィードフォワードに制御するモデルを構築した。そして、実際に人間が行った二点間到達運動と、制御モデルを用いた計算機上の二点間到達運動の結果を比較することにより、始点と終点を結ぶ目標軌道を計画しなくても、手先軌道の特徴が再現できることを示した。また、同様に目標軌道を計画しなくても Bizzzi らが行った実験 [16] の結果を再現できる可能性を示し、フィードフォワード制御を議論する際、FDM と Actor-Critic 法などによって獲得されたフィードバック制御器の存在が無視できないことを確かめた。

5. む す び

本研究では、フィードバック誤差学習と Actor-Critic 法を組み合わせ、制御対象の逆システムだけでなく、フィードバック制御器も環境との相互作用を通じて学習される運動学習モデルを構築した。そして、この学習モデルを鉛直平面内における腕の姿勢保持タスクに適用し、冗長で非線形な特性をもつ二関節六筋モデルに対して、報酬というスカラ量のみから、フィードバック制御器と腕の姿勢保持をフィードフォワードに制御する逆スタティクスモデルが同時に獲得できることを示した。また、提案学習モデルの性能を評価するため、従来の研究で用いられてきたフィードバック誤差学習との性能比較シミュレーション実験を行い、それと同程度の精度で姿勢保持のための逆スタティクスモデルが学習できることを確かめた。更に、姿勢

保持のために獲得された逆スタティックスモデルと、フィードバック制御器である Actor 制御部に、順ダイナミックスモデルを組み合わせた制御モデルを構築し、鉛直平面内の二点間到達運動を計算機上でを行い、実際の人間の二点間到達運動との比較を行った。その結果、この制御モデルによって到達運動における手先軌道の特徴が再現できることが確かめられた。また、これまで始点と終点を結ぶ目標軌道を計画していないと説明できなかった実験結果が、この制御モデルを用いることによって目標軌道を計画しなくても再現できることを示した。

最後に、本研究では提案学習モデルにより逆スタティックスモデルを獲得した。一方、目標軌道に関節角度だけでなく、角速度、角加速度を含めることにより逆ダイナミックスモデルを獲得できることが、我々が行った学習シミュレーション実験によって確かめられている。しかし、脳が運動を行う際に目標軌道を計画し逆ダイナミックスモデルを用いて制御を行っているかどうかについては、いまだ議論が続いている。今後、どのようなレベルの運動制御に身体逆ダイナミックスモデルが必要なのかを検証するため、提案学習モデルを様々なタスクに適用していきたい。

謝辞 この研究の一部は、独立行政法人科学技術振興機構さがけ「協調と制御」研究領域、及び CREST「脳の機能発達と学習メカニズムの解明」研究領域の助成によるものであり、ここに改めて敬意を表する。

文 献

- [1] A. Polit and E. Bizzi, "Characteristics of motor programs underlying arm movements in monkeys," *J. Neurophysiology*, vol.42, pp.183–194, 1979.
- [2] 川人光男, 脳の計算理論, 産業図書, 1996.
- [3] M. Kawato, K. Furukawa, and R. Suzuki, "A hierarchical neural-network model for control and learning of voluntary movement," *Biological Cybern.*, vol.57, pp.169–185, 1987.
- [4] 加納 誠, 川人光男, "フィードバック誤差学習による冗長腕の学習軌道制御," 信学技報, NC89-61, 1990.
- [5] 片山正純, 川人光男, "筋肉・骨格系の運動制御を行う並列階層制御神経回路モデル," 信学論 (D-II), vol.J73-D-II, no.8, pp.1328–1335, Aug. 1990.
- [6] R.S. Sutton and A.G. Barto, *Reinforcement Learning*, MIT Press, Cambridge, MA, 1998.
- [7] A.G. Barto, "Adaptive critics and the basal ganglia," in *Model of information processing in the basal ganglia*, ed., J.C. Houk, J.L. Davis and D.G. Beiser, pp.215–232, MIT Press, 1995.
- [8] 井澤 淳, 近藤俊之, 伊藤宏司, "状態予測機構を用いた強化学習による運動学習モデル," 計測自動制御学会論文

集, vol.39, no.7, pp.679–687, 2003.

- [9] K. Doya, "What are the computations of the cerebellum, the basal ganglia and the cerebral cortex?," *Neural Netw.*, vol.12, pp.961–974, 1999.
- [10] M. Katayama, *A computational understanding of motor learning control using neural internal models for A multi-joint arm*, PhD Thesis, University of Tokyo, 1993.
- [11] 森本 純, 銅谷賢治, "強化学習を用いた高次元連続状態空間における系列運動学習—起き上がり運動の獲得," 信学論 (D-II), vol.J82-D-II, no.11, pp.2118–2131, Nov. 2001.
- [12] K. Doya, "Reinforcement learning in continuous time and space," *Neural Comput.*, vol.12, pp.219–245, 2000.
- [13] 関 庚甫, 小池康晴, "筋肉骨格データに基づく人腕の順動力学モデル," 信学技報, EID2002-36, 2002.
- [14] 井上和夫 (編), 川田昌克, 西岡勝博 (著), *MATLAB/Simulink によるわかりやすい制御工学*, 森北出版, 2001.
- [15] E. Bizzi, A. Polit, and P. Morasso, "Mechanism underlying achievement of final head position," *J. Neurophysiology*, vol.39, pp.435–444, 1976.
- [16] E. Bizzi, N. Accornero, W. Chapple, and N. Hogan, "Posture control and trajectory formation during arm movement," *J. Neuroscience*, vol.4, no.11, pp.2738–2744, 1984.
- [17] R.C. Miall, D.J. Weir, D.M. Wolpert, and J.F. Stein, "Is the cerebellum a smith predictor?," *J. Motor Behavior*, vol.25, pp.203–216, 1993.
- [18] 吉川恒夫, *ロボット制御基礎論, コンピュータ制御機械システムシリーズ*, コロナ社, 1988.

付 録

1. 腕の運動方程式とパラメータ

本研究では、図 A.1 に示す腕の運動方程式をラグランジュ法を用いて以下のように表現した [18].

$$\begin{aligned}
 \tau_S &= [I_1 + I_2 + m_2(l_1^2 + 2l_1l_{g2}\cos(\theta_E))] \ddot{\theta}_S \\
 &\quad + [(I_2 + m_2l_1l_{g2}\cos(\theta_E)) \ddot{\theta}_E \\
 &\quad - m_2l_1l_{g2}\sin(\theta_E)(2\dot{\theta}_S\dot{\theta}_E + \dot{\theta}_E^2) \\
 &\quad + (m_1\hat{g}l_{g1} + m_2\hat{g}l_1)\cos(\theta_S) \\
 &\quad + m_2\hat{g}l_{g2}\cos(\theta_S + \theta_E)] \\
 \tau_E &= [I_2 + m_2l_1l_{g2}\cos(\theta_E)] \ddot{\theta}_S + I_2\ddot{\theta}_E \\
 &\quad + m_2l_1l_{g2}\sin(\theta_E)\dot{\theta}_S^2 \\
 &\quad + m_2\hat{g}l_{g2}\cos(\theta_S + \theta_E) \quad (A.1)
 \end{aligned}$$

ここで、 τ_j , θ_j , $\dot{\theta}_j$, $\ddot{\theta}_j$, ($j = S, E$) は各関節のトルク, 関節角度, 関節角速度, 関節角加速度を表し, m_i , l_i , l_{gi} , I_i , ($i = 1, 2$) は腕の物理パラメータで各リンクの質量, 長さ, 関節から質量中心までの長さ, 関

節回りの慣性モーメントである。また、これらのパラメータの値は表 A・1 のように定めた [10]。

2. 筋のパラメータ

ここでは、本研究で用いた筋のパラメータの値を




図 A・1 二関節の腕
Fig. A・1 2 link arm.

表 A・1 腕のパラメータ
Table A・1 Arm parameter.

	Link 1	Link 2
m_i [kg]	1.59	1.44
l_i [m]	0.3	0.35
l_{gi} [m]	0.18	0.21
I_i [kgm ²]	6.78×10^{-2}	7.99×10^{-2}

表 A・2 モーメントアーム
Table A・2 Moment arm.

	Moment Arm [m]	
	Around Shoulder	Around Elbow
<i>sh flx</i>	0.04	0
<i>sh ext</i>	-0.04	0
<i>el flx</i>	0	0.025
<i>el ext</i>	0	-0.025
<i>dj flx</i>	0.028	0.028
<i>dj ext</i>	-0.035	-0.035

表 A・3 筋の弾性、粘性、長さに関するパラメータ
Table A・3 Muscle parameters.

	k_0 [N/m]	k_1 [N/m]	b_0 [Ns/m]	b_1 [Ns/m]
<i>sh flx</i>	1000	3000	50	100
<i>sh ext</i>	1000	2000	50	100
<i>el flx</i>	600	1400	50	100
<i>el ext</i>	600	1200	50	100
<i>dj flx</i>	300	600	50	100
<i>dj ext</i>	300	600	50	100

	l_0 [m]	l_1 [m]
<i>sh flx</i>	0.150	0.150
<i>sh ext</i>	0.055	0.150
<i>el flx</i>	0.100	0.150
<i>el ext</i>	0.040	0.150
<i>dj flx</i>	0.250	0.150
<i>dj ext</i>	0.130	0.150

示す。モーメントアームの値は表 A・2 のように定めた [10]。

また、筋の弾性、粘性、長さに関する係数を表 A・3 のように定めた。弾性、粘性に関する係数は、筋骨格系のデータに基づいて構築された腕の順ダイナミクスモデル [13] を参考として、タスクが行える十分な範囲内で定めた。一方、筋の長さに関する係数は、肩、肘の角度がシミュレーションで定めた範囲内において、筋張力が負にならないように定めた。

(平成 16 年 9 月 21 日受付, 8 月 17 日再受付)



神原 裕行 (学生会員)

2002 東工大・工・情報工学卒。2004 同大学院博士前期課程了。2005 年 9 月から UCSD, 現在, 同大学院博士後期課程在学中。



金 載侏

1999 韓国朝鮮大学大学院制御計測工学専攻修士課程了。同年東京工業大学知能システム科学専攻博士課程入学, 2003 同大学院博士課程了。同年同大学精密工学研究所の講師, 2005 Handong Global University 講師。



佐藤 誠 (正員)

1973 東工大・工・電子物理卒。1978 同大学院博士課程了。同年, 同大学院工学部助手, 現在, 同大学精密工学研究所教授。画像処理, ヒューマンインタフェースに関する研究に従事 (工博)。



小池 康晴 (正員)

1987 東工大・工・情報工学卒。1989 同大学院博士課程了。同年トヨタ自動車 (株) 入社, 1991 ATR 視聴覚機構研究所出向, 1992 ATR 人間情報通信研究所, 1998 東京工業大学精密工学研究所助教授, 2000～2003 科学技術振興機構 さきがけ 21 の兼任, 2003 から科学技術振興機構 CREST 分担者。ヒューマンインタフェース, 運動制御の神経回路網に関する研究に従事 (工博)。