

近接分離による分散凸最適化—交互方向乗数法に基づくアプローチを中心として—

小 野 峻 佑*

*東京工業大学 科学技術創成研究院 未来産業技術研究所
神奈川県横浜市緑区長津田町 4259 R2-59

*Laboratory for Future Interdisciplinary Research of Science and Technology (FIRST), Institute of Innovative Research (IIR), Tokyo Institute of Technology, R2-59, 4259 Nagatsuta-cho, Midori-ku, Yokohama, Kanagawa, Japan

*E-mail: ono@isl.titech.ac.jp

キーワード：分散最適化 (distributed optimization), 近接分離 (proximal splitting), 凸最適化 (convex optimization), 交互方向乗数法 (alternating direction method of multipliers, ADMM).

JL 0011/16/5511-0954 ©2016 SICE

1. まえがき

情報科学・工学を中心とした応用科学で立ち現れる問題の多くは数理最適化問題として定式化できる。特に、局所最適解が大域的最適解になることを保証しながら柔軟な問題設計を許容する凸最適化^{(1)~(3)}は、理論と応用の両者の観点から健全かつ重要な最適化問題のクラスとして不動の地位にあると言っても過言ではないだろう。制御・信号処理分野においても例外ではなく、これまでさまざまな問題が凸最適化問題に帰着され見通しよく解決されてきた^{(4)~(6)}。中でも、近年注目を浴びているのが、近接分離 (proximal splitting) に基づく凸最適化手法^{(7),(8)}である (以下、近接分離最適化と呼ぶ)。これは、近接写像と呼ばれる操作を基本骨子とした最適化アルゴリズム群を指し、代表的なものとして、近接勾配法 (proximal gradient method, forward-backward splitting method)^{(9)~(11)}、交互方向乗数法 (Alternating Direction Method of Multipliers, ADMM)^{(12),(13)}、主-双対近接分離法 (primal-dual splitting method)^{(14)~(16)}などが挙げられる^(注1)。近接分離最適化は、従来の凸最適化手法と異なり、微分不可能な目的関数や複数の制約条件を含む比較的大規模な問題を効率的に扱えるため、圧縮センシング、ロバスト統計、画像復元、機械学習など幅広い応用において中心的な役割を担っている。

一方、ビッグデータなどのタームに代表されるように、さまざまな分野において大量のデータを処理・解析しなければならない状況が急増している。これはそのまま最適化問題自体のさらなる大規模・高次元化が不可避であることを意味し、必然的にこのような問題に対処するための最適化アルゴリズムを要請する。これに応えるのが、分散最適化技術⁽²⁰⁾である。分散最適化では、仮想ネットワーク上に配置された各ノード (プロセッサ/エージェント) が協力してひとつの目的関数を最適化するというモデルを考える。具体的には、1. 各ノードがおののに割り当てられた局所的な目的関数 (元の目的関数の一部

に相当) に基づき局所的な変数を並列に更新する。2. その更新データをマスターノードが集約・反映する、という操作を繰り返すことで最適化を行う^(注2)。ゆえに、大規模な最適化問題を分散処理を介して効率的に解くことができる (マルチコアによる並列計算が代表的な実例として挙げられる。この際、各ノード=各 CPU コアとなる)。

このような背景のもと、近接分離最適化技術が分散最適化に応用・拡張されることは自然な流れであろう。実際に、前述した代表的な三種類のアルゴリズムの分散最適化応用が提案されているが、この中でも、交互方向乗数法に基づくアプローチがその拡張性・利便性から数多く研究されている。交互方向乗数法の分散最適化への応用可能性は Bertsekas&Tsitsiklis⁽²⁰⁾ によっていち早く示唆され、その後、無線センサネットワークの文脈を中心に多くの応用が提案された^{(21)~(24)}。Boyd らによる論文⁽²⁵⁾がマイルストーンとなって以降、さまざまな応用・アルゴリズム自体の拡張・収束解析など、関連研究の数は指数関数的に増えている (たとえば、文献 26)~35))。

以上を踏まえ、本稿では、交互方向乗数法に焦点を絞り、その分散最適化応用について解説する。まず次章で凸関数や近接写像などの基本的なツールを導入する。3章で交互方向乗数法の一般形および収束定理について紹介し、4章で一般的な分散最適化問題へ交互方向乗数法が自然な形で適用できることを示す。正則化最小二乗法を題材に具体的な応用例を5章で紹介し、最近提案されたより発展的な近接分離による分散最適化技術について6章で触れる。最後に7章で本稿をまとめる。

2. 準備

関数 $f: \mathbb{R}^N \rightarrow (-\infty, \infty]$ の実効定義域 $\text{dom}(f) := \{\mathbf{x} \in \mathbb{R}^N | f(\mathbf{x}) < \infty\}$ が空でなく、そのレベル集合 $\text{lev}_{\leq \alpha}(f) := \{\mathbf{x} \in \mathbb{R}^N | f(\mathbf{x}) \leq \alpha\}$ が任意の $\alpha \in \mathbb{R}$ について閉集合となり、かつすべての $\mathbf{x}, \mathbf{y} \in \mathbb{R}^N$ と $\lambda \in (0, 1)$ に対して $f(\lambda \mathbf{x} + (1-\lambda)\mathbf{y}) \leq \lambda f(\mathbf{x}) + (1-\lambda)f(\mathbf{y})$ を満たすとき、関数 f は下半連続な真凸関数という。 $\mathbb{R}^N$

(注1) これらの手法では効率的に解けないクラスの凸最適化問題に対応するためのアルゴリズムも提案されている^{(17)~(19)}。

(注2) マスターノードを必要としない非同期型の分散最適化手法も数多く研究されている。詳しくは6章を参照のこと。

上のすべての下半連続な真凸関数の集合を $\Gamma_0(\mathbb{R}^N)$ で表わす.

任意の $\gamma > 0$ に対し, $f \in \Gamma_0(\mathbb{R}^N)$ の近接写像 (proximity operator) は

$$\text{prox}_{\gamma f}(\mathbf{x}) := \underset{\mathbf{y} \in \mathbb{R}^N}{\operatorname{argmin}} f(\mathbf{y}) + \frac{1}{2\gamma} \|\mathbf{x} - \mathbf{y}\|^2 \quad (1)$$

で定義される. ここで $\|\cdot\|$ はユークリッドノルム (ℓ_2 ノルム) である. 第二項により, 写像先の存在性・一意性が保証されることに注意されたい. 当然ながら近接写像が効率的に計算可能かどうかは f に依存する.

3. 交互方向乗数法 (ADMM)

つぎのような凸最適化問題を考える.

$$\min_{\mathbf{x} \in \mathbb{R}^N, \mathbf{z} \in \mathbb{R}^M} g(\mathbf{x}) + h(\mathbf{z}) \quad \text{s.t.} \quad \mathbf{z} = \mathbf{L}\mathbf{x} \quad (2)$$

ここで, $g \in \Gamma_0(\mathbb{R}^N)$, $h \in \Gamma_0(\mathbb{R}^M)$, $\mathbf{L} \in \mathbb{R}^{M \times N}$ である (注3). 任意の初期点 $(\mathbf{z}^{(0)}, \mathbf{y}^{(0)})$ に対し, 交互方向乗数法 (Alternating Direction Method of Multipliers, ADMM) (2), (13) は, 問題 (2) の最適解を以下のアルゴリズムで逐次近似する.

$$\begin{cases} \mathbf{x}^{(n+1)} = \underset{\mathbf{x}}{\operatorname{argmin}} g(\mathbf{x}) + \frac{1}{2\gamma} \|\mathbf{z}^{(n)} - \mathbf{L}\mathbf{x} - \mathbf{y}^{(n)}\|^2 \\ \mathbf{z}^{(n+1)} = \text{prox}_{\gamma h}(\mathbf{L}\mathbf{x}^{(n+1)} + \mathbf{y}^{(n)}) \\ \mathbf{y}^{(n+1)} = \mathbf{y}^{(n)} + \mathbf{L}\mathbf{x}^{(n+1)} - \mathbf{z}^{(n+1)}. \end{cases} \quad (3)$$

ただし, $\gamma > 0$ であり, $\mathbf{y}$ は双対変数に相当する.

以下に代表的な交互方向乗数法の収束定理を紹介する.

定理 1 (Eckstein & Bertsekas¹³⁾). 問題 (2) のラグランジュ関数 $\mathcal{L}(\mathbf{x}, \mathbf{z}, \mathbf{y}) := g(\mathbf{x}) + h(\mathbf{z}) + \langle \mathbf{y}, \mathbf{L}\mathbf{x} - \mathbf{z} \rangle$ の鞍点 (注4) および $\mathbf{L}^\top \mathbf{L}$ の逆行列が存在すると仮定する. このとき, (3) で生成される点列 $(\mathbf{x}^{(n)}, \mathbf{z}^{(n)})_{n \geq 1}$ は問題 (2) の最適解 $(\mathbf{x}^*, \mathbf{z}^*)$ へ収束する.

交互方向乗数法は画像復元^{36), 37)} やロバスト主成分分析³⁸⁾ への応用を皮切りにさまざまな場面で活用されてきた. 最近では非凸最適化においても (実用的な意味での) 有効性が確認されており^{25), 39), 40)}, 局所解への収束条件の解析も行われている^{41), 42)}.

4. 交互方向乗数法による分散凸最適化

つぎのような凸最適化問題を考えよう.

$$\min_{\mathbf{u} \in \mathbb{R}^N} \sum_{k=1}^K f_k(\mathbf{u}) + \psi(\mathbf{u}) \quad (4)$$

ここで各 $f_k \in \Gamma_0(\mathbb{R}^N)$ および $\psi \in \Gamma_0(\mathbb{R}^N)$ は近接写像が計算可能であるとする. 5章で詳述するが, このような

(注3) より一般的な定式化を扱う場合²⁵⁾ もあるが, 応用上は問題 (2) で十分であることが多い.

(注4) 三つ組 $(\mathbf{x}^*, \mathbf{z}^*, \mathbf{y}^*)$ がすべての $(\mathbf{x}, \mathbf{z}, \mathbf{y}) \in \mathbb{R}^N \times \mathbb{R}^M \times \mathbb{R}^M$ に対して $\mathcal{L}(\mathbf{x}^*, \mathbf{z}^*, \mathbf{y}) \leq \mathcal{L}(\mathbf{x}, \mathbf{z}^*, \mathbf{y}^*) \leq \mathcal{L}(\mathbf{x}^*, \mathbf{z}, \mathbf{y}^*)$ を満たすとき, $(\mathbf{x}^*, \mathbf{z}^*, \mathbf{y}^*)$ を $\mathcal{L}(\mathbf{x}, \mathbf{z}, \mathbf{y})$ の鞍点と呼ぶ.

問題はさまざまな応用において登場する. この問題を分散最適化によって解く場合を想定する. 具体的には, 仮想ネットワーク上の k 番目のノード (プロセッサ/エージェント) が f_k のみを局所的な目的関数として知っている状況を想定し, マスターノードが ψ の評価と共にこれらのノードの更新情報を統合する (スター型のネットワークトポロジ). ゆえに, 何らかの理由で $f_1, \dots, f_K$ をまとめて評価することが困難な状況 (5章で一例を紹介する) において, 分散最適化が有力なアプローチとなる.

局所変数 $\mathbf{u}_1, \dots, \mathbf{u}_K \in \mathbb{R}^N$ を導入することで, 問題 (4) をつぎのように変形する.

$$\begin{aligned} \min_{\mathbf{u}_1, \dots, \mathbf{u}_K, \mathbf{w} \in \mathbb{R}^N} \quad & \sum_{k=1}^K f_k(\mathbf{u}_k) + \psi(\mathbf{w}) \\ \text{s.t.} \quad & \mathbf{u}_k = \mathbf{w}, \quad k = 1, \dots, K \end{aligned} \quad (5)$$

等式制約によりすべての局所変数が等しくなること (= 合意) が要請されるため, 問題 (5) は合意問題 (consensus problem) と呼ばれる.

この問題に交互方向乗数法を適用する. 具体的には, $\mathbf{x} := \mathbf{w}$, $\mathbf{z} := (\mathbf{u}_1^\top \cdots \mathbf{u}_K^\top)^\top$ とし,

$$\begin{aligned} g(\mathbf{x}) &:= \psi(\mathbf{w}), \quad h(\mathbf{z}) := \sum_{k=1}^K f_k(\mathbf{u}_k) \\ \mathbf{L} &:= (\mathbf{I}_N \cdots \mathbf{I}_N)^\top \in \mathbb{R}^{KN \times N} \end{aligned}$$

と置く (ただし, $\mathbf{I}_N$ は $N \times N$ の単位行列) と, 形式上, 交互方向乗数法が適用可能になる. 以下, 各 f_k および ψ の近接写像が計算可能であるという仮定に留意しながら, アルゴリズム (3) の更新式の詳細を見ていこう.

ステップ1はマスターノードにおける更新に対応する. 行列 $\mathbf{L}$ の定義から, 更新式は

$$\begin{aligned} \mathbf{w}^{(n+1)} &= \underset{\mathbf{w}}{\operatorname{argmin}} \psi(\mathbf{w}) + \frac{1}{2\gamma} \sum_{k=1}^K \|\mathbf{u}_k^{(n)} - \mathbf{w} - \mathbf{y}_k^{(n)}\|^2 \\ &= \underset{\mathbf{w}}{\operatorname{argmin}} \psi(\mathbf{w}) + \frac{K}{2\gamma} \left\| \frac{1}{K} \sum_{k=1}^K (\mathbf{u}_k^{(n)} - \mathbf{y}_k^{(n)}) - \mathbf{w} \right\|^2 \\ &= \text{prox}_{\frac{\gamma}{K} \psi} \left(\frac{1}{K} \sum_{k=1}^K (\mathbf{u}_k^{(n)} - \mathbf{y}_k^{(n)}) \right) \end{aligned}$$

のように変形できる. ここで, 双対変数 $\mathbf{y}$ も各 $\mathbf{u}_k$ に対応して分割されていること, および, 最初の式変形で最小化に関係ない項が消去されていることに注意されたい. まとめると, (i) 一時刻前の各ノードの更新情報をマスターノードが集約し, (ii) 局所変数の平均である $\frac{1}{K} \sum_{k=1}^K (\mathbf{u}_k^{(n)} - \mathbf{y}_k^{(n)})$ を計算し, (iii) これを入力として ψ の近接写像を計算することに相違ない.

ステップ2は各ノードにおける更新に対応する. 変数 $\mathbf{z}$ と関数 h の定義から明らかなように, $\mathbf{u}_k$ ごとに更新式を分離できる. すなわち, 各 $k \in \{1, \dots, K\}$ に関して,

$$\mathbf{u}_k^{(n+1)} = \text{prox}_{\gamma f_k}(\mathbf{w}^{(n+1)} + \mathbf{y}_k^{(n)}) \quad (6)$$

を計算すれば良く, 分散処理が可能である. 具体的には, マスターノードで更新された $\mathbf{w}^{(n+1)}$ の情報を受け取つ

た各ノードが、それ(と局所双対変数 $\mathbf{y}_k^{(n)}$)を入力として f_k の近接写像を計算することになる。ステップ3の双対変数の更新に関しても、ステップ2と同様に各ノードで分散計算できる。

以上をまとめると、Algorithm1 のようになる^(注5)。

Algorithm 1: 分散交互方向乗数法

```

while a stopping criterion is not satisfied do
     $\mathbf{w}^{(n+1)} = \text{prox}_{\frac{\gamma}{K}\psi}(\frac{1}{K} \sum_{k=1}^K (\mathbf{u}_k^{(n)} - \mathbf{y}_k^{(n)}))$ ;
    broadcast  $\mathbf{w}^{(n+1)}$  to all the local nodes;
    for  $k = 1, \dots, K$  in parallel do
         $\mathbf{u}_k^{(n+1)} = \text{prox}_{\gamma f_k}(\mathbf{w}^{(n+1)} + \mathbf{y}_k^{(n)})$ ;
         $\mathbf{y}_k^{(n+1)} = \mathbf{y}_k^{(n)} + \mathbf{w}^{(n+1)} - \mathbf{u}_k^{(n+1)}$ ;
        send  $\mathbf{u}_k^{(n+1)}$  and  $\mathbf{y}_k^{(n+1)}$  to the master node;
     $n \leftarrow n + 1$ ;

```

5. 応用例：正則化最小二乗法

正則化最小二乗法を題材に分散交互方向乗数法の具体的な応用方法について見ていこう。まず、以下のような(観測)モデルを考える。

$$\mathbf{v} = \Phi \bar{\mathbf{u}} + \mathbf{n} \quad (7)$$

モデル(7)は信号処理・制御・機械学習において登場するさまざまなモデルを内包する。たとえば、信号復元問題の場合は、 $\bar{\mathbf{u}} \in \mathbb{R}^N$ が推定すべき信号ベクトル、 $\mathbf{v} \in \mathbb{R}^M$ が観測信号、 $\Phi \in \mathbb{R}^{M \times N}$ が物理的な観測過程を表わす行列、 $\mathbf{n}$ が加法性ノイズを表わす。回帰問題の場合は、 $\bar{\mathbf{u}}$ が学習すべきパラメータベクトル、 $\mathbf{v} \in \mathbb{R}^M$ が出力データ、 Φ が K 個の訓練サンプルベクトル $\phi_k \in \mathbb{R}^N$ を転置し縦に並べた行列、 $\mathbf{n}$ が加法性ノイズにそれぞれ対応する。

このモデルのもと、正則化最小二乗法はつぎのように定式化される。

$$\min_{\mathbf{u} \in \mathbb{R}^N} \frac{1}{2} \|\Phi \mathbf{u} - \mathbf{v}\|^2 + \lambda \mathcal{R}(\mathbf{u}) \quad (8)$$

ここで、 $\mathcal{R} \in \Gamma_0(\mathbb{R}^N)$ は正則化関数であり、推定/学習すべき対象に関する事前知識や望ましい性質(たとえばスパース性など)を反映させる役割を果たす。問題(8)は応用上重要な最適化問題のクラスであり、 ℓ_1 ノルム/混合 $\ell_{1,2}$ ノルム正則化(LASSO/グループ LASSO)^{(43), (44)}、全変動(TV)正則化⁽⁴⁵⁾、フレーム正則化^{(46), (47)}、核型ノルム正則化⁽⁴⁸⁾ などさまざまな定式化の一般形になっている。

いま、行列 Φ とベクトル $\mathbf{v}$ を

$$\Phi = \begin{pmatrix} \Phi_1 \\ \vdots \\ \Phi_K \end{pmatrix}, \quad \mathbf{v} = \begin{pmatrix} \mathbf{v}_1 \\ \vdots \\ \mathbf{v}_K \end{pmatrix}$$

^(注5) Algorithm1 は文献⁽²⁵⁾ で紹介されているものとはほぼ同じであるが、交互方向乗数法(3)からの導出過程が若干異なる。

のように K 個のブロック行列/ベクトルに分割する。簡単のため M は K で割り切れるとし、各 Φ_k のサイズは等しい($\frac{M}{K} \times N$)ものとする。すると、問題(8)はつぎのように書き換えられる。

$$\min_{\mathbf{u} \in \mathbb{R}^N} \frac{1}{2} \sum_{k=1}^K \|\Phi_k \mathbf{u} - \mathbf{v}_k\|^2 + \lambda \mathcal{R}(\mathbf{u}) \quad (9)$$

明らかに、 $f_k(\mathbf{u}) := \frac{1}{2} \|\Phi_k \mathbf{u} - \mathbf{v}_k\|^2$, $\psi(\mathbf{u}) := \lambda \mathcal{R}(\mathbf{u})$ とすれば、問題(9)は問題(4)の一例となることがわかる。

5.1 二乗誤差関数 f_k の近接写像

Algorithm1 の更新順序とは前後するが、まずは f_k の近接写像の計算($\mathbf{u}_k^{(n)}$ の更新)について考えてみよう。近接写像の定義(1)から、以下の二次関数最小化問題に帰着される。

$$\min_{\mathbf{u} \in \mathbb{R}^N} \frac{1}{2} \|\Phi_k \mathbf{u} - \mathbf{v}_k\|^2 + \frac{1}{2\gamma} \|\mathbf{w}^{(n+1)} + \mathbf{y}_k^{(n)} - \mathbf{u}\|^2 \quad (10)$$

目的関数を微分し $\mathbf{u}$ について整理すると、

$$(\Phi_k^\top \Phi_k + \frac{1}{\gamma} \mathbf{I}_N) \mathbf{u} = \Phi_k^\top \mathbf{v}_k + \frac{1}{\gamma} (\mathbf{w}^{(n+1)} + \mathbf{y}_k^{(n)}) \quad (11)$$

となり、この線型方程式系を解けば良いのだが、行列 $(\Phi_k^\top \Phi_k + \frac{1}{\gamma} \mathbf{I})$ のサイズは $N \times N$ であるため、変数の次元 N が大きい($N \geq 10^4$) 場合^(注6)、一般にその計算は容易ではない($\mathcal{O}(N^2)$ を超えると厳しい)。仮に $\Phi_k^\top \Phi_k$ が疎行列であったり、高速な変換(フーリエ変換など)で対角化可能であるような構造をもっていれば $\mathcal{O}(N \log N)$ 程度の計算量で済むが、そうでない場合はどうすれば良いだろうか。実はここで分散最適化の定式化が活きるのである。当該行列に対し、逆行列の補題(Sherman-Morrison-Woodbury Formula⁽⁴⁹⁾)を用いると、

$$(\Phi_k^\top \Phi_k + \frac{1}{\gamma} \mathbf{I}_N)^{-1} = \gamma \mathbf{I}_N - \gamma^2 \Phi_k^\top (\mathbf{I}_{\frac{M}{K}} + \gamma \Phi_k \Phi_k^\top)^{-1} \Phi_k \quad (12)$$

を得る。注目すべきは、逆行列のサイズが $\frac{M}{K} \times \frac{M}{K}$ になっているため、 $\frac{M}{K}$ が N に比べて十分に小さければ、計算量を大幅に削減できる点である。仮に、 M 個の CPU コアによる並列計算が可能($K = M$)であるとすると、(12)式右辺の逆行列はスカラーになり、結果として(11)式の計算量は $\mathcal{O}(N)$ まで低減される。

5.2 正則化関数 $\mathcal{R}$ の近接写像

つぎは $\lambda \mathcal{R}$ の近接写像($\mathbf{w}^{(n)}$ の更新)である。当然のことながら近接写像の計算可能性は $\mathcal{R}$ の種類に依存するが、ここではいくつかの有用な正則化関数の近接写像が効率的に計算できることを示そう。以下に紹介する正則化関数はどれも微分不可能な凸関数であるため、従来の勾配法のような最適化手法(をベースにした分散最適化手法)では扱いが困難であることに注意されたい。

^(注6) たとえば画像再構成問題を考える場合、 N は画素数(の自然数倍)に相当し、 $N > 10^5$ であることが多い。

まずは、統計的推定や圧縮センシング⁵⁰⁾のパラダイムでその有効性が示された ℓ_1 ノルム正則化 (LASSO) の場合を考える. ℓ_1 ノルム $\|\mathbf{x}\|_1 := \sum_{i=1}^N |x_i|$ は非凸関数である ℓ_0 擬ノルム^(注7)の下界の中で最大の凸関数になっており、推定対象がスパースである際に ℓ_2 ノルム正則化 (Tikhonov 正則化) に比べて高い推定性能を示すことが知られている^(注8). このとき、 $\mathcal{R} = \|\cdot\|_1$ の近接写像はよく知られたソフト閾値処理に一致する. 具体的には、入力ベクトルの各要素の絶対値を削る処理になり、数式で示すと $i = 1, \dots, N$ に対しつぎのようになる.

$$[\text{prox}_{\gamma\|\cdot\|_1}(\mathbf{x})]_i = \text{sgn}(x_i) \max\{|x_i| - \gamma, 0\}$$

ここで $\text{sgn}(\cdot)$ は $(\cdot)$ の符号を表わす.

推定対象 $\mathbf{u}$ に対してグループ構造をもつスパース性が仮定できる場合 (値の大きい要素がまとまって現れる) は、混合 $\ell_{1,2}$ ノルム $\|\mathbf{x}\|_{1,2} := \sum_{\mathbf{g} \in \mathcal{G}} \|\mathbf{x}_{\mathbf{g}}\|_2$ による正則化 (グループ Lasso) が有効となる. ここで、 $\mathbf{x}_{\mathbf{g}}$ は $\mathbf{x}$ の要素を重複のないグループに分割した際の各グループベクトルを表わす. この場合の近接写像の計算は以下のようなグループごとにスケールされたソフト閾値処理になり、 ℓ_1 ノルムのときと同様に効率的に計算できる.

$$[\text{prox}_{\gamma\|\cdot\|_{1,2}}(\mathbf{x})]_{\mathbf{g}} = \max\{1 - \frac{\gamma}{\|\mathbf{x}_{\mathbf{g}}\|_2}, 0\} \mathbf{x}_{\mathbf{g}}, \text{ for } \mathbf{g} \in \mathcal{G}$$

何らかの線型変換を介したドメインで (グループ) スパース性を評価したいとき、つまり $\mathcal{R}(\mathbf{x}) = \|\Psi\mathbf{x}\|_1$ (Ψ は行列) のような場合はどうなるだろうか. 近接写像に関する性質として以下のようなものがある. $\Psi\Psi^\top = \alpha\mathbf{I}_N$ ($\alpha > 0$) を満たす任意の行列 Ψ に対して、

$$\text{prox}_{\gamma\mathcal{R} \circ \Psi}(\mathbf{x}) = \mathbf{x} + \alpha^{-1}\Psi^\top(\text{prox}_{\gamma\alpha\mathcal{R}}(\Psi\mathbf{x}) - \Psi\mathbf{x})$$

が成立する. すなわち、行列が合成される前の関数の近接写像が計算可能であれば、それを利用して合成後の近接写像も計算できるということである. 任意の直交変換はこの条件を満たすため、フーリエ変換や直交ウェーブレット変換後の係数のスパース性を評価することができる. この条件を満たさない線型変換を利用する場合は、一般には閉形式で近接写像を計算できるとは限らない (二次元の全変動正則化やフレーム正則化がこれに相当する). このような場合、Algorithm1 では、近接写像を近似的に計算するために別の反復手法 (近接勾配法の加速版である FISTA⁵¹⁾ など) を内部ループで用いる必要がある. 本稿では詳しく触れないが、このような状況を回避できる分散最適化手法も研究されている (6 章を参照のこと).

推定対象 $\mathbf{u}$ がベクトルではなく行列の場合、核型ノルム $\|\mathbf{X}\|_* := \sum_{i=1}^n \sigma_i(\mathbf{X})$ ($\sigma_i(\mathbf{X})$ は行列 $\mathbf{X} \in \mathbb{R}^{n_1 \times n_2}$

(注7) ベクトルの非ゼロの要素数として定義されるため、スパース性の理想的な評価指標とみなされている.

(注8) 統計的には推定対象に関する事前分布としてラプラス分布を仮定することに相当する.

の i 番目に大きい特異値を表わし、 $n := \min\{n_1, n_2\}$ である) を正則化関数として用いる場合が考えられる. ℓ_1 ノルムと ℓ_0 擬ノルムの関係と同様に、核型ノルムは行列のランク関数の下界の中で最大の凸関数になっているため、推定対象行列に低ランク性を仮定できる場合に核型ノルム正則化が有効となる. 核型ノルムの近接写像の計算は特異値にソフト閾値処理を施すことに相当する. 具体的には、行列 $\mathbf{X}$ の特異値分解を $\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^\top$ (Σ は $\mathbf{X}$ の特異値を要素とする対角行列、 $\mathbf{U}$, $\mathbf{V}$ は直交行列) とすると、

$$\text{prox}_{\gamma\|\cdot\|_*}(\mathbf{X}) = \mathbf{U}\tilde{\Sigma}_\gamma\mathbf{V}^\top$$

となる. ここで、 $\tilde{\Sigma}_\gamma$ は対角行列であり、その要素は $\max\{\sigma_i(\mathbf{X}) - \gamma, 0\}$ ($i = 1, \dots, n$) である. 行列の一般化であるテンソルに対するテンソル核型ノルム正則化⁵²⁾ や、推定対象行列を小さいブロックに分割した際の低ランク性を評価するためのブロック核型ノルム正則化⁵³⁾ などの拡張も提案されており、これらの近接写像も特異値のソフト閾値処理を用いて計算できる.

最後に、正則化とは少し異なるが、推定対象に対して何らかの制約条件を課す場合を考えよう. 制約条件が空でない閉凸集合 $C \in \mathbb{R}^N$ として表現されると仮定し、 C に対する指示関数を以下のように定義する.

$$\iota_C(\mathbf{x}) := \begin{cases} 0, & \text{if } \mathbf{x} \in C, \\ \infty, & \text{otherwise} \end{cases}$$

すると、(1) 式より、指示関数の近接写像は距離射影^(注9)となるため、 $\mathcal{R} := \iota_C$ とすれば、Algorithm1 は制約付き最小二乗問題を分散最適化するアルゴリズムとして利用できる. 以下に応用上有用である距離射影が計算可能な閉凸集合の例を紹介する.

- 範囲制約: $C := [a, b]^N$ ($a < b$) で定義され、推定対象が取りうる値 (たとえば 8bit 画像の場合は $[0, 255]$) を制限する. 距離射影は範囲外の値を a か b どちらか近い方の値に置き換えるだけである.
- ℓ_2 ノルム球: $C := \{\mathbf{x} \in \mathbb{R}^N \mid \|\mathbf{x} - \mathbf{b}\| \leq \varepsilon\}$ ($\varepsilon > 0$, $\mathbf{b} \in \mathbb{R}^N$) で定義され、球の外にあるベクトル $\mathbf{x}$ に対し距離射影は $P_C(\mathbf{x}) = \mathbf{b} + \frac{\varepsilon(\mathbf{x} - \mathbf{b})}{\|\mathbf{x} - \mathbf{b}\|}$ で与えられる.
- ℓ_1 ノルム球: $C := \{\mathbf{x} \in \mathbb{R}^N \mid \|\mathbf{x} - \mathbf{b}\|_1 \leq \varepsilon\}$ ($\varepsilon > 0$, $\mathbf{b} \in \mathbb{R}^N$) で定義される. 距離射影は閉形式では表現できないが、有限回で終了するアルゴリズム⁵⁴⁾ によって効率的に計算可能である.

6. 発展的な手法

本稿の主題に関連する発展的な手法について紹介する. スペースの関係上、詳細な説明は省くため、詳しい内容

(注9) 閉凸集合 $C \neq \emptyset$ に対する距離射影は $P_C(\mathbf{x}) := \arg\min_{\mathbf{y} \in C} \|\mathbf{x} - \mathbf{y}\|$ で定義され、現在の点 $\mathbf{x}$ を最も近い C 内の点に移す写像である.

に関しては文献を参照されたい。

非同期型アルゴリズム：本稿で解説した分散最適化手法は、マスターノードがすべてのノードの情報を受け取ってから更新を行う同期型のアルゴリズムであった。その性質上当然ではあるが、特定のノードの更新情報の伝達の遅れが全体の速度低下に繋がる。最悪の場合、特定のノードが故障してしまうとアルゴリズム自体を停止せざるを得ない。このような欠点を解消するために、非同期型の分散最適化手法が提案され、さまざまな非同期状況（確率的/決定論的）を仮定した上で解析が行われている^{30), 31), 33), 55)}。

広いクラスの最適化問題への対応およびアルゴリズムの効率化：本稿で対象とした最適化問題（4）ではカバーできないクラスの問題を効率的に扱える分散最適化手法もいくつか提案されている。代表的なものとして、非凸最適化問題への対応⁵⁵⁾、各局所変数に多面体制約が課されている場合の分散最適化⁵⁶⁾、内部ループを回避できる主-双対近接分離型分散最適化⁵⁷⁾などが挙げられる。また、アルゴリズム中の近接写像の計算を大幅に近似しても収束が保証される手法も提案されている³⁴⁾。

7. むすび

本稿では交互方向乗数法に基づくアプローチを中心に近接分離による分散最適化を解説した。近接分離最適化では、近接写像が計算可能な関数ごとに変数を分離するテクニックが鍵となっている。ゆえに、本質的に並列処理へ向いており、局所変数を介して自然な形で分散最適化へ適用できる。また、最近では分散最適化だけでなく、（合意問題ではない）制御のための最適化^{58), 59)}やグラフ上に定義された信号を扱う最適化^{60), 61)}などにおいても近接分離最適化が活用されており、今後ますますその応用範囲は広がっていくと予想される。

（2016年7月25日受付）

参考文献

- 1) R.T. Ralph: Convex analysis, Princeton university press (1970)
- 2) S. Boyd and L. Vandenberghe: Convex optimization, Cambridge university press (2004)
- 3) H.H. Bauschke and P.L. Combettes: Convex analysis and monotone operator theory in Hilbert spaces, Springer, New York (2011)
- 4) D.P. Palomar and Y.C. Eldar, Eds.: Convex Optimization in Signal Processing and Communications, 1st, Cambridge University Press (2009)
- 5) J.-L. Starck, F. Murtagh, and J.M. Fadili: Sparse Image and Signal Processing: Wavelets, Curvelets, Morphological Diversity, Cambridge University Press (2010)
- 6) S. Sra, S. Nowozin, and S.J. Wright: Optimization for Machine Learning, Neural information processing series, MIT Press (2012)
- 7) P.L. Combettes and J.-C. Pesquet: Proximal splitting methods in signal processing, *Fixed-Point Algorithms for Inverse Problems in Science and Engineering*, 185/212, Springer-Verlag (2011)
- 8) N. Parikh and S. Boyd: Proximal Algorithms, *Foundations and Trends in Optimization*, 1–3, 127/239 (2014)
- 9) G.B. Passty: Ergodic convergence to a zero of the sum of monotone operators in Hilbert space, *J. Math. Anal. Appl.*, **72**, 383/390 (1979)
- 10) P. Tseng: Applications of a splitting algorithm to decomposition in convex programming and variational inequalities, *SIAM J. Control Optim.*, **29**, 119/138 (1991)
- 11) P.L. Combettes and V. Wajs: Signal recovery by proximal forward-backward splitting, *SIAM J. Multi. Model. Simul.*, **4**, 1168/1200 (2005)
- 12) D. Gabay and B. Mercier: A dual algorithm for the solution of nonlinear variational problems via finite elements approximations, *Comput. Math. Appl.*, **2**, 17/40 (1976)
- 13) J. Eckstein and D. Bertsekas: On the Douglas-Rachford splitting method and proximal point algorithm for maximal monotone operators, *Math. Program.*, **55**, 293/318 (1992)
- 14) A. Chambolle and T. Pock: A first-order primal-dual algorithm for convex problems with applications to imaging, *J. Math. Imaging and Vision*, **40**–1, 120/145 (2010)
- 15) P.L. Combettes and J.-C. Pesquet: Primal-dual splitting algorithm for solving inclusions with mixtures of composite, Lipschitzian, and parallel-sum type monotone operators, *Set-Val. Var. Anal.*, **20**–2, 307/330 (2012)
- 16) L. Condat: A primal-dual splitting method for convex optimization involving Lipschitzian, proximable and linear composite terms, *J. Optimization Theory and Applications* (2013)
- 17) P.L. Combettes: Systems of Structured Monotone Inclusions: Duality, Algorithms, and Applications, *SIAM J. Optim.*, **23**–4, 2420/2447 (2013)
- 18) S. Ono and I. Yamada: Hierarchical convex optimization with primal-dual splitting, *IEEE Trans. Signal Process.*, **63**–2, 373/388 (2015)
- 19) S. Ono and I. Yamada: Signal recovery with certain involved convex data-fidelity constraints, *IEEE Trans. Signal Process.*, **63**–22, 6149/6163 (2015)
- 20) D.P. Bertsekas and J.N. Tsitsiklis: Parallel and distributed computation: numerical methods, **23**, Prentice hall Englewood Cliffs, NJ (1989)
- 21) I.D. Schizas, A. Ribeiro, and G.B. Giannakis: Consensus in Ad Hoc WSNs With Noisy Links –Part I: Distributed Estimation of Deterministic Signals, *IEEE Trans. Signal Process.*, **56**–1, 350/364 (2008)
- 22) Q. Ling and Z. Tian: Decentralized Sparse Signal Recovery for Compressive Sleeping Wireless Sensor Networks, *IEEE Trans. Signal Process.*, **58**–7, 3816/3827 (2010)
- 23) G. Mateos, J.A. Bazerque, and G.B. Giannakis: Distributed Sparse Linear Regression, *IEEE Trans. Signal Process.*, **58**–10, 5262/5276 (2010)
- 24) T. Erseghe, D. Zennaro, E. Dall’Anese, and L. Vangelista: Fast Consensus by the Alternating Direction Multipliers Method, *IEEE Trans. Signal Process.*, **59**–11, 5523/5537 (2011)
- 25) S. Boyd, N. Parikh, E. Chu, B. Peleato, and J. Eckstein: Distributed optimization and statistical learning via the alternating direction method of multipliers, *Foundations and Trends in Machine Learning*, **3**–1, 1/122 (2011)
- 26) J.F.C. Mota, J.M.F. Xavier, P.M.Q. Aguiar, and M. Puschel: Distributed Basis Pursuit, *IEEE Trans. Signal Process.*, **60**–4, 1942/1956 (2012)
- 27) C. Shen, T.H. Chang, K.Y. Wang, Z. Qiu, and C.Y. Chi: Distributed Robust Multicell Coordinated Beamforming With Imperfect CSI: An ADMM Approach, *IEEE Trans. Signal Process.*, **60**–6, 2988/3003 (2012)

- 28) E. Wei and A. Ozdaglar: Distributed Alternating Direction Method of Multipliers, *IEEE Conf. Decis. Cont. (CDC)*, 5445/5450 (2012)
- 29) J.F.C. Mota, J.M.F. Xavier, P.M.Q. Aguiar, and M. Pschel: D-ADMM: A Communication-Efficient Distributed Algorithm for Separable Optimization, *IEEE Trans. Signal Process*, **61**–10, 2718/2723 (2013)
- 30) F. Iutzeler, P. Bianchi, P. Ciblat, and W. Hachem: Asynchronous distributed optimization using a randomized alternating direction method of multipliers, *IEEE Conf. Decis. Cont. (CDC)*, 3671/3676 (2013)
- 31) E. Wei and A. Ozdaglar: On the $O(1/k)$ convergence of asynchronous distributed alternating direction method of multipliers, *ArXiv e-prints*, <http://arxiv.org/abs/1307.8254> (2013)
- 32) W. Shi, Q. Ling, K. Yuan, G. Wu, and W. Yin: On the Linear Convergence of the ADMM in Decentralized Consensus Optimization, *IEEE Trans. Signal Process*, **62**–7, 1750/1761 (2014)
- 33) R. Zhang and J. Kwok: Asynchronous distributed ADMM for consensus optimization, *Proc. Int. Conf. Mach. Learn.(ICML)*, 1701/1709 (2014)
- 34) T.H. Chang, M. Hong, and X. Wang: Multi-Agent Distributed Optimization via Inexact Consensus ADMM, *IEEE Trans. Signal Process*, **63**–2, 482/497 (2015)
- 35) F. Iutzeler, P. Bianchi, P. Ciblat, and W. Hachem: Explicit Convergence Rate of a Distributed Alternating Direction Method of Multipliers, *IEEE Trans. Auto. Control*, **61**–4, 892/904 (2016)
- 36) T. Goldstein and S. Osher: The split Bregman method for L_1 -regularized problems, *SIAM J. Imaging Sci.*, **2**, 323/343 (2009)
- 37) M. Afonso, J. Bioucas-Dias, and M. Figueiredo: Fast image recovery using variable splitting and constrained optimization, *IEEE Trans. Image Process*, **19**–9, 2345/2356 (2010)
- 38) E.J. Candès, X. Li, Y. Ma, and J. Wright: Robust principal component analysis?, *Journal of the ACM*, **58**–3 (2011)
- 39) Z. Wen, C. Yang, X. Liu, and S. Marchesini: Alternating direction methods for classical and ptychographic phase retrieval, *Inverse Problems*, **28**–11, 115010 (2012)
- 40) S. Ono and I. Yamada: Color-line regularization for color artifact removal, *IEEE Trans. Comput. Imag.*, **2**–3, 204/217 (2016)
- 41) G. Li and T.K. Pong: Global convergence of splitting methods for nonconvex composite optimization, *SIAM J. Optim.*, **25**–3, 2434/2460 (2015)
- 42) M. Hong, Z.-Q. Luo, and M. Razaviyayn: Convergence analysis of alternating direction method of multipliers for a family of nonconvex problems, *SIAM J. Optim.*, **26**–1, 337/364 (2016)
- 43) R. Tibshirani: Regression shrinkage and selection via the lasso, *Journal of the Royal Statistical Society: Series B (Methodological)*, 267/288 (1996)
- 44) M. Yuan and Y. Lin: Model selection and estimation in regression with grouped variables, *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, **68**–1, 49/67 (2006)
- 45) L.I. Rudin, S. Osher, and E. Fatemi: Nonlinear total variation based noise removal algorithms, *Phys. D*, **60**–1–4, 259/268 (1992)
- 46) D.L. Donoho and I.M. Johnstone: Adapting to unknown smoothness via wavelet shrinkage, *Journal of the american statistical association*, **90**–432, 1200/1224 (1995)
- 47) J.-Luc Starck, E.J. Candès, and D.L. Donoho: The curvelet transform for image denoising, *IEEE Trans. Image Process*, **11**–6, 670/684 (2002)
- 48) J.-F. Cai, E. Candès, and Z. Shen: A singular value thresholding algorithm for matrix completion, *SIAM J. Optim.*, **20**–4, 1956/1982 (2010)
- 49) G.H. Golub and C.F.V. Loan: Matrix Computations, 4th ed., Johns Hopkins University Press (2012)
- 50) E. Candès and M. Wakin: An introduction to compressive sampling, *IEEE Signal Process. Magazine*, **25**–2, 21/30 (2008)
- 51) A. Beck and M. Teboulle: A fast iterative shrinkage-thresholding algorithm for linear inverse problems, *SIAM J. Imaging. Sci.*, **2**, 183/202 (2009)
- 52) S. Gandy, B. Recht, and I. Yamada: Tensor completion and low-n-rank tensor recovery via convex optimization, *Inverse Problems*, **27**–2 (2011)
- 53) S. Ono, T. Miyata, and I. Yamada: Cartoon-texture image decomposition using blockwise low-rank texture characterization, *IEEE Trans. Image Process*, **23**–3, 1128/1142 (2014)
- 54) J. Duchi, S. S-Shwartz, Y. Singer, and T. Chandra: Efficient projections onto the ℓ_1 -ball for learning in high dimensions, *Proc. Int. Conf. Mach. Learn.(ICML)*, 272/279 (2008)
- 55) T.H. Chang, M. Hong, W.C. Liao, and X. Wang: Asynchronous Distributed ADMM for Large-Scale Optimization – Part I: Algorithm and Convergence Analysis, *IEEE Trans. Signal Process*, **64**–12, 3118/3130 (2016)
- 56) T.H. Chang: A Proximal Dual Consensus ADMM Method for Multi-Agent Constrained Optimization, *IEEE Trans. Signal Process*, **64**–14, 3719/3734 (2016)
- 57) J.-C. Pesquet and A. Repetti: A class of randomized primal-dual algorithms for distributed optimization, *J. Nonlinear Convex Anal.*, **16**–12, 2453/2490 (2015)
- 58) F. Lin, M. Fardad, and M.R. Jovanovi: Design of Optimal Sparse Feedback Gains via the Alternating Direction Method of Multipliers, *IEEE Trans. Auto. Control*, **58**–9, 2426/2431 (2013)
- 59) T. Ikeda, M. Nagahara, and S. Ono: Discrete-Valued Control by Sum-of-Absolute-Values Optimization, *IEEE Trans. Auto. Control*, accepted (2016)
- 60) S. Ono, I. Yamada, and I. Kumazawa: Total generalized variation for graph signals, *Proc. IEEE Int. Conf. Acoust., Speech, Signal Process.(ICASSP)* (2015)
- 61) S. Chen, A. Sandryhaila, J.M.F. Moura, and J. Kovaevi: Signal Recovery on Graphs: Variation Minimization, *IEEE Trans. Signal Process*, **63**–17, 4609/4624 (2015)

[著者紹介]

おの 野 峻 佑 君



2010年東京工業大学工学部情報工学科卒。14年同大学大学院理工学研究科博士課程修了(集積システム専攻)。博士(工学)。12~14日本学術振興会特別研究員(DC1)。現在、東京工業大学 科学技術創成研究院 未来産業技術研究所 助教、および JST さきがけ個人研究者(兼任)。主として画像処理、信号処理、数理最適化の研究に従事。電子情報通信学会学術奨励賞(2013)、電子情報通信学会論文賞(2014)、IEEE SPS Japan Chapter Outstanding Student Journal Paper Award(2014)、丹羽保次郎記念論文賞(2015)、手島精一記念研究賞博士論文賞(2016)、テレコムシステム技術賞(奨励賞、2016)各受賞。IEEE、電子情報通信学会の会員。